


Automatické rozhodovanie prostriedkami umelej inteligencie




Cvičenie 11 z predmetu RaZ



Na dnešnom cvičení sa budeme venovať automatickému rozhodovaniu pomocou prostriedkov výpočtovej umelej inteligencie, najmä umelých neurónových sietí.

Základné typy rozhodovacích problémov riešiteľných prostriedkami UI

- Klasifikácia
 - triedy
 - nominálne hodnoty
 - označené (labelled)
- Zhukovanie
 - zhluky
 - nominálne hodnoty
 - neoznačené (unlabelled)
- Predikcia
 - numerické hodnoty




Na úvod krátke opakovanie.

Klasifikácia je zatriedenie objektov do množiny vopred známych tried. Výsledkom je teda nominálna označená hodnota. Podmienky, kedy patrí objekt do danej triedy sú vopred známe. Napríklad v grafe možno dáta do tried krivkou, resp. hyperplochou).

Zhlukovanie je zatriedenie objektov do množiny neoznačených zhukov. Zhuk je podobný triede avšak s tým rozdielom, že nemá priradený názov, teda je to neoznačená (unlabelled) nominálna hodnota. Neexistujú žiadne vonkajšie podmienky, ako priradzovať objekty k zhukom, ale platí, že objekty v rámci toho istého zhuku majú podobné atribúty. Vzhľadom na chýbajúce vonkajšie podmienky nevieme dáta v grafe rozseparovať krivkami/hyperplochami.

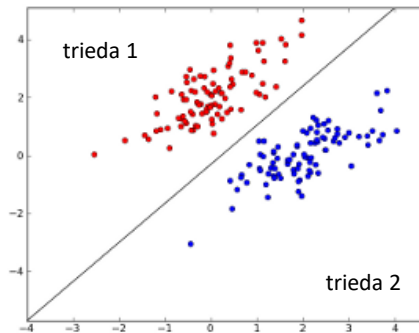
Pri predikcii na základe historických dát nejakej meranej (numerickej) veličiny (alebo viacerých veličín) z minulosti predikujeme hodnotu tejto veličiny do budúcnosti.

KLASIFIKÁCIA



Zaradenie príkladu do triedy


- nominálna označená (labelled) hodnota



Klasifikácia je zatriedenie nového príkladu do vopred definovaného **konečného počtu** tzv. klasifikačných tried.

ZHLUKOVANIE

Zoskupovanie podobných príkladov do zhlukov




Zhlukovanie umožňuje určiť príslušnosť rozhodovacieho prípadu do skupiny tzv. zhliku. Objekty vo vnútri zhliku sa vyznačujú podobnými atribútmi. Počet zhlukov sa určuje buď manuálne alebo automaticky.

PREDIKCIA



- Nie na základe predpokladov a domnienok
- Na základe predošlých dát, štatisticky separovateľných zložiek (trend, periodicitu, náhodnosť)
- Iných predikčných modelov



Predikcia je podobná klasifikácii, ale s tým rozdielom, že výsledkom nie je trieda ale numerická hodnota, ktorá by mala nasledovať s ohľadom na hodnoty predchádzajúce.

Systémy umelej inteligencie

„Cieľom systemov umelej inteligencie je vypracovať paradigmy alebo algoritmy, ktoré požadujú od stroja riešiť ulohy, ktoré by vyriešil len človek so znalosťami.“



Požiadavky na systémy UI:

- vedieť **uložiť znalosti**,
 - knowledge representation,
- automaticky **získavať nové znalosti** počas experimentov,
 - učenie (learning).
- **aplikovať znalosti** pre riešenie problému,
 - uvažovanie (reasoning),

Dôležité je uvedomiť si, že systémy výpočtovej UI kladú dôraz na schopnosť automatického učenia z dát.


Prostriedky výpočtovej inteligencie

- **neurónové siete**
 - učenie a adaptačné schopnosti



- **evolučné algoritmy**
 - systematické náhodné hľadanie,
 - optimalizácia

- **fuzzy logika**
 - reprezentácia neurčitosti




Neurónové siete

- neurónová sieť (NS) je masívne paralelný procesor, ktorý má sklon k uchovávaní znalostí a ich ďalšiemu využívaniu.
- má schopnosť aproximácie ľubovoľnej funkcie pomocou vzoriek vstupných a výstupných dát bez ohľadu na znalosť matematického modelu problému.
- je uznávaným spôsobom riešenia širokého spektra problémov:
 - klasifikácia do tried, predikcia, zhlukovanie,
 - aproximácia funkcií, transformácia signálov,
 - asociačné problémy, simulácia pamäte,
- je robustnou alternatívou ku konvenčným deterministickým a programovateľným metódam

Neurónové siete

- Základnou procesnou jednotkou je umelý neurón



VSTUPNÁ FUNKCIA

$$in_i = \sum_{j=1}^N w_{ij} y_j + \Theta_i$$

AKTIVAČNÁ FUNKCIA



$$x_i = f(in_i) = \frac{1}{1 + e^{-\delta in_i}}$$

VÝSTUPNÁ FUNKCIA

$$y_i = out(x_i) = x_i$$

Neurónové siete

- neuróny sa v NS skladajú do zložitejších štruktúr (topológií),
- najpoužívanejšou topológiou je viacvrstvová štruktúra:
 - jedna vstupná vrstva,
 - jedna výstupná vrstva,
 - jedna alebo viaceré skryté vrstvy
- topológie NS rozdeľujeme do dvoch základných skupín:
 - dopredné NS,
 - rekurentné NS.
- najjednoduchšou štruktúrou je jednovrstvový perceptrón.




Perceptrón je najjednoduchšia dopredná neurónová sieť. Skladá sa z viacerých neurónov na vstupe a jedného neurónu na výstupe aj na skrytej vrstve. Dokáže rozdeliť objekty do dvoch tried, ale podmienkou je ich lineárna separovateľnosť. Ak sú dáta lineárne separovateľné, je možné ich rozdeliť priamkou, vid' obr.

Perceptrón a XOR problém


STIAHNITE SI PODKLADY Z:

<http://lirslm.fei.tuke.sk/raz/cviko11.zip>

LINEÁRNE SEPAROVATEĽNÉ DÁTA



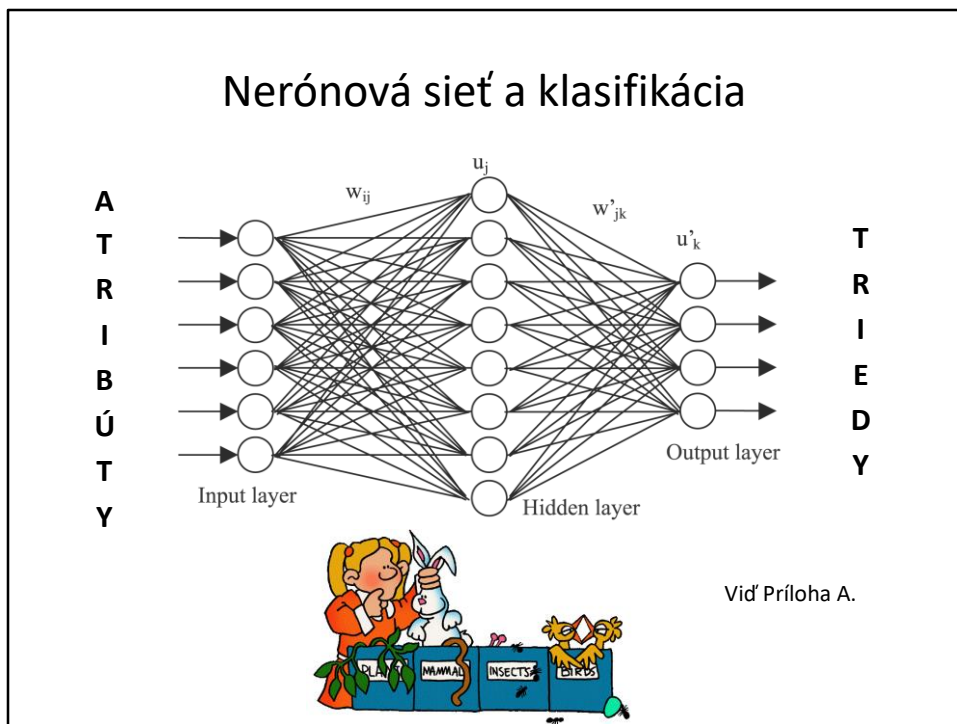
XOR PROBLÉM



Problémom perceptrónu je neschopnosť klasifikovať dáta ak nie sú lineárne separovateľné.

Nasleduje názorná ukážka v Programe – Multilayer Perceptron:

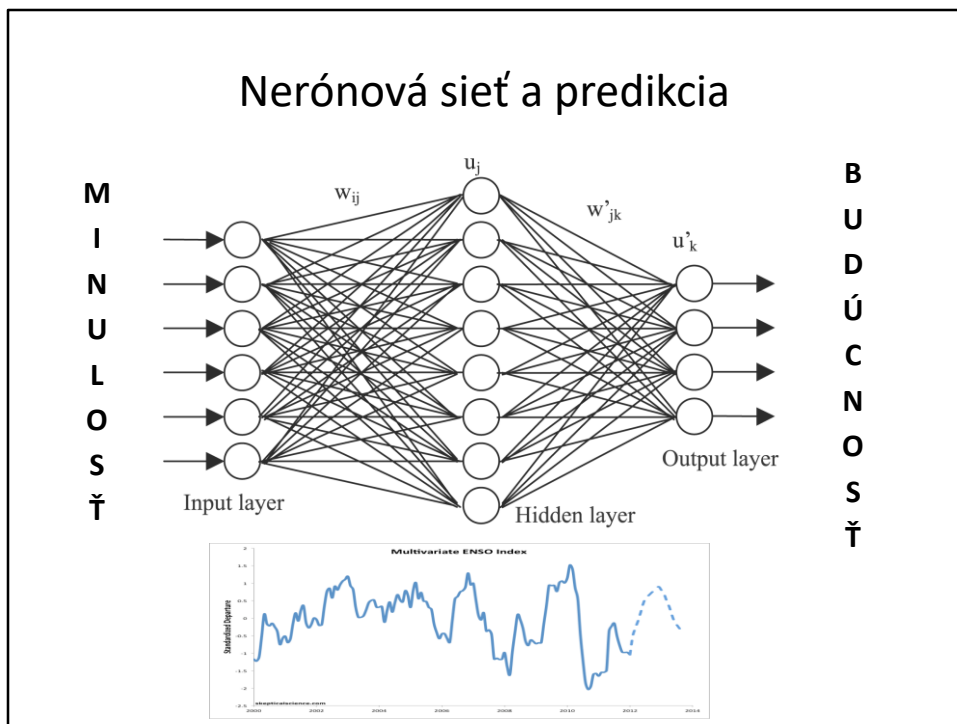
1. Skopírujeme si trénovaciu a testovaciu množinu zo zložky XOR ku binárke.
(Pokúste sa pozrieť do tých súborov a pochopiť, ako sú v nich uložené dáta)
2. Spustíme program a vytvoríme novú NS bez skrytej vrstvy.
3. Pokúsime sa učiť takto vytvorenú sieť.
4. Výsledky budú nedostatočné, pretože jednovrstvový perceptrón nedokáže XOR problém vyriešiť.
5. Môžeme skúsiť vytvoriť zložitejšiu NS, ktorá už tento problém bude vedieť riešiť.



Pomocou NS je možné jednoducho klasifikovať objekty z viacerými atribútmi do rôznych tried.

Nasleduje názorná ukážka v Programe – Multilayer Perceptron:

1. Skopírujeme si trénovaciu a testovaciu množinu zo zložky Klasifikácia ku binárke. (Pokúste sa pozrieť do tých súborov a pochopiť, ako sú v nich uložené dáta)
2. Ide o multispektrálne satelitné dáta so 7 atribútmi a 6 možnými triedami (cesty, stromy, lúky, domy atď.)
3. Pokúsime sa naučiť neurónovú sieť klasifikovať tieto dáta.




Pomocou NS je možné jednoducho predikovať hodnoty numerických atribútov v budúcnosti. Na vstupe sú historické hodnoty numerickej veličiny v pevne danom poradí (časovom okne) v minulosti a na výstupe sú predikované hodnoty v pevne danom časovom poradí v budúcnosti.

Nasleduje názorná ukážka v Programe – Multilayer Perceptron:

1. Vygenerujeme si trénovaciu a testovaciu množinu pomocou programu v priečinku Predikcia, alebo použijeme už vygenerované množiny z podpriečinku. (Pokúste sa pozrieť do tých súborov a pochopiť, ako sú v nich uložené dáta)
2. Trénovacia množina pozostáva z meteorologických dát, konkrétne teploty, z oblasti TUKE z mesiaca november (2013). Testovacia množina je z konca novembra a zo začiatku decembra. Záznamy sú vedené v 15-minútových intervaloch.
3. Cieľom je učiť NS na dátach z novembra a takto naučenú sieť použiť na predikovanie teploty v decembri.

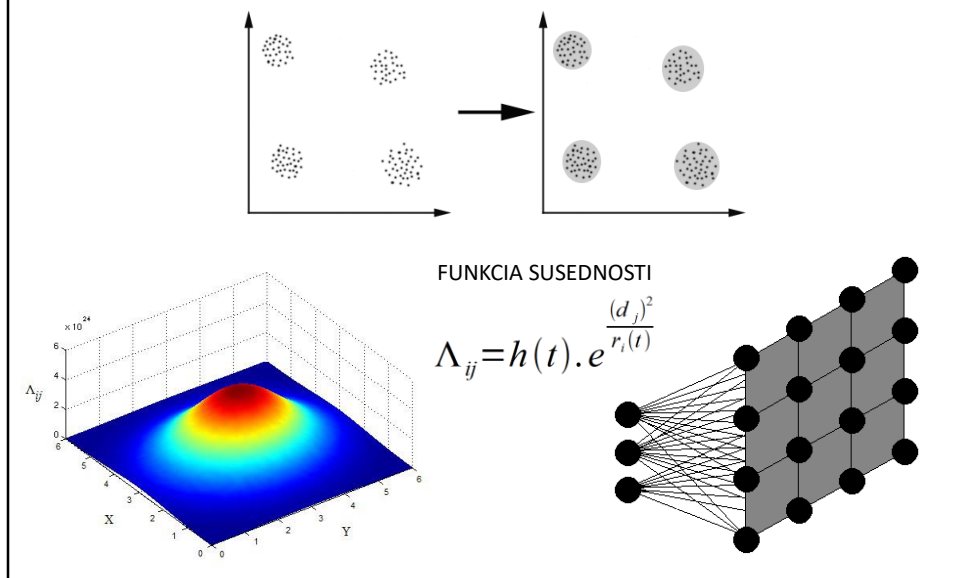
Neurónové siete - Zhlukovanie

- Pri nekontrolovanom učení môžeme ponúknuť iba vstupné dáta, ktoré sieť sama spracuje a určí výstup.
- Konkurenčné učenie je proces, pri ktorom sa hodnoty SV na výstupných neurónoch formujú do pozície zodpovedajúcej centráam zhlukov.
- Výstupná vrstva sa formuje iba na základe vstupných dát, čo zodpovedá nekontrolovanému učeniu.
- Topológia NS pre konkurenčné učenie je dvojvrstvová, kde na vstupnej vrstve sa nachádza M neurónov a na výstupnej N neurónov.



Vid' Príloha B.

Kohonenove mapy - Zhlukovanie



Kohonenove siete predstavujú veľmi dôležité rozšírenie konkurenčného učenia, ktoré spočíva v dvoch hlavných zmenách:

1. Prvá zmena spočíva v tom, že neuróny na výstupnej vrstve NS sú usporiadané do nejakého geometrického tvaru, ktorý značne závisí od konkrétnej aplikácie.
2. Najčastejšie je používaná dvojrozmerná mriežka v tvare obdĺžnika, kde sú neuróny vo vrstve umiestnené vedľa seba, a teda existuje možnosť určenia suseda. Túto vrstvu nazývame Kohonenovou vrstvou.
3. Ďalším rozšírením je pripustenie princípu viacerých víťazov (multiply WTA). Samotné zhľukovanie sa deje takým spôsobom, že hodnoty SV susedných neurónov sú podobné a naopak hodnoty SV neurónov, ktoré sú od seba viac vzdialené, sú rozdielne. Príčinou je zavedenie funkcie susednosti (viď snímok) kde $h(t)$ je adaptačná výška, d_j je vzdialenosť medzi neurónmi v Kohonenovej vrstve a $r(t)$ predstavuje polomer priestorového susedstva medzi neurónmi v cykle učenia t . Funkcia susednosti spôsobuje, že každá zmena hodnôt SV víťazného neurónu vplyva na zmenu hodnôt SV susedných neurónov. Veľkosť tejto zmeny klesá s rastúcou vzdialenosťou od víťaza.

OCR – Kohonenove mapy

<http://www.heatonresearch.com/articles/42/page1.html>

- Zhukovanie je možné použiť aj na rozpoznávanie objektov, či vzorov, v prípade, že sme vzniknuté zhukky dodatočne označili (labelled clusters)
- Použitie pri rozpoznávaní znakov, určovaní podobnosti obrazov a podobne.

Nezabudnite si spustiť program Kohonen NN.

Otázky?



ĎAKUJEM ZA POZORNOST

