

TECHNICKÁ UNIVERZITA V KOŠICIACH  
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

Mapovanie priestoru pomocou zhlukovania  
obrazov Kohonenovou sieťou

Michal PUHEIM

BAKALÁRSKA PRÁCA

2011



TECHNICKÁ UNIVERZITA V KOŠICIACH  
FAKULTA ELEKTROTECHNIKY A INFORMATIKY  
KATEDRA KYBERNETIKY A UMELEJ INTELIGENCIE

**Mapovanie priestoru pomocou zhlukovania  
obrazov Kohonenovou sieťou**

BAKALÁRSKA PRÁCA

Michal Puheim

Vedúci bakalárskej práce:

Ing. Rudolf Jakša, PhD.

Konzultant bakalárskej práce:

Ing. Rudolf Jakša, PhD.

Košice 2011

## Analytický list

---

Autor:	Michal Puheim
Názov práce:	Mapovanie priestoru pomocou zhlukovania obrazov Kohonenovou sieťou
Jazyk práce:	slovenský, anglický
Typ práce:	Bakalárska práca
Počet strán:	50
Akademický titul:	Bakalár
Univerzita:	Technická univerzita v Košiciach
Fakulta:	Fakulta elektrotechniky a informatiky (FEI)
Katedra:	Katedra kybernetiky a umelej inteligencie (KKUI)
Študijný odbor:	Kybernetika
Študijný program:	Inteligentné systémy
Mesto:	Košice
Vedúci práce:	Ing. Rudolf Jakša, PhD.
Konzultanti práce:	Ing. Rudolf Jakša, PhD.
Dátum odovzdania:	20. 5. 2011
Dátum obhajoby:	16. 6. 2011
Kľúčové slová:	Kohonenova sieť, SOM, zhlukovanie obrazov, Nao
Kategória konspekt:	Výpočtová technika; Umelá inteligencia
Citovanie práce:	Puheim, M.: Mapovanie priestoru pomocou zhlukovania obrazov Kohonenovou sieťou. Diplomová práca. Košice: Technická univerzita v Košiciach, Fakulta elektrotechniky a informatiky, 2011. 50 s.
Názov práce v AJ:	Enviroment mapping by Clustering of Images Using Kohonen Network
Kľúčové slová v AJ:	Kohonen network, SOM, image clustering, Nao

## **Abstrakt v SJ**

Hlavným cieľom tejto bakalárskej práce je návrh systému umožňujúceho mapovať priestor zhľukovaním obrazových dát Kohonenovou neurónovou sieťou. Tento systém zahŕňa dve fázy činnosti. V prvej fáze vytvára mapu priestoru zhľukovaním obrázkov charakteristických pre dané body priestoru, ktorú v druhej fáze využíva pri podpore navigácie v tomto priestore. V tejto fáze prichádzajú na vstup systému nové obrázky, pomocou ktorých systém na základe porovnania s charakteristickými obrázkami v zhľukoch prislúchajúcich bodom na mape určí, v okolí ktorého bodu mapy bol nový obrázok zhotovený. Za účelom ohodnotenia výsledkov systému boli vytvorené ďalšie obrázky, pri ktorých sa zaznamenalo miesto na mape, v okolí ktorého boli zriadené. Porovnaním týchto záznamov s výsledkami systému bolo možné určiť jeho presnosť mapovania. V závere práce sú uvedené niektoré ďalšie možnosti zlepšenia predstaveného systému.

## **Abstrakt v AJ**

The main aim of this bachelor thesis is to design the system that enables environment mapping by clustering of images using Kohonen neural network. This system includes two stages of activity. In the first stage it creates environment map by clustering of images characteristic for given spot in the environment, which is in the second stage used to support the navigation in this environment. In this stage the new pictures are entering the input of the system and by comparing them to the characteristic pictures in clusters corresponding to the spots on the map the system is able to determine the spot on the map in which neighborhood the new picture was taken. In order to evaluate the results of the system there were another pictures created, for which the space on the map, in the neighborhood of which they were taken, was marked. By comparing these records to the outputs of the system it was possible to determine its mapping accuracy. In the conclusion of the thesis there are listed some more possibilities to improve the accuracy of the given system.

TECHNICKÁ UNIVERZITA V KOŠICIACH

Fakulta elektrotechniky a informatiky

Katedra kybernetiky a umelej inteligencie

## ZADANIE BAKALÁRSKEJ PRÁCE

Študijný odbor: 9.2.7 Kybernetika

Študijný program: Inteligentné systémy

Názov práce:

**Mapovanie priestoru pomocou zhľukovania obrazov Kohonenovou sieťou  
Environment Mapping by Clustering of Images Using Kohonen Network**

Študent (tituly, meno, priezvisko): **Michal Puheim**

Školiteľ (tituly, meno, priezvisko):

**Ing. Rudolf Jakša, PhD.**

Školiace pracovisko:

**Katedra kybernetiky a umelej inteligencie**

Konzultant práce (tituly, meno, priezvisko):

Pracovisko konzultanta:

Pokyny na vypracovanie bakalárskej práce:

1. Vypracovať úvod do problematiky zhľukovania a Kohonenových sietí.
2. Navrhnuť systém pre zhľukovanie obrazov pomocou Kohonenových sietí.
3. Implementovať navrhnutý systém.
4. Overiť systém na dátach z robota Nao pre úlohu mapovania priestoru.
5. Vypracovať dokumentáciu podľa pokynov vedúceho práce.

Jazyk, v ktorom sa práca vypracuje:

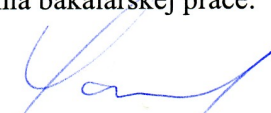
slovenský

Termín pre odovzdanie práce:


20.05.2011

Dátum zadania bakalárskej práce:

31.10.2010

  
prof. Ing. Ján Sarnovský, CSc.  
vedúci garantujúceho pracoviska



  
prof. Ing. Liberios Vokorokos, PhD.  
dekan fakulty

## Čestné vyhlásenie

Vyhlasujem, že som celú bakalársku prácu vypracoval samostatne s použitím uvedenej odbornej literatúry.

Košice, 20. 5. 2011



*vlastnoručný podpis*

## **Pod'akovanie**

Ďakujem môjmu vedúcemu bakalárskej práce Ing. Rudolfovi Jakšovi, PhD. za usmernenie a cenné rady, ktoré mi pomohli pri písaní bakalárskej práce, prof. Ing. Petrovi Sinčákovi, Csc. za jeho angažovanosť pri vytváraní skvelých podmienok práce v Laboratóriu Umelej Inteligencie, ako aj doktorandom Ing. Jaroslavovi Tuhárskemu za množstvo inšpiratívnych podnetov a Ing. Petrovi Smolárovi za pomoc pri práci s robotom Nao. Ďalej by som chcel poďakovať mojej rodine, ktorá ma podporovala nielen počas štúdia na univerzite, ale aj počas celého môjho života.



## Predhovor

K problematike spracovania obrazu som sa dostal už počas projektu v druhom roku štúdia na tejto univerzite, keď sme pracovali v simulačnom prostredí na regulátore robota futbalistu. Veľmi ma zaujala stránka spracovania vizuálnej informácie, najmä spôsob získavania informácií z obrazu. Hoci nebolo veľkým problémom rozpoznávať jednoduché objekty na ihrisku, ako je napríklad lopta alebo bránka, veľké starosti spôsobovala lokalizácia pozície robota na ihrisku. Ambíciou pred výberom témy tejto práce bolo pokúsiť sa tento problém aspoň čiastočne vyriešiť.

Tému som si zároveň vybral pre možnosť dostať sa do kontaktu so skutočným robotom a nie len simulačným programom. Vybraným robotom je Nao od firmy Aldebaran Robotics, ktorý sa v súčasnosti využíva ako štandardná platforma pri súťaži „Robot Soccer World Cup”.

Bakalárska práca sa zaoberá zhľukovaním obrazov v rôznych miestach priestoru pomocou neurónových sietí. Na neurónových sieťach využívajúcich nekontrolované učenie, konkrétne Kohonenovej siete, ma zaujala najmä rýchlosť jej učenia, ktorá bola mnohonásobne vyššia v porovnaní s klasifikačnými sieťami využívajúcimi kontrolované učenie so spätným šírením chyby.

Mojim cieľom v tejto práci bolo využiť tento potenciál neurónových sietí a navrhnúť systém schopný mapovať rôznorodý priestor a podporiť tak robota pri určovaní jeho polohy.

# Obsah

<b>Zoznam obrázkov.....</b>	<b>10</b>
<b>Zoznam tabuliek.....</b>	<b>12</b>
<b>Zoznam symbolov a skratiek.....</b>	<b>13</b>
<b>Úvod.....</b>	<b>14</b>
<b>1 Formulácia úlohy.....</b>	<b>16</b>
<b>2 Zhlukovanie pomocou neurónových sietí.....</b>	<b>17</b>
2.1 Všeobecná charakteristika neurónových sietí.....	17
2.2 Učenie neurónových sietí.....	19
2.2.1 Konkurenčné učenie a zhluková analýza.....	20
2.2.2 Kohonenove siete.....	22
<b>3 Zhlukovanie obrazových údajov.....</b>	<b>24</b>
3.1 Reprezentácia farby – RGB model.....	24
3.2 Definícia pojmu obraz použitá pri práci.....	25
3.3 Princíp zhlukovania obrazov.....	26
<b>4 Úvod do komunikácie s robotom Nao.....</b>	<b>27</b>
4.1 Základné charakteristiky robota Nao.....	27
4.2 Programové príslušenstvo robota – Choreographe.....	27
4.3 Možnosti získania spätnej väzby od robota – Telepathe.....	28
<b>5 Návrh a implementácia systému pre mapovanie priestoru zhlukovaním obrazov     Kohonenovou sieťou.....</b>	<b>30</b>
5.1 Návrh topológie Kohonenovej vrstvy ako mapy priestoru.....	30
5.2 Návrh systému a jeho realizácia.....	33
5.2.1 Príprava a predspracovanie vstupných obrázkov.....	34
5.2.2 Vizualizácia hodnôt synaptických váh.....	35
5.2.3 Inicializácia váh neurónov na výstupnej vrstve siete.....	37
5.2.4 Návrh a testovanie algoritmu zhlukovania.....	38
5.2.5 Spôsob vyhodnotenia výsledkov mapovania systému.....	41
<b>6 Overenie činnosti navrhnutého systému.....</b>	<b>42</b>
6.1 Príprava pokusnej zostavy.....	42
6.2 Popis pokusov.....	43
6.2.1 Výsledky pokusov pri rôznom počte cyklov učenia.....	43

6.2.2	Výsledky pokusov pri rôznej veľkosti mapy.....	44
6.2.3	Výsledky pokusov pri rôznych parametroch učenia.....	45
<b>7</b>	<b>Záver.....</b>	<b>47</b>
	<b>Zoznam použitej literatúry.....</b>	<b>49</b>
	<b>Prílohy.....</b>	<b>50</b>

## Zoznam obrázkov

Obr. 1: Štruktúra neurónu. Prevzaté zo SINČÁK [1].....	17
Obr. 2: Štruktúra doprednej NS. Prevzaté zo SINČÁK [1].....	19
Obr. 3: Zmena váh smerujúcich k víťaznému neurónu. Prevzaté zo SINČÁK [1].....	21
Obr. 4: Kohonenova NS s 3 vstupmi a 16 výstupmi usporiadanými do mriežky 4x4....	22
Obr. 5: Možný tvar funkcie susednosti $\Delta_{ij}$ na dvojrozmernej výstupnej mriežke.....	23
Obr. 6: Aditívne miešanie farieb v RGB modeli.....	24
Obr. 7: Model RGB mapovaný do kocky.....	24
Obr. 8: Reprezentácia obrazu v jednorozmernom vektore.....	25
Obr. 9: Vstupom NS sú RGB hodnoty z obrazového vektora. Prevzaté z KOVÁČ [5].	26
Obr. 10: Robot Nao.....	27
Obr. 11: Prostredie programu Choreographe.....	28
Obr. 12: Plugin Camera Viewer aplikácie Telepathe.....	29
Obr. 13: Reprezentácia mapy priestoru vo forme mriežky.....	30
Obr. 14: Rozšírenie dvojrozmernej mapy o tretí rozmer určujúci rádius otočenia.....	31
Obr. 15: Možné spôsoby prepojenia neurónov na výstupnej vrstve.....	32
Obr. 16: Zobrazenie plnej konektivity medzi neurónmi na výstupnej vrstve.....	32
Obr. 17: Bloková schéma zobrazujúca algoritmus činnosti systému.....	33
Obr. 18: Princíp vizualizácie hodnôt SV ich projekciou do obrazovej mapy. Prevzaté z KOVÁČ [5].....	35
Obr. 19: Vizualizácia váh neurónovej siete počas učenia.....	36
Obr. 20: Redukcia dimenzie pri zobrazení viacrozmernej mapy.....	36
Obr. 21: Vizualizácia váh neurónovej siete po náhodnej inicializácii.....	37
Obr. 22: Vizualizácia váh po inicializácii náhodným rozložením vstupných dát.....	37
Obr. 23: Vizualizácia váh po manuálnej inicializácii.....	38
Obr. 24: Testovanie funkčnosti algoritmu na jednoduchej úlohe s dvoma vstupmi.....	39
Obr. 25: Deformácia farieb pri parametre $\gamma$ vyššom ako 1.....	40

---

Obr. 26: Praktická realizácia mapy v pokusnom priestore.....	42
Obr. 27: Schéma rozloženia uzlov mapy s príslušnými smerovými neurónmi.....	42
Obr. 28: Uhlomer použitý pri otáčaní robota.....	43
Obr. 29: Vizualizácia SV v jednom uzle v troch smeroch pred a po 5 cykloch učenia. .	44
Obr. 30: Vizualizácia SV v jednom uzle v troch smeroch pred a po 5 cykloch učenia po zmene parametrov.....	46

---

## Zoznam tabuliek

Tab. 1: Parametre učenia.....	40
Tab. 2: Porovnanie pokusov pre rôzne počty cyklov učenia pre mapu s 36 smermi.....	44
Tab. 3: Porovnanie pokusov pre rôzne počty cyklov učenia pre mapu s 18 smermi.....	45
Tab. 4: Porovnanie pokusov pri zmene parametrov učenia.....	46

## Zoznam symbolov a skratiek

FF NS	dopredná neurónová sieť
LMS	metóda najmensej kvadratickej chyby (least mean square)
NS	neurónová sieť
RC NS	rekurentná neurónová sieť
RGB	farebný model využívajúci farby červená, zelená a modrá (red, green, blue)
SOM	samo-organizujúca sa mapa (self organizing map)
SV	synaptické váhy
URBI	Universal Robot Behavior Interface – špecializované vývojové prostredie určené pre robotické aplikácie
WTA	metóda zmeny synaptických váh „vít'az berie všetko” (winner takes all)

---

## Úvod

Téma mapovania prostredia a vo všeobecnosti aj téma spracovania obrazu je v súčasnosti veľmi aktuálna, keďže aj napriek veľkému pokroku v tejto oblasti stále nepoznáme systém, ktorý by bol schopný dostatočne efektívne rozpoznávať rôznorodé objekty alebo prostredie, v ktorom sa nachádza. Preto je stále namieste snaha nachádzať nové riešenia týchto problémov.

Cieľom tejto práce je vytvoriť systém, ktorý v prvej fáze (v procese učenia) vytvorí na základe obrázkov z kamery robota mapu priestoru, pomocou ktorej sa dokáže neskôr orientovať. V druhej fáze budú do systému vstupovať nové obrázky z kamery a systém na základe porovnania týchto obrázkov s obrázkami charakterizujúcimi vytvorené miesta na mape určí približnú pozíciu, v okolí ktorej bol nový obrázok zhotovený. Systém takto umožní podporu robota pri určovaní svojej polohy.

Väčšina konvenčných metód mapovania prostredia sa opiera o segmentáciu obrazu, napríklad pomocou vyhľadávania hrán. Tieto metódy majú problémy s informačným šumom, ktorý často sprevádza vizuálne dáta. Neurónové siete majú výhodu v tom, že sú dostatočne robustné a schopné tento šum potlačiť.

V našom prípade je plánom využiť na účely mapovania výhody Kohonenovej neurónovej siete, kde vstupom budú obrazové dáta a výstupná vrstva bude v špeciálnom tvare umožňujúcom modelovať mapu prostredia.

Prvá kapitola práce obsahuje zoznam cieľov práce, tak ako je uvedené v zadaní práce, ako aj stanovenie ďalších podcieľov vyplývajúcich zo zadania alebo potrebných pre dokončenie práce.

V druhej kapitole je zhrnutá teória potrebná pre prácu s neurónovými sieťami a nevyhnutné poznatky nutné k pochopeniu základných princípov zhľukovania objektov pomocou Kohonenových sietí.

Tretia kapitola sa venuje úvodu do spracovania obrazových údajov, kde sa definuje pojem obraz, ako je použitý v ďalšej práci. Priestor je venovaný aj riešeniu problému prechodu od zhľukovania jednoduchých dát k zhľukovania obrazov.



---

Štvrtá kapitola sa venuje oboznámeniu s robotom Nao, ako aj úvodu k možnostiam komunikácie s týmto robotom. Posledná podkapitola tejto časti popisuje možnosti získavania obrazových dát z kamier tohto robota.

Návrhu a implementácii systému pre mapovanie priestoru je venovaný priestor v piatej kapitole. Obzvlášť dôležitá je v tejto časti prvá podkapitola, ktorá sa venuje vytvoreniu modelu mapy priestoru pomocou Kohonenovej siete. Druhá podkapitola popisuje jednotlivé súčasti systému a spôsob jeho fungovania.

V šiestej kapitole sú popísané podmienky, v ktorých boli realizované pokusy pri overovaní schopností systému pri riešení úlohy mapovania priestoru, ako aj porovnania výsledkov týchto pokusov.

V závere je obsiahnuté overenie splnenia cieľov práce, ďalej sú zhrnuté výsledky pokusov, ako aj naznačené ďalšie možnosti vývoja systému v budúcnosti.

## 1 Formulácia úlohy

Hlavným cieľom bakalárskej práce je navrhnúť systém mapovania priestoru zhlukovaním obrázkov Kohonenovou neurónovou sieťou. Medzi ďalšie ciele práce, ako je popísané v zadaní práce, patrí:

1. Vypracovať úvod do problematiky zhlukovania Kohonenových sietí.
2. Navrhnúť systém pre zhlukovanie obrazov pomocou Kohonenových sietí.
3. Implementovať navrhnutý systém.
4. Overiť systém na dátach z robota Nao pre úlohu mapovania priestoru.
5. Vypracovať dokumentáciu podľa pokynov vedúceho práce.

Z týchto cieľov automaticky vyplývajú ďalšie podúlohy, ktoré je vhodné a potrebné vyriešiť.

Pred oboznámením sa s Kohonenovými sieťami je potrebné vypracovať aspoň stručný všeobecný úvod do teórie neurónových sietí, ktorý čitateľa dostane do obrazu a poskytne mu základné poznatky potrebné pre pochopenie ďalších kapitol.

Keďže navrhujeme systém pracujúci s obrazom, je potrebné zhrnúť základné teoretické poznatky o podstate obrazu a spôsobe práce s obrazom. Zároveň je potrebné vysvetliť, čo je podstatou zhlukovania obrazu.

Z dôvodu práce s dátami z robota Nao je namieste uviesť charakteristiku tohto robota, ako aj popis softvérového príslušenstva umožňujúceho komunikáciu s robotom a získavanie senzorických dát.

Hoci to nie je nevyhnutné, pri realizácii a testovaní neurónovej siete je dôležité umožniť kontrolu procesu učenia. Z tohto dôvodu je veľmi vhodné do návrhu systému zahrnúť subsystém umožňujúci vizualizáciu učenia siete.

## 2 Zhlukovanie pomocou neurónových sietí


Umelé neurónové siete (NS) sa v súčasnosti stávajú uznávaným spôsobom riešenia širokého spektra problémov, ako sú napríklad problémy aproximácie funkcií, klasifikácie do tried, asociačné problémy, simulácia pamäte, transformácia signálov a mnohé iné. Zatiaľ čo na jednej strane je pri implementácii NS zaujímavá jej biologická podstata, na strane druhej je robustnou alternatívou ku konvenčným deterministickým a programovateľným metódam.<sup>[1][2]</sup>

NS je možné veľmi úspešne využívať aj pri zhľukovaní objektov. Zhľukovanie je vo všeobecnosti definované ako logický postup zabezpečujúci zlučovanie podobných objektov do skupín. Zhľuk teda reprezentuje skupinu objektov, ktoré majú podobné črty alebo charakteristiky, inak povedané príznaky. Zhľukovanie sa potom realizuje na základe týchto príznakov.<sup>[3]</sup>

Nasledujúce podkapitoly obsahujú poznatky prevažne prevzaté zo SINČÁK [1].

### 2.1 Všeobecná charakteristika neurónových sietí

Neurónová sieť je masívne paralelný procesor, ktorý má sklon k uchovávaní znalostí a ich ďalšiemu využívaniu. Veľkou výhodou je jej schopnosť aproximácie ľubovoľnej funkcie pomocou vzoriek vstupných a výstupných dát bez ohľadu na znalosť matematického modelu problému.<sup>[1]</sup>



Obr. 1: Štruktúra neurónu. Prevzaté zo SINČÁK [1].

Základnou procesnou jednotkou NS je tzv. umelý neurón, zobrazený na Obr. 1, ktorý sa skladá z nasledujúcich častí:<sup>[1][4]</sup>


- **Synaptické váhy (SV)** – ich hodnoty sú nositeľkami znalostí NS. SV sú naviazané na spojenia medzi neurónmi (synapsie), ktoré majú presne určený smer toku signálu. Podľa toku tohto signálu vieme neuróny rozdeliť na:
  - Predsynaptické (zdrojové),
  - Postsynaptické (cieľové).
- **Prah neurónu** – hodnota  $\Theta_i$ , ktorá prispieva ku vstupu z vonkajšieho sveta.
- **Vstup do neurónu (dendrit)** – vstupnou funkciou je obvykle súčet prahovej hodnoty a sumy súčinov výstupov z predchádzajúcich neurónov a príslušných váh.

$$in_i = \sum_{j=1}^N w_{ij} out_j + \Theta_i \quad (1)$$

- **Aktivačná funkcia** –  $f(in_i)$ , ktorej výsledkom je aktivačná hodnota neurónu  $x_i$ . Najčastejšie sa používa funkcia signum, ďalej sigmoidálna alebo lineárna (resp. po častiach lineárna) funkcia.
- **Výstupná funkcia** –  $out(x_i)$ , ktorá určuje výstupnú hodnotu neurónu. Zvyčajne sa používa funkcia identity.

Neuróny sa v NS skladajú do zložitejších štruktúr, ktoré majú určenú svoju topológiu. Vo všeobecnosti môže mať NS ľubovoľnú štruktúru popísateľnú orientovaným grafom, avšak vlastnosti takejto siete sa ťažko analyzujú a preto sú najčastejšie využívané siete s pravidelnými štruktúrami. Jednou z najpoužívanějších topológií je viacvrstvová štruktúra s jednou vstupnou, jednou výstupnou a jednou alebo viacerými skrytými vrstvami. Vo všeobecnosti rozdeľujeme topológie NS do dvoch základných skupín:<sup>[1]</sup>

- **Dopredné NS (feed-forward FF NS)** – kde sa signál šíri po synaptických prepojeniach len jedným smerom, a to dopredu.
- **Rekurentné NS (recurrent RC NS)** – pripúšťajú šírenie signálu oboma smermi a rozdelenie neurónov na vrstvy je tým pádom často nejednoznačné.



Obr. 2: Štruktúra doprednej NS. Prevzaté zo SINČÁK [1].

V ďalšej časti práce sa obmedzíme na využitie NS dopredného charakteru.

## 2.2 Učenie neurónových sietí

Činnosť NS je možné rozdeliť do dvoch fáz:<sup>[1][4]</sup>

- **Fáza učenia** (adaptácie) – počas ktorej sa do hodnôt váh NS ukladajú znalosti. Je to teda stav NS, kedy sa SV menia.
- **Fáza života** – počas ktorej sa poznatky získané v procese učenia využijú v prospech riešenia nejakého problému (napr. klasifikácia, optimalizácia, zhlukovanie a pod.). V tejto fáze sa už SV nemenia.

Učenie je proces, v ktorom sa synaptické váhy (SV) menia na základe nejakých pravidiel. Pravidlá vyvolávajúce zmeny SV sú podmienené typom učenia NS. Pod učením rozumieme adaptáciu NS, ktorá po ukončení učenia bude nositeľkou znalostí získaných počas učenia.<sup>[1]</sup>

Učenie rozdelíme do dvoch hlavných skupín:<sup>[1]</sup>

- **Kontrolované učenie** – učenie s učiteľom (supervised learning), kde pre dané vstupné dáta sú určené odpovedajúce výstupné dáta. Výsledky NS pri procese učenia je teda možné s týmito dátami porovnávať.
- **Nekontrolované učenie** – učenie bez učiteľa (unsupervised learning), kde pre dané vstupné dáta nie sú určené odpovedajúce výstupy. Pri tomto type učenia teda nie je možné kontrolovať výstup z NS.

### 2.2.1 Konkurenčné učenie a zhluková analýza

Pri nekontrolovanom učení ide o spracovanie vstupu do NS na základe určitých zákonitostí. NS môžeme počas takéhoto učenia ponúknuť iba vstupné dáta, ktoré sieť sama spracuje a určí výstup. Z tohto dôvodu sa takéto NS zvyknú označovať aj ako samo-organizujúce sa siete (self-organizing network) alebo samo-organizujúce sa mapy (self-organizing map – SOM). Otázka ukončenia učenia v tomto type siete spočíva v nájdení jej globálnej stability, čo znamená, že NS sa prestane učiť, ak zmena SV v čase  $t$  a v čase  $t + 1$  bude dostatočne malá.<sup>[1]</sup>

Konkurenčné učenie je proces, pri ktorom sa hodnoty SV na výstupných neurónoch formujú do pozície zodpovedajúcej centráм zhlukov. Výstupná vrstva sa formuje iba na základe vstupných dát, čo zodpovedá nekontrolovanému učeniu. Topológia NS pre konkurenčné učenie je dvojvrstvová, kde na vstupnej vrstve sa nachádza  $M$  neurónov a na výstupnej  $N$  neurónov. Pri prezentovaní vstupného vektora  $x$  je aktivovaný iba jediný z neurónov výstupnej vrstvy (vítaz) a následkom toho dochádza ku konkurenčnému chovaniu neurónov. Tento proces je možné zhrnúť do nasledujúcich bodov:<sup>[1][5]</sup>


- Výstupné neuróny majú ako aktivačnú funkciu použitú funkciu identity

$$out_i(t) = \sum_{j=1}^M w_{ij}(t) x_j(t) \quad (2)$$

- Následne vyberieme neurón s maximálnou hodnotou  $ou_i(t)$  (pre  $i = 1, 2, \dots, N$ ) a urobíme operáciu

$$out_i(t) = \begin{cases} 1 & out_i = \max \{ out_i, \forall i = 1, 2, \dots, N \} \\ 0 & \text{inak} \end{cases} \quad (3)$$

teda neurón s maximálnou hodnotou bude nastavený na 1 a ostatné budú nastavené na 0. Tento prístup je aspektom konkurenčného správania a konkrétna metóda sa nazýva „vítaz berie všetko“ (winner takes all – WTA), vid' Obr. 3.



Obr. 3: Zmena váh smerujúcich k víťaznému neurónu. Prevzaté zo SINČÁK [1].

- V ďalšom kroku prebehne zmena synaptických váh, ktoré smerujú do víťazného neurónu. Odvodenie adaptačného pravidla pre zmeny SV je analogické ako pri kontrolovanom učení a LMS prístupe. Cieľom je, aby sa hodnoty jednotlivých prvkov vstupného vektora  $x$  premietli do hodnôt synaptických váh, teda aby podobné vstupy mali podobné víťazné neuróny a naopak, aby odlišné vstupy mali rozdielne víťazné neuróny. Chybové funkcie odpovedajú rozdielu synaptických váh k  $i$ -tému víťaznému neurónu a hodnoty vstupného neurónu.

$$J(t) = 0.5 \sum_{j=1}^M (w_{ij}(t) - x_j(t))^2 \quad (4)$$

Minimalizáciou tohto rozdielu dochádza k premietnutiu vstupov do hodnôt synaptických váh. Ak si označíme učiaci pomer ako  $\gamma$ , potom samotné odvodenie zmeny SV bude vyzeráť nasledovne:

$$\Delta w_{ij} = -\gamma \frac{\partial J(t)}{\partial w_{ij}(t)} \quad (5)$$

Pre všetky neuróny rôzne od víťazného neurónu je zmena váh nulová. Pre víťazný neurón  $i$  dostávame po upravení derivácie vzťah:

$$w_{ij}(t+1) = w_{ij}(t) + \gamma (x_j(t) - w_{ij}(t)) \quad (6)$$

- Problémom ostáva inicializácia váh. Zvyčajne sa to rieši tak, že sa vyberie určitý počet náhodných vektorov  $x$  zo vstupnej vzorky a tieto sa použijú ako štartovacie hodnoty SV.
- Vzhľadom na to, že vlastne chceme hľadať rozdiel medzi vstupným vektorom a hodnotami SV, tak môžeme ako aktivačnú funkciu výstupných neurónov použiť aj Euklidovu vzdialenosť medzi jednotlivými vektormi, teda pre  $i$ -tý výstupný neurón to bude hodnota:

$$out_i(t) = \sqrt{\sum_{j=1}^M (w_{ij}(t) - x_j(t))^2} \quad (7)$$

Tento spôsob aktivácie ale mení vzťah (3) do tvaru:


$$out_i(t) = \begin{cases} 1 & out_i = \min\{out_i, \forall i = 1, 2, \dots, N\} \\ 0 & \text{inak} \end{cases} \quad (8)$$

Uvedený prístup má výhodu voči predošlému v tom, že nie je požadovaná normalizácia a odpadávajú možné problémy s vektormi rovnakých smerov.

### 2.2.2 Kohonenove siete

Kohonenove siete [6] predstavujú veľmi dôležité rozšírenie konkurenčného učenia, ktoré spočíva v dvoch hlavných zmenách:<sup>[1]</sup>

- Prvá zmena spočíva v tom, že neuróny na výstupnej vrstve NS sú usporiadané do nejakého geometrického tvaru, ktorý značne závisí od konkrétnej aplikácie. Najčastejšie je používaná dvojrozmerná mriežka v tvare obdĺžnika, kde sú neuróny vo vrstve umiestnené vedľa seba, a teda existuje možnosť určenia suseda. Túto vrstvu nazývame Kohonenovou vrstvou.



Obr. 4: Kohonenova NS s 3 vstupmi a 16 výstupmi usporiadanými do mriežky 4x4.




- Ďalším rozšírením je pripustenie princípu viacerých víťazov (multiply WTA). Samotné zhlukovanie sa deje takým spôsobom, že hodnoty SV susedných neurónov sú podobné a naopak hodnoty SV neurónov, ktoré sú od seba viac vzdialené, sú rozdielne. Príčinou je zavedenie funkcie susednosti  $\Lambda_{ij}$  v tvare:

$$\Lambda_{ij} = h(t) \cdot e^{-\frac{(d_j)^2}{r_i(t)}} \quad (9)$$

kde  $h(t)$  je adaptačná výška,  $d_j$  je vzdialenosť medzi neurónmi v Kohonenovej vrstve a  $r(t)$  predstavuje polomer priestorového susedstva medzi neurónmi v cykle učenia  $t$ . Funkcia susednosti spôsobuje, že každá zmena hodnôt SV víťazného neurónu vplýva na zmenu hodnôt SV susedných neurónov. Veľkosť tejto zmeny klesá s rastúcou vzdialenosťou od víťaza.

Na Obr. 5 vidíme možný tvar funkcie susednosti  $\Lambda_{ij}$  na dvojrozmernej výstupnej mriežke, kde súradnice víťazného ( $i$ -teho) neurónu sú  $X_i = 3$  a  $Y_i = 3$ . Z obrázku vyplýva, že hodnota  $\Lambda_{ij}$  sa pre ( $j$ -ty) neurón (so súradnicami  $X_j, Y_j$ ) s rastúcou vzdialenosťou od víťazného ( $i$ -teho) neurónu znižuje.



Obr. 5: Možný tvar funkcie susednosti  $\Lambda_{ij}$  na dvojrozmernej výstupnej mriežke.

V prípade použitia funkcie susednosti sa vzťah (6) určený na výpočet novej hodnoty SV pretransformuje do tvaru:


$$w_{ij}(t+1) = w_{ij}(t) + \gamma \Lambda_{ij}(x_j(t) - w_{ij}(t)) \quad (10)$$

### 3 Zhlukovanie obrazových údajov

Pred začatím práce s vizuálnymi údajmi a prechodom k zhlukovaniu obrazov je potrebné zdefinovať, čo je podstatou obrazu, z čoho sa skladá a ako je možné s ním pracovať. Nasledujúce podkapitoly obsahujú poznatky z prác KUNDRÁT [4], KOVÁČ [5], ako aj praktické skúsenosti v oblasti práce s obrazom z projektu [7].


#### 3.1 Reprezentácia farby – RGB model

Medzi najznámejšie a aj najpoužívannejšie spôsoby kódovania farby patrí tzv. RGB model. Tento model používa aditívny spôsob miešania farieb využívaný vo väčšine moderných obrazoviek. Názov modelu je odvodený od troch základných farieb, ktorých odtiene sa pri vyžarovaní sčítavajú a vytvárajú tak celé farebné spektrum. Jedná sa o červenú, zelenú a modrú farbu (red, green, blue – RGB).<sup>[4]</sup>



Obr. 6: Aditívne miešanie farieb v RGB modeli.

V praxi sa používa rozdelenie každej farby podľa intenzity na 256 odtieňov od 0 až po 255, čo je 8 bitov alebo 1 bajt. Čím je táto hodnota väčšia, tým je farba danej zložky jasnejšia. Takto je možné vytvoriť vyše 16 a pol milióna rôznych farieb.




Obr. 7: Model RGB mapovaný do kocky.

Každá farba je teda presne definovaná hodnotami svojich troch zložiek. Ich hodnota môže kolísať medzi minimom (tmavá farba) až maximom (plná intenzita). Pokiaľ sú hodnoty všetkých zložiek farby na minime, výsledná farba odpovedá čiernej a ak sú na maxime, výsledok odpovedá bielej.<sup>[4]</sup>

### 3.2 Definícia pojmu obraz použitá pri práci

Dvojmerný digitálny obraz je tvorený množstvom malých obrazových bodov, pixlov. Pixel je najmenší obrazový element v digitálnej rastrovej grafike a je v tvare malého štvorcového bodu. Tieto body v obraze vytvárajú štvorcovú sieť, ktorej veľkosť definuje rozlíšenie obrazu. Každý pixel možno jednoznačne identifikovať podľa jeho súradníc v sieti.

Obraz je teda možné definovať ako dvojmerný vektor pixlov, kde každý pixel má určenú svoju pozíciu a farbu. Pre účely spracovania obrazu je však jednoduchšie a výhodnejšie tento dvojmerný vektor zobraziť ako jednorozmerný a to tak, že všetky riadky uložíme za sebou do jedného sledu. Teda celý obraz bude uložený ako jednorozmerný vektor pixelov, kde pre každý pixel pripadajú tri farebné zložky – červená (R), zelená (G) a modrá (B).<sup>[7]</sup>



Obr. 8: Reprezentácia obrazu v jednorozmernom vektore.


Keďže RGB komponenty môžu nadobúdať hodnoty od 0 do 255, je výhodné tieto trojice normovať, čo čiastočne odstráni napríklad aj nepriaznivé dôsledky rozdielneho osvetlenia. Vyberie sa zložka s najväčšou hodnotou a ňou sa predelia hodnoty všetkých troch farebných zložiek. Získame tak trojice hodnôt medzi 0 a 1, ktorých vektor potom môžeme výhodne použiť na vstupe neurónovej siete. Taktiež je možné hodnoty normovať ich predelením farebným rozsahom, čo je v našom prípade 256.<sup>[7]</sup>

### 3.3 Princíp zhlukovania obrazov

Pri zhlukovaní obrazov Kohonenovou NS sú vstupom siete hodnoty farebných zložiek pixlov obrazového vektora. Ak  $x$  je šírka obrazu a  $y$  jeho výška, potom celkový počet vstupných neurónov  $M$  vieme určiť na základe vzťahu:<sup>[7]</sup>

$$M = 3 \cdot x \cdot y \quad (11)$$

Počas procesu učenia NS sa v každej iterácii dajú na vstup siete postupne jeden za druhým všetky obrázky. NS sa ich v priebehu učenia pokúsi mapovať do hodnôt SV na výstupných neurónoch, kde adaptáciou SV postupne vzniknú tzv. modely zhlukov.



Obr. 9: Vstupom NS sú RGB hodnoty z obrazového vektora. Prevzaté z KOVÁČ [5].

Na NS je možné pozerat' sa ako na dynamický systém. Aj preto prípad, v ktorom na vstup NS dávame v každom cykle učenia obrázky stále v rovnakom poradí, môže mať za následok vznik cyklických oscilácií, ktoré môžu negatívne ovplyvniť výsledok učenia. V prípade Kohonenovej NS to môže znamenať napríklad neschopnosť siete vytvárať nové zhluky. Preto je v priebehu učenia vhodné v každej iterácii meniť poradie obrázkov na vstupe NS.

## 4 Úvod do komunikácie s robotom Nao

Zdrojom experimentálnych dát potrebných pre vypracovanie tejto práce bol robot Nao a nasledujúce pasáže sa venujú predstaveniu robota samotného, ako aj príslušného programového vybavenia.

### 4.1 Základné charakteristiky robota Nao

Nao je humanoidný robot vyvíjaný francúzskou spoločnosťou Aldebaran Robotics. Množstvo kĺbových prepojení vo verzii „Academic edition” zaručuje až 25 stupňov voľnosti pohybu. Všetky verzie obsahujú sonarové a infračervené senzory, nárazové senzory, dotykový senzor a vnútornú senzorickú jednotku zahŕňajúcu gyroskop a akcelerometer. Súčasťou výbavy sú samozrejme aj dve kamery.<sup>[8]</sup>



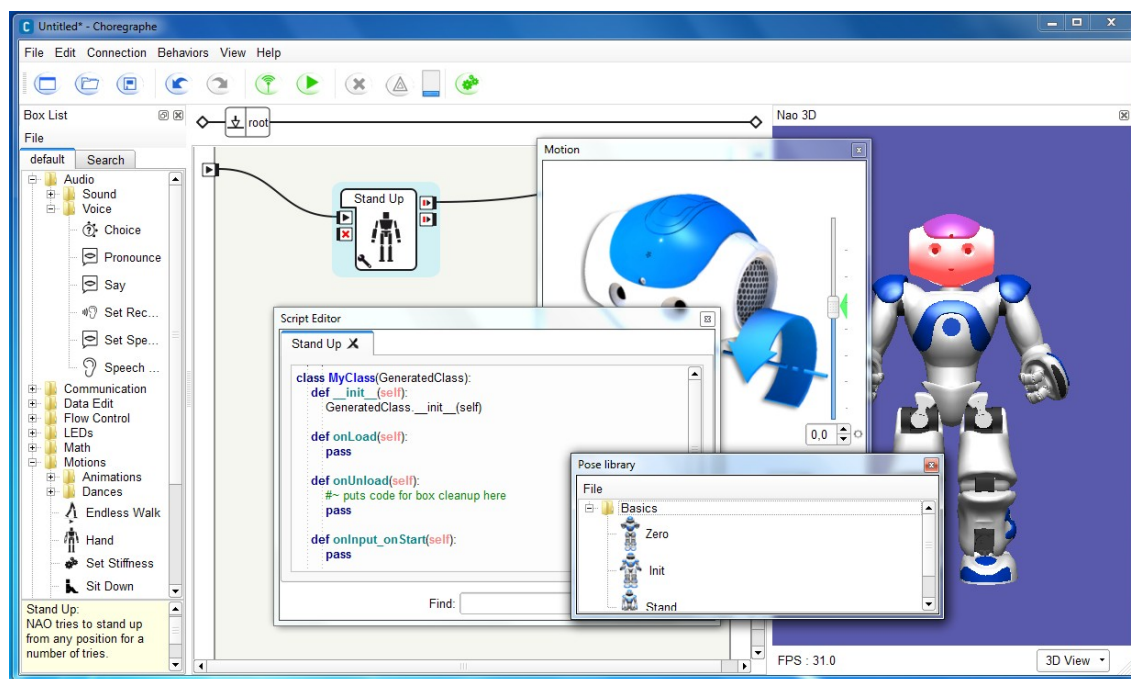
Obr. 10: Robot Nao.

Ako operačný systém je použitý Linux založený na OpenEmbedded distribúcii. Systém v súčasnosti využíva 500 MHz procesor GEODE od AMD, 256 MB RAM pamäte a 2 GB USB flash disk ako dlhodobú pamäť. Na pripojenie do siete je možné použiť vstavané Ethernetové pripojenie alebo bezdrôtové Wi-fi pripojenie (IEEE 802.11g).<sup>[8]</sup>

### 4.2 Programové príslušenstvo robota – Choreographie

Choreographie je vývojové prostredie dodávané k robotovi, založené na vizuálnom programovaní, umožňujúce vytvárať a editovať pohyby, ako aj celkové správanie

robotu. Pri programovaní v Choreographe je možné používať skriptovacie jazyky URBI a Python, pomocou ktorých je následne možné volať moduly napísané v ďalších jazykoch (C/C++, Java, DotNet, Matlab atď).<sup>[8]</sup>



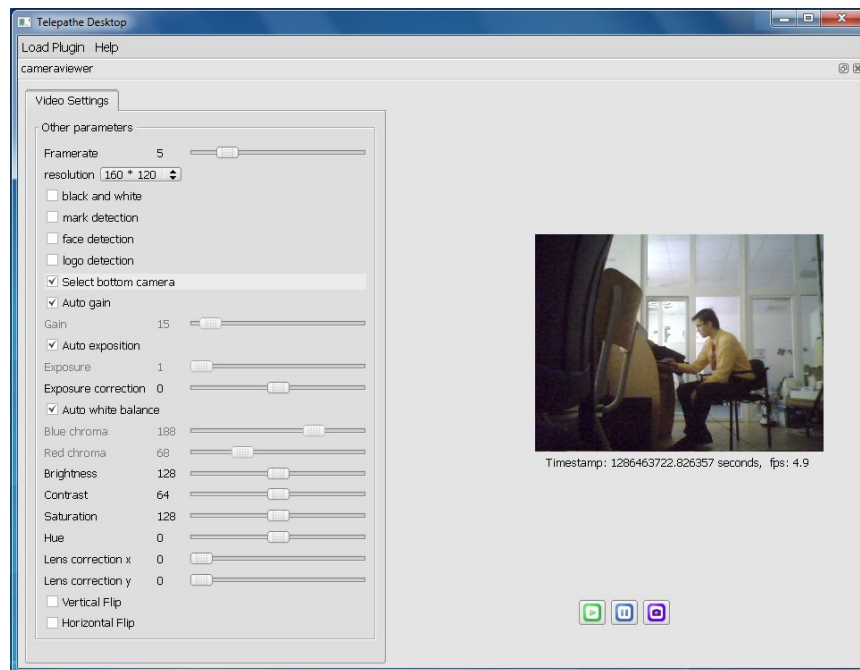
Obr. 11: Prostredie programu Choregraphe.

Prostredníctvom programu je možné priamo ovládať jednotlivé klby robota, ako aj zobrazíť informácie zo senzorov. Program je navyše kompatibilný s robotickými simulátormi, ako je napríklad Robotics Studio od Microsoft-tu alebo Webots od firmy Cyberbotics.<sup>[8]</sup>

### 4.3 Možnosti získania spätnej väzby od robota – Telepathe

Telepathe je modulárna desktopová aplikácia, ktorá umožňuje získať spätnú väzbu z robota, ako aj zasielať mu základné príkazy. Ponúka upraviteľné prostredie so schopnosťou načítať viaceré pluginy, pričom medzi dva základné patria Memory Viewer a Camera Viewer.<sup>[8]</sup>

Memory Viewer umožňuje napríklad monitorovať v reálnom čase počas činnosti robota hodnoty premenných v jednotlivých moduloch pamäte. Camera Viewer zase poskytuje vizuálnu spätnú väzbu, teda umožňuje zobrazíť to, čo robot vidí. Taktiež je možné priamo upravovať niektoré nastavenia kamery, napríklad kontrast alebo jas.<sup>[8]</sup>



Obr. 12: Plugin Camera Viewer aplikácie Telepathe.

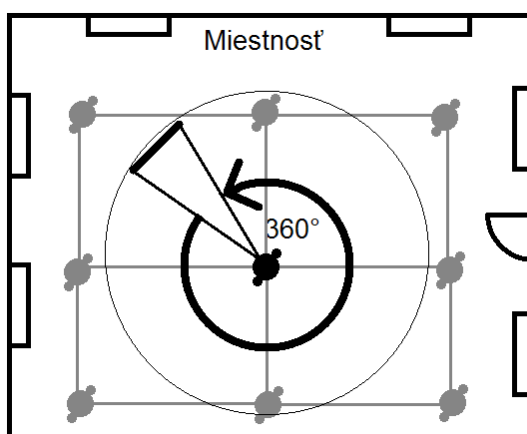
Hoci je zrejmé, že Telepathe je možné použiť ako veľmi silný nástroj pre debugging, zároveň je pomocou neho možné do pamäte robota ukladať video alebo fotografie, ktoré sa následne dajú stiahnuť do počítača pomocou FTP klienta, ako je napríklad WinSCP. V našom prípade to bol hlavný zdroj dát pre ďalšie experimenty.

## 5 Návrh a implementácia systému pre mapovanie priestoru zhlukovaním obrazov Kohonenovou sieťou

Po naštudovaní teoretických podkladov zhrnutých v kapitolách 2 a 3 bolo cieľom vytvoriť systém umožňujúci zhlukovať obrázky do mapy priestoru. Na tento účel je využitá Kohonenova NS, kde vstupom je vektor pixelov obrázku a výstupná vrstva je v tvare špeciálnej trojrozsomernej matice, pri ktorej návrhu bolo ambíciou vytvoriť mapu vo forme modelu priestoru implementovateľného do hodnôt SV.

### 5.1 Návrh topológie Kohonenovej vrstvy ako mapy priestoru

Predstava mapy priestoru bola spoiatku vo forme dvojrozsomernej mriežky, kde pre každý uzol mriežky boli presne určené súradnice. Každý uzol by reprezentoval konkrétne miesto v priestore. Každému uzlu by zároveň prislúchal charakteristický obrázok reprezentujúci dané miesto priestoru. Tento obrázok by bol uložený v hodnotách SV neurónu na výstupnej vrstve NS reprezentujúceho daný uzol priestoru. Charakteristický obrázok by vznikol zhlukovaním obrázkov získaných z kamery robota v blízkom okolí danej časti priestoru, tj. daného uzla mapy. Na základe takto vytvorenej mapy by sa robot mohol v budúcnosti navigovať a porovnaním charakteristického obrázku a záberu z kamery určiť, v blízkosti akého uzla mapy sa nachádza.




Obr. 13: Reprezentácia mapy priestoru vo forme mriežky.

Takmer okamžite ale vyšlo najavo, že mapovanie obrázkov z trojrozsomného priestoru na dvojrozsomnú mriežku neprináša požadované výsledky. Dvojrozsomná



mriežka postačovala iba v prípade, keď sa robot pri pohybe neotáčal. Kým pri pohľade z jedného smeru boli obrázky v okolí daného bodu mapy veľmi podobné, pri otočení robota o  $180^\circ$  boli úplne iné. Na základe tohto sme dospeli k záveru, že je potrebné do mapy doplniť ďalší rozmer určujúci smer otočenia.




Obr. 14: Rozšírenie dvojrozsmernej mapy o tretí rozmer určujúci rádius otočenia.

Kým pri dvojrozsmernej mriežke bol uzol priestoru reprezentovaný práve jedným neurónom na výstupnej vrstve, po pridaní ďalšieho rozmeru pripadá jednému uzlu celá skupina neurónov, kde každý jeden neurón určuje daný smer otočenia. V ďalších častiach práce budeme preto uzol mapy chápať ako konkrétne miesto v priestore, zatiaľ čo neuróny spadajúce pod tento uzol budú reprezentovať smer otočenia pohľadu kamery robota v danom mieste priestoru.


K Obr. 14 je dôležité poznamenať, že jednotlivé hrany spájajúce neuróny (čierne kruhy) tu nereprezentujú spôsob prepojenia neurónov na výstupnej vrstve NS, ale iba symbolicky zobrazujú ich príslušnosť k uzlu mapy (modré body). Spôsob prepojenia neurónov je zobrazený na Obr. 15. Naznačuje dve možné spôsoby prepojenia neurónov:

- **Prepojenia v uzloch** – kde sú prepojené tie neuróny toho istého uzla, ktoré majú susedné smery otočenia. Takto prepojené neuróny v uzle vytvárajú pomyselnú kružnicu s centrom v tomto uzle. Na Obr. 15 je tento druh prepojenia zobrazený čiernou farbou.
- **Prepojenia v rovnakých smeroch** – kde sú prepojené neuróny reprezentujúce rovnaký smer otočenia, ale sú umiestnené v dvoch rôznych susediacich uzloch. Na Obr. 15 je tento druh prepojenia zobrazený červenou farbou.



Obr. 15: Možné spôsoby prepojenia neurónov na výstupnej vrstve.

Treba si uvedomiť, že Obr. 15 je neúplný a zobrazuje prepojenie len v jednom smere. Vo výstupnej vrstve na reálnej sieti sú ale prepojené všetky neuróny rovnakých smerov. Tento prípad plnej konektivity zobrazuje Obr. 16:



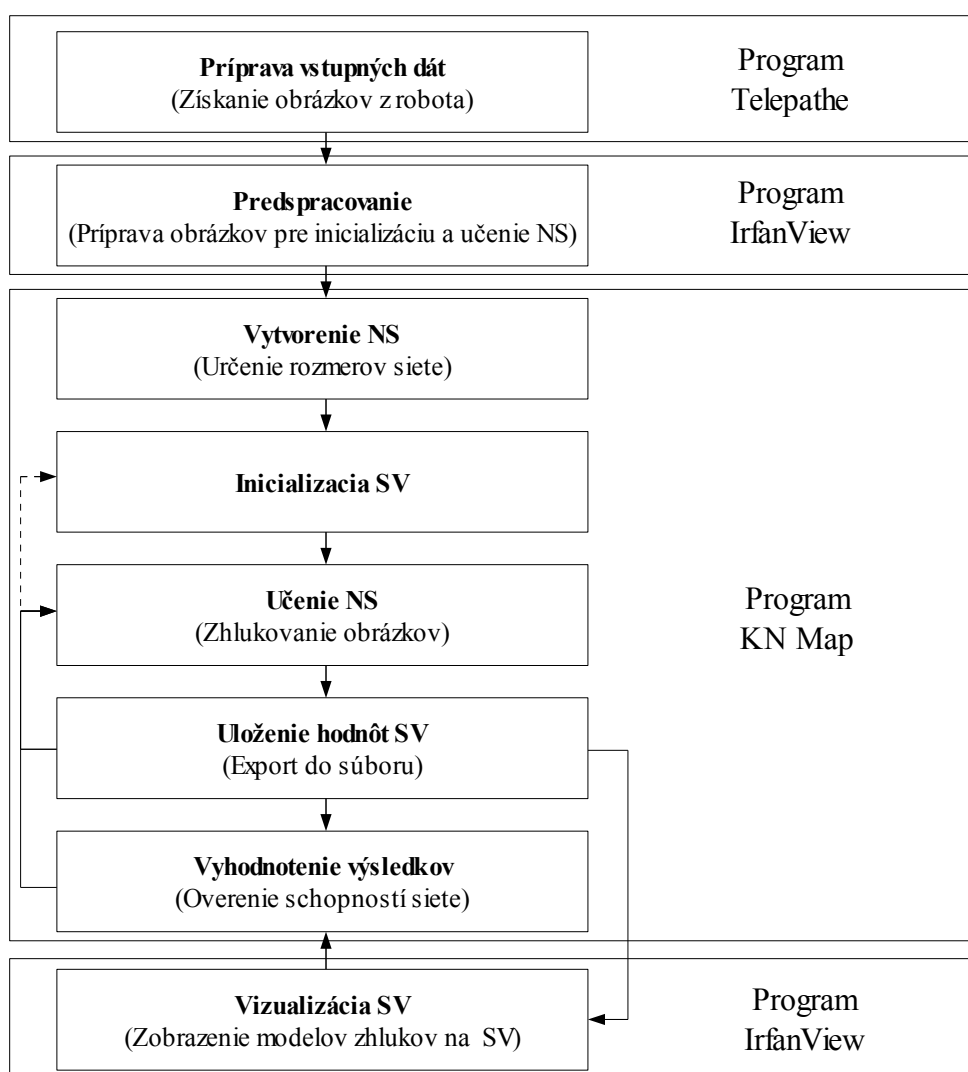
Obr. 16: Zobrazenie plnej konektivity medzi neurónmi na výstupnej vrstve.

Obrázok zároveň jasne a zrozumiteľne demonštruje trojrozmernosť navrhnutej výstupnej vrstvy. Prvé dva rozmery určujú formu základnej mriežky, ktorá definuje počet a rozloženie uzlov mapy priestoru. Cyklický tretí rozmer zase definuje smer otočenia v danom uzle mapy.

Topológia v tejto podobe bola použitá pri finálnych experimentoch. Oproti pôvodnému návrhu vo forme dvojrozsmernej mriežky, kde robot mapoval pomocou súradníc iba svoju pozíciu, je pridanou hodnotou NS v takejto podobe navyše aj schopnosť určiť smer, ktorým sa robot pozerá.

## 5.2 Návrh systému a jeho realizácia

Systém je navrhnutý za účelom overenia jeho možností pri mapovaní priestoru. Keďže systém pracuje s veľkým objemom údajov, dôraz bol kladený hlavne na jeho rýchlosť a aj preto je napísaný ako konzolová aplikácia v jazyku C. Samotný program mapovania priestoru (KN Map) neobsahuje žiadne grafické prvky, keďže ani neboli nevyhnutné. Získanie obrazových údajov zabezpečuje aplikácia Telepathe a prípadnú potrebu vizualizácie obrázkov a modelov zhlukov na SV sieti zabezpečuje program IrfanView. Navyiac, v prípade implementácie tohto systému na reálnom robotovi, nebudú dokonca ani tieto podporné programy potrebné.



Obr. 17: Bloková schéma zobrazujúca algoritmus činnosti systému.

---

Spusteniu samotného programu pre mapovanie predchádza získanie obrázkov z robota a ich prevedenie do formátu vhodného k spracovaniu pomocou NS. Následne je možné tieto obrázky spracovať v sieti, čím vznikne mapa priestoru, v ktorom boli vytvorené. Túto mapu je potom možné vyskúšať na ďalších obrázkoch z daného priestoru a overiť tak úspešnosť mapovania. Spôsob realizácie systému a algoritmus jeho fungovania je zobrazený v blokovej schéme na Obr. 17. Nasledujúce podkapitoly sa jeho činnostiam budú venovať podrobnejšie.

### 5.2.1 Príprava a predspracovanie vstupných obrázkov

Zmyslom tohto procesu je zabezpečenie množiny obrázkov vo formáte vhodnom pre vstup do NS. Medzi ďalšie podmienky patrí rovnaká veľkosť všetkých obrázkov a ich načítanie pri nemennom nastavení parametrov kamery. Veľmi dôležité sú aj svetelné podmienky, keďže obrázky za jasného dňa a pri izbovom osvetlení majú rozdielne charakteristiky, čo môže mať zlý vplyv na proces zhukovania. Celkovo predpokladom fungovania systému sú nemenné podmienky v priestore, pre ktorý sa vytvára mapa.

Zdrojom nových obrázkov je aplikácia Telepathe, pomocou ktorej je možné uložiť snímky z kamery do pamäte robota a následne ich pomocou ftp klienta (napr. WinSCP) stiahnuť na disk počítača so systémom.

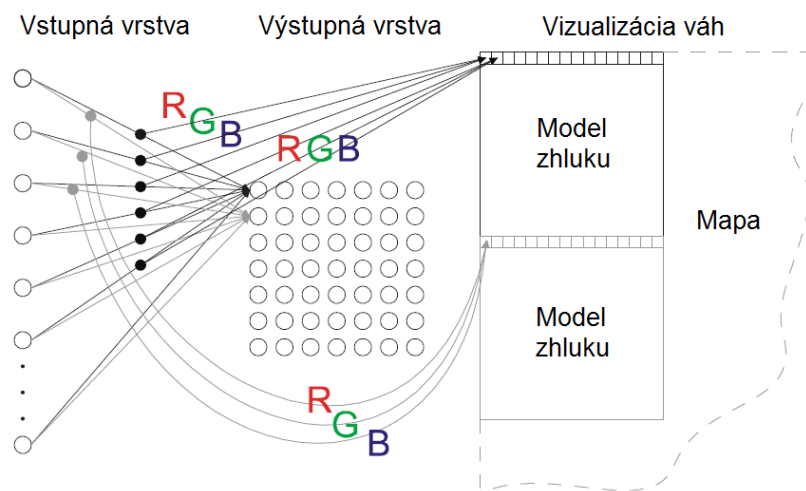
Za zmienku stojí fakt, že obrázky v Telepathe je možné robiť v troch možných rozlíšeniach – 160x120, 320x240 a 640x480. Problémom ale je, že v každom prípade sa uložia ako obrázok s rozlíšením 640x480, a to aj pri použití nižšieho rozlíšenia, hoci v horšej kvalite. Ťažko povedať, či je to zámerné alebo sa jedná o chybu programu, ale v každom prípade, takéto rozlíšenie je pre účely spracovania NS priveľké (spolu sa jedná o 307 200 pixlov na obrázok, pričom každý pixel má tri farebné zložky). Obrázky je preto vhodné zmenšiť.

Obrázky je následne možné pomocou programu IrfanView skonvertovať do formátu .ppm v textovom režime, s ktorým sa následne v NS veľmi jednoducho pracuje. Program IrfanView poskytuje na takéto účely veľmi účinné prostriedky vo forme hromadného spracovania viacerých súborov naraz v jednej dávke. Súčasne je

v priebehu konverzie možné zmenšiť rozlíšenie a taktiež hromadne zmeniť názvy súborov podľa vopred zadanej masky.

### 5.2.2 Vizualizácia hodnôt synaptických váh


Princípom fungovania Kohonenovej NS je premietnutie hodnôt jednotlivých vstupov do hodnôt synaptických váh. V priebehu procesu učenia je možné hodnoty váh vizualizovať a zobrazíť tak modely obrázkov charakteristických pre jednotlivé zhľuky, čo umožňuje lepšiu kontrolu nad priebehom učenia a v počiatočných fázach implementácie NS značne pomáha pri hľadaní vhodných parametrov učenia.<sup>[5]</sup>



Obr. 18: Princíp vizualizácie hodnôt SV ich projekciou do obrazovej mapy.


Prevzaté z KOVÁČ [5].

Možnosť využitia tejto metódy pri kontrole stavu SV počas adaptácie NS je prezentovaná na Obr. 19. Obrázok zobrazuje zmenu stavu SV na výstupnej vrstve siete počas troch cyklov učenia.



Obr. 19: Vizualizácia váh neurónovej siete počas učenia.

Uvedený prístup je výborný pre dvojrozmerné výstupné vrstvy v tvare mriežky. V prípade použitia viacrozmernej mapy, ako je to v našom prípade, však týmto spôsobom nie je možné zobraziť váhy všetkých neurónov. Riešením je redukcia dimenzie výstupnej vrstvy tak, že sa zobrazia len váhy na neurónoch rovnakého smeru.



Obr. 20: Redukcia dimenzie pri zobrazení viacrozmernej mapy.


Takýmto spôsobom je potom možné postupne zobraziť váhy vo všetkých smeroch. Výsledkom bude  $n$ -tica dvojrozmerných máp modelov zhlukov na výstupnej vrstve. Tieto  $n$ -tice je už možné jednoducho analyzovať.

---

### 5.2.3 Inicializácia váh neurónov na výstupnej vrstve siete


Kohonenova NS je veľmi závislá na počiatočných hodnotách SV na výstupnej vrstve. V navrhnutom systéme boli vytvorené tri možné typy inicializácie SV:

- **Náhodná inicializácia** – kde sa hodnoty SV nastavujú na náhodnú hodnotu v intervale  $<0,1>$ . Výsledkom je biely šum s rovnomerným rozdelením po celej oblasti mapy. Tento typ inicializácie je výhodný v tom, že nie je potrebná znalosť vstupných dát. Navyše jeho implementácia je veľmi jednoduchá.



Obr. 21: Vizualizácia váh neurónovej siete po náhodnej inicializácii.


- **Inicializácia s náhodným rozložením vstupných dát** – základom je inicializácia bielym šumom, nad ktorým sa navyše náhodne vyberú obrázky zo vstupnej množiny a ich príslušnými hodnotami sa inicializujú váhy smerujúce do časti neurónov výstupnej vrstvy.



Obr. 22: Vizualizácia váh po inicializácii náhodným rozložením vstupných dát.



- **Manuálne určená inicializácia** – v prípade využitia tohto typu inicializácie sa kombinujú výhody manuálnej tvorby mapy priestoru a výhod Kohonenovej NS. Pri jej vzniku bola potreba aktívneho zásahu do tvorby mapy priestoru. Základom je opäť biely šum, nad ktorý sa aplikujú inicializačné obrázky. Miesto na mape, určené pre aplikáciu konkrétneho inicializačného obrázku, je určené názvom jeho súboru. Obr. 23 zobrazuje inicializáciu tohto typu na trojrozsmernej mape s rozmerom 3x2 a 36 smermi pohľadu pre prvých šesť rôznych smerov.



Obr. 23: Vizualizácia váh po manuálnej inicializácii.

#### 5.2.4 Návrh a testovanie algoritmu zhukovania

Učenie je v programe implementované štandardným spôsobom, ktorý bol prezentovaný v kapitolách 2.2.1 a 2.2.2, pričom ako aktivačná funkcia neurónov je použitý vzťah (7). Neuróny na výstupnej vrstve boli usporiadané do formy dvojrozsmernej matice (mriežky) s rozmermi určenými podľa potreby.

Pre určenie vzdialenosti  $j$ -teho neurónu od víťazného neurónu na výstupnej mriežke bola použitá euklidovská vzdialenosť. Ak  $x_j$  a  $y_j$  sú súradnice  $j$ -teho neurónu a  $x_{vit}$  a  $y_{vit}$  sú súradnice víťazného neurónu, potom vzťah pre výpočet ich vzdialenosti  $d_j$  vyzerá nasledovne:

$$d_j = \sqrt{(x_j - x_{vit})^2 + (y_j - y_{vit})^2} \quad (12)$$

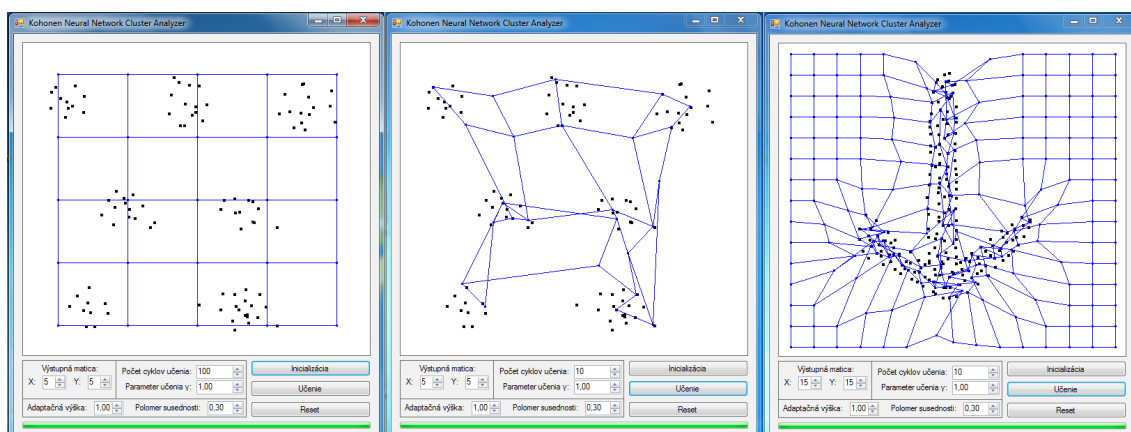
Z dôvodu snahy o optimalizáciu rýchlosti učenia boli vzťahy (12) a (9) mierne upravené, aby sa predišlo zbytočnému odmocňovaniu a následnému opätovnému umocňovaniu parametra  $d_j$ .

$$d_j = (x_j - x_{vit})^2 + (y_j - y_{vit})^2 \quad (13)$$



$$\Lambda_{ij} = h(t) \cdot e^{\frac{d_j}{r_i(t)}} \quad (14)$$

Spočiatku bola pre účely overenia funkčnosti algoritmu vyskúšaná sieť s dvoma vstupmi, čo boli v tomto prípade súradnice bodu zadaného užívateľom. Sieti sa postupne dali na vstup všetky body a hodnoty SV na výstupnej vrstve sa postupne adaptovali smerom k centráм zhlukov. Výsledky týchto pokusných experimentov možno vidieť na Obr. 24.




Obr. 24: Testovanie funkčnosti algoritmu na jednoduchej úlohe s dvoma vstupmi.

Po overení funkčnosti algoritmu bol rozšírený počet vstupov pre účely zhlukovania obrázkov. V tejto fáze bola použitá dvojrozmerná výstupná vrstva v tvare mriežky, kde bolo hlavným cieľom nájsť vhodné parametre pre zhlukovanie. Pri týchto pokusoch vyplynulo zopár zaujímavých poznatkov. Ak si vzťah (10) rozšírimo využitím vzťahu (14), dostaneme rovnicu určujúcu zmenu SV v tvare:

$$w_{ij}(t+1) = w_{ij}(t) + \gamma \cdot h(t) \cdot e^{\frac{d_j}{r_i(t)}} (x_j(t) - w_{ij}(t)) \quad (15)$$

Z tejto rovnice vyplýva, že učiaci parameter  $\gamma$  a adaptačná výška  $h(t)$  majú rovnaký vplyv na zmenu váh, čo znamená, že pri hľadaní vhodného nastavenia stačí meniť iba jeden z týchto parametrov. Parameter  $h(t)$  bol preto nastavený permanentne na hodnotu 1 a ďalej bol upravovaný iba učiaci parameter  $\gamma$ .

Zároveň vyšlo najavo, že pri nastavení parametra  $\gamma$  nad hodnotu 1 dochádzalo k deformácii farieb modelov zhlukov na výstupnej výstupnej vrstve, pretože jednotlivé farebné zložky sa adaptovali na hodnoty vyššie ako maximum farebného rozsahu (v tomto prípade 255).



Obr. 25: Deformácia farieb pri parametre  $\gamma$  vyššom ako 1.

Po niekoľkých testoch boli určené hodnoty základných troch parametrov vhodné pre adaptáciu SV siete v ďalších pokusoch. Hodnoty týchto parametrov sú zobrazené v tabuľke Tab 1.:

Parameter	Hodnota
$\gamma$	0,3
$h(t)$	1
$r_i(t)$	1,5

Tab. 1: Parametre učenia

Pri rozšírení dvojrozmernej mriežky o ďalší rozmer určujúci smer pohľadu, bolo potrebné upraviť vzťah pre výpočet vzdialenosti od víťazného neurónu (13). Pri tejto úprave je dôležité reflektovať fakt, že sa jedná o cyklický rozmer. Napríklad, ak je veľkosť tohto rozmeru 9, tak najkratšia vzdialenosť medzi prvým a ôsmym prvkom nie je 7, ale 2. So zreteľom na tieto okolnosti môžeme určiť nový vzťah pre výpočet vzdialenosti.

Ak  $x_j$ ,  $y_j$  a  $s_j$  sú súradnice  $j$ -teho neurónu a  $x_{vit}$ ,  $y_{vit}$  a  $s_{vit}$  sú súradnice víťazného neurónu, pričom veľkosť rozmeru určujúceho smer je  $s_{max}$ , potom vzdialenosť  $d_j$  je určená nasledovne:

$$d_j = (x_j - x_{vit})^2 + (y_j - y_{vit})^2 + (\min(|s_j - s_{vit}|, s_{max} - |s_j - s_{vit}|))^2 \quad (16)$$

### 5.2.5 Spôsob vyhodnotenia výsledkov mapovania systému

Po ukončení učenia je možné pristúpiť k overeniu jej schopností NS zaraďovať nové obrázky do správnych zhlukov. Na tento účel je potrebná množina testovacích obrázkov, kde pre každý obrázok máme určené, v okolí akého uzla priestoru a s akým smerom natočenia bol vytvorený. Sieť následne zaraďí tieto obrázky do zhlukov na výstupnej vrstve. Porovnaním vzdialeností súradníc zhlukov a súradníc týchto obrázkov je možné určiť presnosť mapovania. Na tento účel môže byť využitý napríklad vzťah:

$$D(o, z) = \sqrt{(x_o - x_z)^2 + (y_o - y_z)^2 + (\min(|s_o - s_z|; s_{max} - |s_o - s_z|)/4)^2} \quad (17)$$


Kde  $x_o$ ,  $y_o$  a  $s_o$  sú súradnice testovaného obrázka a  $x_z$ ,  $y_z$  a  $s_z$  sú súradnice príslušného zhliku, pričom veľkosť rozmeru určujúceho smer je  $s_{max}$ . Vo vzťahu sme znížili váhu presného určenia smeru na štvrtinu, keďže chyba smerovania o pár stupňov nie je taká podstatná, ako chyba polohy.

## 6 Overenie činnosti navrhnutého systému

Po dokončení systému sme pokročili k otestovaniu jeho schopností pri úlohe mapovania priestoru. Ďalšia časť práce je preto venovaná popisu pokusov vykonaných na navrhnutom systéme.


### 6.1 Príprava pokusnej zostavy

Pred uskutočnením samotných pokusov bolo potrebné pripraviť sadu obrázkov z pokusného priestoru. V laboratóriu bola na tento účel vyčlenená časť miestnosti.



Obr. 26: Praktická realizácia mapy v pokusnom priestore.


V miestnosti boli vytvorené uzlové body v tvare matice s rozmerom 3x2, pričom rovnaká topológia bola použitá aj na výstupnej vrstve NS. (Poznámka k Obr. 27: Počet neurónov určujúcich smer je na obrázku len demonštratívny. Pri reálnych pokusoch bol ich počet stanovený na 18, prípadne 36.)



Obr. 27: Schéma rozloženia uzlov mapy s príslušnými smerovými neurónmi.

V každom uzle pokusného priestoru boli následne vytvorené obrázky z jeho okolia. Obrázky boli snímané počas otáčania robota v danom uzle každých 10°.

Celkovo tak v každom uzle vzniklo až 36 referenčných obrázkov pre rôzne smery otočenia. Tieto obrázky boli následne použité pri inicializácii a učení NS.



Obr. 28: Uhlomer použitý pri otáčaní robota.

Naviac bolo vytvorených 10 testovacích obrázkov, ktoré neboli umiestnené presne v daných uzloch priestoru. Ich pozícia bola stanovená v približnom okolí uzlov, pričom pre každý obrázok boli zaznamenané súradnice najbližšieho uzla a daný smer otočenia. Tieto obrázky boli použité pri hodnotení výsledkov mapovania.

## 6.2 Popis pokusov

Pre účely ohodnotenia schopností siete sme vykonali celkovo 9 pokusov s rozdielnymi veľkosťami siete, s rozličným počtom cyklov učenia, ako aj s rôznymi parametrami učenia. V priebehu tohto procesu sme sa snažili nastaviť všetky atribúty siete na také hodnoty, ktoré by vykazovali najlepšie výsledky.


### 6.2.1 Výsledky pokusov pri rôznom počte cyklov učenia

Pri prvom pokuse sme zisťovali vplyv dĺžky učenia na výsledky mapovania. Ukázalo sa, že sieť má problém po adaptácii zlepšiť svoje schopnosti mapovania oproti základnej inicializácii. S rastúcim počtom cyklov učenia sa chyba mapovania nežiadúco zvyšovala. Parametre experimentov a ich výsledky zobrazuje tabuľka Tab. 2:

Počet trénovacích obrázkov	197	197	197
veľkosť obrázkov	160x120	160x120	160x120
rozmery mapy	3x2x36	3x2x36	3x2x36
inicializácia	manuálna	manuálna	manuálna
<b>počet cyklov učenia</b>	<b>5</b>	<b>1</b>	<b>0</b>
parameter učenia	0,3	0,3	0,3
adaptačná výška	1	1	1
polomer susednosti	1,5	1,5	1,5
trvanie učenia	01:03:28	00:12:63	00:00:00
počet testovacích obrázkov	10	10	10
priemerná chyba na obrázok	1,21	1,07	1,02

Tab. 2: Porovnanie pokusov pre rôzne počty cyklov učenia pre mapu s 36 smermi.

Na Obr. 29 je zobrazená vizualizácia hodnôt SV na začiatku učenia a následne po piatich cykloch učenia. Zobrazenie je realizované z jedného uzla mapy pre tri rôzne smery otočenia.



Obr. 29: Vizualizácia SV v jednom uzle v troch smeroch pred a po 5 cykloch učenia

### 6.2.2 Výsledky pokusov pri rôznej veľkosti mapy

V ďalšom pokuse sme skúsili znížiť počet neurónov na výstupnej vrstve znížením počtu možných smerov z 36 na 18. Snahou bolo, aby sa do jednotlivých zhlukov mapovalo viac obrázkov, čo by mohlo zmeniť výsledky zhlukovania. Kým pri predchádzajúcom pokuse bolo na 216 zhlukov dostupných iba 197 obrázkov,

pri ďalšom sa počet zhlukov znížil na 108 pri zachovaní rovnakej množiny trénovacích obrázkov.

Počet trénovacích obrázkov	197	197	197
veľkosť obrázkov	160x120	160x120	160x120
<b>rozmery mapy</b>	<b>3x2x18</b>	<b>3x2x18</b>	<b>3x2x18</b>
inicializácia	manuálna	manuálna	manuálna
<b>počet cyklov učenia</b>	<b>5</b>	<b>1</b>	<b>0</b>
parameter učenia	0,3	0,3	0,3
adaptačná výška	1	1	1
polomer susednosti	1,5	1,5	1,5
trvanie učenia	0:33:07	0:06:43	0:00:00
počet testovacích obrázkov	10	10	10
priemerná chyba na obrázok	1,58	1,03	0,81

Tab. 3: Porovnanie pokusov pre rôzne počty cyklov učenia pre mapu s 18 smermi.

Z výsledkov je zrejmé, že zmena nepomohla k lepším výsledkom. Hoci by sa pri pohľade na priemernú hodnotu chyby mohlo zdať, že pri pokuse so sieťou bez učenia je mapovanie lepšie ako v predchádzajúcom pokuse, ide iba o klamný dojem, keďže sieť s menším rozmerom je sama o sebe menej presná.


### 6.2.3 Výsledky pokusov pri rôznych parametroch učenia

V ďalších pokusoch sme sa pokúsili overiť vplyv zmeny parametrov učenia na výsledky mapovania sieťou. Pri pohľade na Obr. 29 vidieť, že modely zhlukov po určitom počte cyklov učenia vykazujú stratu textúry a prílišné rozmazanie obsahu. Pokúsili sme sa preto zvýšiť parameter učenia  $\gamma$  a znížiť polomer susednosti  $r_i(t)$  v snahe dosiahnuť lepšiu výraznosť modelov zhlukov. Výsledky týchto pokusov ukazuje tabuľka Tab. 4:

Počet trénovacích obrázkov	197	197	197
veľkosť obrázkov	160x120	160x120	160x120
rozmery mapy	3x2x36	3x2x36	3x2x36
inicializácia	manuálna	manuálna	manuálna
počet cyklov učenia	2	2	5
<b>parameter učenia</b>	<b>0,6</b>	<b>0,8</b>	<b>0,8</b>
adaptačná výška	1	1	1
<b>polomer susednosti</b>	<b>1</b>	<b>0,5</b>	<b>0,5</b>
trvanie učenia	00:25:32	00:25:31	01:03:45
počet testovacích obrázkov	10	10	10
priemerná chyba na obrázok	1,17	1,22	1,14

Tab. 4: Porovnanie pokusov pri zmene parametrov učenia

Sieť pri poslednom pokuse s parametrom učenia o hodnote 0,8 vykazovala mierne zlepšenie výsledkov mapovania oproti predchádzajúcim pokusom, keď sa chyba ani po piatich cykloch učenia ďalej nezvyšovala. Modely zhlukov si zároveň uchovali dostatočnú informáciu o textúre. Na Obr. 30 je zobrazený stav SV v jednom uzle siete v troch smeroch:



Obr. 30: Vizualizácia SV v jednom uzle v troch smeroch pred a po 5 cykloch učenia po zmene parametrov



## 7 Záver

Hlavným cieľom tejto práce bolo vytvoriť systém, ktorý by dokázal zmapovať priestor zhlukovaním obrazov Kohonenovou sieťou. Tento systém mal byť schopný vytvoriť mapu priestoru a následne na základe obrázkov vstupujúcich do systému určovať súradnice pozície a rádius otočenia na mape. Možno konštatovať, že tento cieľ sa podarilo naplniť. Bol vytvorený variabilný systém s rôznymi možnosťami nastavenia, ako je napríklad veľkosť mapy priestoru, rozmer vstupných obrázkov, parametre a dĺžka trvania učenia siete a spôsoby inicializácie siete. Zároveň obsahuje veľmi užitočnú možnosť vizualizácie učenia, pomocou ktorej je ho možné veľmi prehľadne kontrolovať. Systém je možné ďalej jednoducho upravovať a vylepšovať.

Prvý bod zadania, s cieľom vypracovať úvod do problematiky zhlukovania Kohonenových sietí, bol splnený v kapitole 2, najmä v časti 2.2. Teoretické poznatky z oblasti zhlukovania obrazov, potrebné pri práci s týmito sieťami, sú uvedené v kapitole 3. Druhý a tretí bod práce zahŕňajúci návrh a implementáciu systému je splnený v kapitole 5. Na presný popis podstaty mapovania pomocou Kohonenovej vrstvy v navrhnutom systéme bol kladený dôraz najmä v časti 5.1, zatiaľ čo časť 5.2 podrobne popisuje jednotlivé prvky systému. Štvrtý bod, s cieľom overiť schopnosti systému pri mapovaní priestoru, bol splnený v časti 6, ktorá popisuje a porovnáva dosiahnuté výsledky experimentov.

Napriek tomu, že všetky body práce boli splnené, aj naďalej ostáva veľa možností na zlepšenie. Výsledky experimentov potvrdili, že chyba mapovania je stále veľmi veľká pre praktické nasadenie. Každý testovací obrázok bol do mapy v priemere zaradený o jednu pozíciu vedľa miesta, ktoré bolo očakávané. Problémy mohol spôsobovať charakter miestnosti, kde boli experimenty realizované, keďže prakticky na jednej tretine zorného poľa bola biela stena, ktorej zábery nie sú veľmi vhodné pre procedúru zhlukovania. Na obhajobu predstaveného systému však možno povedať, že ani bežný človek by z takých obrázkov nevedel usúdiť veľa. Aj preto by bolo zaujímavé otestovať systém v rôznorodejšom prostredí, kde by procedúra zhlukovania určite dosiahla lepšie výsledky. Zároveň, hoci bolo vytvorených takmer 200 rozličných obrázkov, bolo zrejmé, že systém trpel nedostatkom vstupných dát. Na účely

---

automatizácie získavania nových obrázkov by bolo vhodné vytvoriť nový samostatný modul integrovaný na robotovi.

Do budúcnosti by bolo najlepšie pokúsiť sa realizovať celý systém na robotovi, pričom jeho činnosť by bola rozdelená na fázu mapovania, počas ktorej by robot systematicky prechádzal a mapoval celý priestor a na fázu života, pri ktorej by sa robot riadil na základe informácií z fázy mapovania. Problémom by v tomto prípade mohla byť kapacita pamäte robota, čo by sa dalo čiastočne riešiť ďalším zmenšením rozmeru vstupných obrázkov, alebo nejakou formou predspracovania, ktoré by mohlo zároveň zlepšiť výsledky zhukovania. Možné je tiež rozdelenie mapovacej siete na viacero rôznych podsietí s adaptívnym načítaním jednotlivých častí podľa aktuálnej pozície.

---

## Zoznam použitej literatúry

- [1] SINČÁK P., ANDREJKOVÁ G.: *Neurónové siete – Inžiniersky prístup (Dopredné neurónové siete)*, č. 1. Košice: Elfapress, ISBN 80-88786-38-X, (1996). Dostupný na internete:  
<<https://luix-ai.fei.tuke.sk/student/TZUI?action=AttachFile&do=view&target=neuronky1.pdf>>
- [2] SINČÁK P., ANDREJKOVÁ G.: *Neurónové siete – Inžiniersky prístup (Rekurentné a modulárne neurónové siete)*, č. 2. Košice: Elfapress, ISBN 80-88786-42-8, (1996). Dostupný na internete:  
<<https://luix-ai.fei.tuke.sk/student/TZUI?action=AttachFile&do=view&target=neuronky2.pdf>>
- [3] KRIŠKA J.: *Hierarchická a nehierarchická zhuková analýza* [online]. Bratislava: STU-FIIT-UISI. [citované 2011-05-01]. Dostupný na internete:  
<[http://www2.fiit.stuba.sk/~kapustik/ZS/Clanky0607/kriskal/index.html#\\_Toc150627224](http://www2.fiit.stuba.sk/~kapustik/ZS/Clanky0607/kriskal/index.html#_Toc150627224)>
- [4] KUNDRÁT J.: *Zhlukovanie vizuálnej informácie z robota AIBO pomocou Kohonenovej neurónovej siete*. Bakalárska práca. Košice: TUKE-FEI-KKUI, 2009. 49 s. Dostupný na internete:  
<<http://neuron.tuke.sk/jaksa/theses/2009/Kundrat-Uzak-Jaksa-Bc09-thesis.pdf>>
- [5] KOVÁČ J.: *Vyhľadávanie v obrazovej databáze s využitím samoorganizujúcich sa máp a multiscale reprezentácie*. Diplomová práca. Košice: TUKE-FEI-KKUI, 2007. 61 s. Dostupný na internete:  
<<http://neuron.tuke.sk/jaksa/theses/2007/Kovac-Jaksa-MSc07-thesis.pdf>>
- [6] KOHONEN, T.: *Self-organizing maps*. Springer, Berlin, Heidelberg, New York, 1995, 1997, 2001. 501s. ISBN 3-540-67921 9.
- [7] BUGAN A., FODOROVÁ D., PUHEIM M., SABOL T., SZABÓOVÁ V.: *Robotic Football Team TUKE*. Košice: TUKE-FEI-KKUI, 2010. Dostupný na internete:  
<<http://masteron.ic.cz/subory/RFT%20TUKE%20Zaverecna%20sprava.pdf>>
- [8] ALDEBARAN ROBOTICS: *NAO User Guide*. [online]. Version 1.10.37. [citované 2011-05-01]. Dostupný na internete:  
<[http://users.aldebaran-robotics.com/docs/site\\_en/index\\_doc.html](http://users.aldebaran-robotics.com/docs/site_en/index_doc.html)>

## **Prílohy**

Príloha A: CD médium – bakalárska práca v elektronickej podobe, prílohy  
v elektronickej podobe, program KN Map, obrázky použité pri pokusoch

Príloha B: Používateľská príručka

Príloha C: Systémová príručka

Príloha D: Zdrojový kód programu