

TECHNICKÁ UNIVERZITA V KOŠICIACH
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

**VYUŽITIE FUZZY KOGNITÍVNYCH MÁP V SITUAČNOM
RIADENÍ A MODELOVANÍ ZLOŽITÝCH SYSTÉMOV**

Písomná práca k dizertačnej skúške

2015

Ing. Michal Puheim

TECHNICKÁ UNIVERZITA V KOŠICIACH
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

**VYUŽITIE FUZZY KOGNITÍVNYCH MÁP V SITUAČNOM
RIADENÍ A MODELOVANÍ ZLOŽITÝCH SYSTÉMOV**

Písomná práca k dizertačnej skúške

Študijný program:	Umelá inteligencia
Študijný odbor:	9.2.8 umelá inteligencia
Školiace pracovisko:	Katedra kybernetiky a umelej inteligencie (KKUI)
Školiteľ:	Dr. h. c. mult. prof. Ing. Ladislav Madarász, PhD.
Školiteľ špecialista:	Dr. Ing. Ján Vaščák

2015 Košice

Ing. Michal Puheim

Abstrakt v SJ

Predmetom predloženej písomnej práce k doktorandskej dizertačnej skúške je prehľad rôznych metód, postupov a prostriedkov využiteľných pri riadení a modelovaní zložitých systémov. Prvá časť práce sa zaoberá najmä metodikou situačného riadenia zložitých systémov s využitím prostriedkov umelej inteligencie. Druhá časť práce je orientovaná na konkrétny prostriedok umelej inteligencie, ktorým sú fuzzy kognitívne mapy. Uvedený je podrobný popis tejto metódy, vrátane jej možných aplikácií v oblasti riadenia leteckých prúdových motorov, konkrétne pri riadení a modelovaní malého prúdového motora (MPM) s typovým označením ISTC-21V.

Kľúčové slova v SJ

Situačné riadenie, umelá inteligencia, fuzzy kognitívne mapy, letecké prúdové motory

Abstrakt v AJ

The subject of the proposed doctoral dissertation exam thesis is the review of various methods, approaches and means applicable to control of complex systems. The first part of the thesis addresses mostly the methodology of situational control of complex systems with use of means of artificial intelligence. The second part of the thesis is oriented on the specific tool of artificial intelligence, which are the fuzzy cognitive maps. Detailed description of this method is given, including its possible applications in the field of control of aircraft turbojet engines, specifically in control and modelling of the small turbojet engine model ISTC-21V.

Kľúčové slova v AJ

Situational control, artificial intelligence, fuzzy cognitive maps, aircraft turbojet engines,

Čestné vyhlásenie

Vyhlasujem, že som celú dizertačnú prácu vypracoval samostatne s použitím uvedenej odbornej literatúry.

V Košiciach, 30. januára 2015

.....

vlastnoručný podpis

PodĎakovanie

Touto cestou by som rád vyjadril úprimné poďakovanie môjmu školiťovi Dr. h. c. mult. prof. Ing. Ladislavovi Madarászovi, PhD. za jeho trpezlivosť, ohľaduplnosť a ústretové vedenie počas celého doterajšieho doktorandského štúdia. Taktiež by som chcel poďakovať Dr. Ing. Jánovi Vaščákovi za jeho cenné pripomienky a odbornú pomoc nielen pri vypracovaní tejto práce. Ďakujem všetkým kolegom z Leteckej fakulty Technickej univerzity za ústretovosť a odborné vedenie v oblasti tak blízkej raketovej vede. A nakoniec, by som chcel poďakovať mojej rodine, ktorá ma podporovala nielen počas štúdia na univerzite, ale aj počas celého môjho života.

Obsah

Zoznam obrázkov	8
Zoznam symbolov a skratiek	10
Úvod	11
1. Ciele písomnej práce k dizertačnej skúške.....	13
2. Situačné riadenie a modelovanie zložitých systémov.....	14
2.1. Zložitý systém	14
2.2. Riadenie a modelovanie vo všeobecnosti	15
2.3. Riadenie a modelovanie ZS	17
2.4. Situačné riadenie a modelovanie ZS	19
2.4.1. Metodika situačného riadenia	19
2.4.2. Situačné modelovanie	21
3. Využitie prostriedkov umelej inteligencie pri situačnom riadení	23
3.1. Prehľad prostriedkov výpočtovej UI.....	24
3.1.1. Neurónové siete	24
3.1.2. Evolučné a populačné algoritmy.....	27
3.1.3. Fuzzy inferenčné systémy	29
3.2. Hybridné systémy UI v riadení.....	34
3.2.1. Hybridné systémy riadenia technických systémov.....	34
3.2.2. Hybridizácia prostriedkov výpočtovej UI	35
3.3. Využitie prostriedkov UI v situačnom riadení a modelovaní.....	40
4. Fuzzy kognitívne mapy	45
4.1. Jednoduché kognitívne mapy.....	46
4.2. Fuzzy kognitívne mapy	47
4.3. Formálna definícia FKM.....	48
4.4. Výpočet aktivačnej hodnoty konceptu.....	49
4.5. Základné problémy riešiteľné pomocou FKM	50
4.6. Metódy automatizovaného učenia FKM	52
5. Perspektívy využitia FKM pri situačnom modelovaní a riadení leteckých motorov	54
5.1. Letecké turbokompresorové motory	54
5.2. Malý prúdový motor (MPM) s typovým označením ISTC-21V	58
5.3. Situačné riadenie a modelovanie MPM	61
5.4. FKM pri riadení a modelovaní MPM	63
5.4.1. FKM pri modelovaní a diagnostike MPM	65

5.4.2. FKM pri riadení MPM.....	66
5.4.3. FKM ako situačný klasifikátor stavov MPM.....	67
Záver.....	69
Tézy budúcej doktorandskej dizertačnej práce.....	70
Zoznam použitej literatúry	71
Profil doktoranda	75

Zoznam obrázkov

Obr. 1 Otvorený (kompenzačný) riadiaci obvod.	16
Obr. 2 Uzavretý (spätно-väzobný) riadiaci obvod.....	17
Obr. 3 Proces riadenia zložitého systému (komplexu).....	20
Obr. 4 Štrukturálna schéma situačného modelu	22
Obr. 5 Štruktúra umelého neurónu.....	25
Obr. 6 Viacvrstvová dopredná neurónová sieť s dvoma skrytými vrstvami.	26
Obr. 7 Všeobecná schéma evolučného algoritmu.	28
Obr. 8 Znáznornenie krajiny vhodnosti pre problém s dvoma parametrami	28
Obr. 9 Fuzzy množina.	30
Obr. 10 Lingvistická jazyková premenná.....	31
Obr. 11 Vizualizácia inferencie fuzzy pravidiel.....	32
Obr. 12 Štruktúra fuzzy regulátora.....	33
Obr. 13 Architektúra hybridného riadiaceho systému.....	35
Obr. 14 Možnosti hybridizácie prostriedkov výpočtovej UI.....	36
Obr. 15 NARA – Neural-network designed on Approximate Reasoning Architecture.....	38
Obr. 16 Algoritmus iteratívneho generovania pravidiel AdaBoost.....	40
Obr. 17 Perspektívny model situačného riadenia zahŕňajúci prostriedky U.....	41
Obr. 18 Štrukturálna schéma formátorového riadenia.....	42
Obr. 19 Funkcionálny model situačného riadenia formátorom.....	43
Obr. 20 Jednoduchá kognitívna mapa.....	46
Obr. 21 Kognitívna mapa využitá na zobrazenie politickej situácie	47
Obr. 22 Fuzzy kognitívna mapa.	48
Obr. 23 Výpočet aktivačnej hodnoty konceptu.....	49
Obr. 24 Model výmenníka tepla realizovaný pomocou FKM.....	51
Obr. 25 Vizualizácia troch rôznych atraktorov FKM s dvoma sledovanými hodnotami konceptov.	51
Obr. 26 Letecký turbokompresorový motor GE-90 firmy General Electric Aviation.	54
Obr. 27 Hlavné časti dvojhriadeľového LTKM.....	55
Obr. 28 Jeden stupeň axiálneho kompresora	56
Obr. 29 Malý prúdový motor (MPM) s typovým označením ISTC-21V	59
Obr. 30 Zmena parametrov malého prúdového motora počas jedného merania	60
Obr. 31 Situačná dekompozícia MPM	61
Obr. 32 Schéma formátorového riadenia MPM.....	62

Obr. 33 Modelovanie nelineárneho vzťahu medzi parametrami A a B prostredníctvom FKM.	64
Obr. 34 Modelovanie dynamických vzťahov medzi parametrami A a B prostredníctvom FKM.	64
Obr. 35 Návrh lokálneho modelu MPM realizovaného pomocou FKM.	65
Obr. 36 Návrh riadenia LTKM realizovaného prostredníctvom FKM.	66
Obr. 37 Alternatívny návrh riadenia s využitím FKM.	67
Obr. 38 Zjednodušený pohľad na situačnú klasifikácia pomocou FKM.	68

Zoznam symbolov a skratiek

BP	Metóda spätného šírenia chyby („Backpropagation of Error“)
BS	Bayesovská sieť
DDHL	Dátovo poháňané hebbovo učenie („Data Driven Hebbian Learning“)
DEC	Systém riadenia leteckého motora („Digital Engine Control“)
DS	Dynamický systém
EA	Evolučné algoritmy
FADEC	Systém riadenia motora s plnou autoritou („Full Authority Digital Engine Control“)
FIS	Fuzzy inferenčný systém
FKM	Fuzzy kognitívna mapa
FM	Fuzzy množina
FS	Fuzzy systémy
HL	Hebbian Learning – hebbovo učenie
IRL	Iteratívne učenie pravidiel („Iterative Rule Learning“)
IS	Inteligentný systém
ISTC-21V	Inteligentný malý prúdový motor s premenlivou výstupnou dýzou („Intelligent Small Turbojet Engine with Variable exhaust noozle“)
KM	Kognitívna mapa
KTR	Konvenčná teória riadenia
LMS	Least Mean Square – metóda strojového učenia založená na najmenšej kvadratickej chybe
LP	Lingvistická jazyková premenná
LTKM	Letecký turbokompresorový motor
MPM	Malý prúdový motor
NS	Umelá neurónová sieť
PS	Petriho sieť
SR	Situačné riadenie
SUI	Symbolická umelá inteligencia
SV	Synaptická váha medzi neurónmi v NS
TSK	Takagi-Sugeno-Kangov fuzzy inferenčný systém (resp. regulátor)
UI	Umelá inteligencia
ZS	Zložitý systém

Úvod

„Rozhodnutie je len začiatok. Len čo sa človek rozhodne, pohnú sa v skutočnosti do mocného prúdu a ten ho unáša na miesto, o ktorom v momente rozhodnutia vôbec nepremýšľal.“

Paulo Coelho

So zložitými systémami sa stretávame každodenne vo všetkých sférach bežného života. Medzi tieto systémy patrí väčšina sociologických, spoločenských, psychologických, biologických, technických, fyzikálnych a iných systémov, ktoré sú založené na princípe samoregulácie alebo sú riadené vonkajšími zásahmi. Neustály rast náročnosti riešených problémov vrátane nutnosti riadiť stále zložitejšie systémy nevyhnutne vyžaduje implementáciu nových metodických postupov pri návrhu riadiacich systémov. Cieľom je priniesť vyššiu bezpečnosť, kvalitu a robustnosť riadenia.

Cieľom predloženej práce je vypracovať prehľad metód, postupov a prostriedkov, ktoré sú využiteľné na riešenie uvedených problémov. Patrí medzi ne metodika situačného riadenia (uvedená v 2. kapitole), ktorá je široko aplikovateľná pri riadení rozsiahleho spektra rôznych zložitých systémov. Umelá inteligencia, v súčasnosti ako jedna z najrýchlejšie sa rozvíjajúcich oblastí informatiky a výpočtovej techniky, ponúka taktiež prostriedky pre dosiahnutie týchto cieľov (ich prehľad sa venuje 3. kapitola). Jedným z týchto prostriedkov sú aj fuzzy kognitívne mapy (uvedené v 4. kapitole), ktoré sú veľmi vhodné pre opis, modelovanie a modelovanie zložitých systémov a v tejto súvislosti aj na ich diagnostiku a riadenie.

Medzi hlavné výhody fuzzy kognitívnych máp patrí ich schopnosť zachytiť reťazené kauzálne väzby medzi pojmami, ktoré môžu reprezentovať rôzne abstraktné ale aj konkrétne objekty z reálneho sveta. Touto schopnosťou tvoria alternatívu k produkčným pravidlovým systémom. Prednosťou je veľmi dobrá prehľadnosť modelov, ktoré popisujú. Možnosťou je tiež postupná tvorba čiastkových modelov reálneho sveta a ich neskoršie zlúčenie do kompletného komplexného modelu. Všetky tieto vlastnosti predpovedajú veľmi dobrú uplatniteľnosť fuzzy kognitívnych máp pri modelovaní zložitých systémov. Návrh metód modelovania a riadenia s využitím fuzzy kognitívnych máp je tiež jedným z cieľov tejto práce.

Pri testovaní rôznych metód a prostriedkov riadenia zložitých systémov máme v priestoroch Laboratória inteligentného riadenia systémov leteckých motorov (LIRS LM), prístup k unikátnemu zložitému systému, ktorým je malý letecký prúdový motor (MPM) s typovým označením ISTC-21V. Hoci je tento motor rozmerovo malý, v jeho vnútri prebiehajú zložité termodynamické deje, ktoré

sú veľmi blízke veľkým komerčným prúdovým motorom. Ako objekt je preto veľmi vhodný pre implementáciu a overenie rôznych modelov a riadiacich algoritmov, ktoré môžu byť neskôr zovšeobecnené a aplikovateľné aj v iných oblastiach a pri iných zložitých systémoch. Keďže pri plnení našich výskumných cieľov chceme využiť možnosť práce s týmto výnimočným zložitým systémom, v záverečnej časti písomnej práce (5. kapitola) sa venujeme jeho predstaveniu. Nakoniec uvádzame prehľad experimentálnych metód založených na fuzzy kognitívnych mapách, ktoré na tomto motore plánujeme preveriť.

1. Ciele písomnej práce k dizertačnej skúške

*„Kto chce hýbať svetom, musí pohnúť
najsôr sám sebou.“*

Sokrates

Písomná práca k dizertačnej skúške je orientovaná na nasledujúce hlavné ciele:

- Vypracovanie úvodu k využitiu metodiky situačného riadenia pri riadení a modelovaní zložitých systémov.
- Prehľad možností využitia prostriedkov umelej inteligencie pri situačnom riadení a modelovaní.
- Vypracovanie prehľadu problematiky fuzzy kognitívnych máp a ich využitia pri modelovaní a riadení technických systémov.
- Prehľad perspektív využitia fuzzy kognitívnych máp a ich modifikácií pri modelovaní a riadení leteckých turbokompresorových motorov.
- Stanovenie téz dizertačnej práce.

2. Situačné riadenie a modelovanie zložitých systémov

„Poznať nesmiernu zložitosť skutočnosti, to je pre mňa
vec úcty k životu, ktorá sa stupňuje až do úžasu.“

Karel Čapek

Pri riadení zložitých systémov, ktoré obsahujú veľký počet prvkov (technických, netechnických prostriedkov a ľudí), veľmi často nedokážeme vytvoriť presný matematický model riadeného systému. V prípade, že by sa nám ho aj podarilo zostrojiť, bol by pravdepodobne veľmi zložitý a pri riadení ťažko prakticky využiteľný. Pri návrhu riadenia takéhoto systému však môžeme využiť metodiku situačného riadenia, ktorá vykoná dekompozíciu riadenia daného systému na menšie problémy, závislé od aktuálneho stavu systému, ktoré už je možné vyriešiť [1].

2.1. Zložitý systém

Za *systém* ako taký, je zvyčajne považovaná „účelovo definovaná množina prvkov a väzieb medzi nimi, ktorá je od ostatných objektov v priestore a čase oddelená reálnou alebo virtuálnou hranicou“ [2]. Už z tejto formulácie je zrejmé, že definícia konkrétneho systému alebo jeho typu sa môže výrazne meniť v závislosti od rôznych východiskových požiadaviek. Aj z tohto dôvodu je k pojmu *zložitý systém* (ZS) možné priradiť široké spektrum riadených objektov a príslušných riadiacich subsystémov. Samotný pojem ZS nie je ojedinelý. Za veľmi blízke a často zamieňané pojmy je možné považovať aj termíny ako *veľký systém*, *rozsiahly systém*, *komplex* a podobne. Presná definícia pojmu je náročná a u rôznych autorov prevládajú rôzne prístupy [3].

Pre naše účely budeme využívať definíciu [4], podľa ktorej je ZS *súborom konečného počtu prvkov* (systémov, subsystémov, elementov) a ich vzájomných prepojení, ktorému prináležia nasledovné vlastnosti [1][3][4][5][6][7]:

- *veľký počet prvkov*, ktorý sa môže dodatočne meniť (počet prvkov v ZS sa môže zväčšovať alebo zmenšovať),
- *vzťahy medzi prvkami* definujúce štruktúru ZS, ktoré sa taktiež môžu meniť (rovnako ako prvky samotné),
- *hierarchickosť organizačnej štruktúry* prvkov ZS (bez ohľadu na to, či sa jedná o riadiaci alebo riadený systém),
- *právo autonómneho rozhodovania prvkov* (organizácia ZS je veľmi často decentralizovaná, takže jednotlivé prvky majú určitú mieru samostatnosti),
- *zmena miesta* (oblasti priestoru), v ktorom sa ZS nachádza a v ktorom pôsobí,

- *zmena organizačnej štruktúry ZS* (t. j. zmena spojení alebo vzťahov medzi prvkami; spojenia a vzťahy elementov ZS sa môžu v priebehu jeho riadenia meniť prostredníctvom organizačných zásahov s cieľom naplnenia vopred vytýčených globálnych cieľov riadenia).

Na ZS môže zároveň pôsobiť celá rada rôznych nežiaducich vplyvov, napr. rušivé vplyvy okolia (poruchy), vplyvy narúšajúce komunikáciu medzi prvkami (šumy), chaotické správanie okolia a systému samotného, ľudský faktor (pri ergatických systémoch) a ďalšie náhodné vplyvy. Nepredvídateľnosť správania systému preto vyžaduje schopnosť ovplyvňovať jeho štruktúru v závislosti od aktuálnej situácie, t. j. schopnosť reorganizácie, reštrukturalizácie a adaptácie jednak prvkov ZS ako aj zodpovedajúcich riadiacich mechanizmov [5]. Z vlastností ZS, ktoré boli uvedené v predchádzajúcich odstavoch, vyplýva, že štruktúru ZS je možné ovplyvňovať (riadiť) [1]:

- pôsobením na jednotlivé prvky ZS,
- pôsobením na vzťahy medzi prvkami ZS.

V prípade snahy o zmenu štruktúry SZ je dôležitým predpokladom schopnosť jej popisu a zobrazenia. Na tento účel je možné použiť v zásade dva základné prístupy, ktorými sú [1]:

- grafy a teória grafov,
- štruktúrne, interakčné (väzbové) matice.

Popis prostredníctvom grafov môže byť výhodný najmä z hľadiska vizualizácia, hoci pri veľkom počte súvisiacich prvkov sa prehľadnosť do určitej miery stráca. Na druhej strane zápis pomocou interakčných matíc je užitočný pri strojovom spracovaní.

2.2. Riadenie a modelovanie vo všeobecnosti

Modelovanie dynamického systému (DS) je možné definovať ako proces tvorby popisu systému, resp. proces určovania jeho kvalitatívnych a kvantitatívnych vlastností [8]. Na tento účel používame matematické modely, ktoré zahŕňajú vzájomné pôsobenie jednotlivých systémových činiteľov, prvkov alebo podsystémov a taktiež ich interakciu s okolím. Vzájomné pôsobenie medzi prvkami sa prejavuje jednak v prípade priameho vzájomného spojenia prvkov alebo nepriamo pri spoločnom pôsobení na iný subsystém (kooperácii), resp. oboma spôsobmi [3]. Je dôležité uvedomiť si, že matematický model popisujúci DS a vzťahy medzi jeho prvkami je vždy iba účelovou abstrakciou reálneho systému a jeho presnosť je obmedzená, pretože pri snahe o zvládnutie skutočnej zložitosti systému je často potrebné vykonať rôzne zjednodušenia [3]. Medzi bežné formy opisu lineárnych aj nelineárnych DS patria najmä [8][9]:

- lineárne diferenciálne rovnice,


- laplaceov operátor (obrazový prenos),
- fourierov operátor (frekvenčný prenos),
- prechodové, impulzné a frekvenčné charakteristiky,
- metódy stavového priestoru,
- lagrangeovské rovnice,
- neurónové siete,
- fuzzy-neurónové modely.

Za *riadenie* DS považujeme účelové pôsobenie, ktorého cieľom je vplývať na dynamické procesy medzi prvkami systému tak, aby boli dosiahnuté špecifické vopred určené ciele riadenia [8]. Medzi základné ciele riadenia patrí [8]:

- *stabilizácia* – kde cieľom je dosiahnutie požadovanej stabilnej hodnoty regulovanej veličiny (napr. regulácia výšky hladiny v nádrži),
- *závislé riadenie* (vlečná regulácia) – kde cieľ riadenia je odvodený od senzoricky snímaného parametra iného nezávislého DS (napr. elektrický nastaviteľný ovládač centrálného kúrenia),
- *extremálna regulácia* (optimalizácia) – ktorej cieľom je maximalizácia alebo minimalizácia kriteriálnej funkcie, ktorej parametrami môžu byť vstupno-výstupné veličiny systému a jeho vnútorné stavy.


V závislosti od spôsobu využívania informácií o modeli DS, resp. o výstupných regulovaných veličinách rozdeľujeme základné typy riadenia na [8]:

- *riadenie bez spätnej väzby* (ovládanie) – pri ktorom nezisťujeme odozvu riadeného DS na vplyvy riadiaceho systému; predpokladom je znalosť dostatočne presného (inverzného) modelu riadeného DS, ktorý umožňuje vopred vyhodnotiť dôsledok zvoleného akčného zásahu; pri tomto type riadenia sa používajú najmä otvorené (resp. dopredné alebo kompenzačné) riadiace obvody (pozri Obr. 1);



Obr. 1 Otvorený (kompenzačný) riadiaci obvod.

- *riadenie so spätnou väzbou* (regulácia) – kde síce nepoznáme presný model systému, avšak pomocou sledovania odchýlky aktuálnej hodnoty sledovaného parametra (resp. parametrov – aktuálnych vstupov, výstupov, resp. stavov) DS od cieľovej hodnoty, dokážeme vypočítať požadované akčné zásahy s dostatočnou presnosťou; pri určovaní odchýlky od požadovanej hodnoty sa používajú uzavreté (spätno-väzobné alebo regulačné) riadiace obvody (pozri Obr. 2);



Obr. 2 Uzavretý (spätno-väzobný) riadiaci obvod.

- *všeobecné riadenie* – ktoré je kombináciou predchádzajúcich dvoch typov; pri tomto type riadenia sa využívajú kombinované riadiace štruktúry zostavené z otvorených aj z uzavretých riadiacich obvodov.

Veľmi obvyklé je aj taxonomické zatriedenie s ohľadom na účasť ľudského činiteľa v procese riadenia DS. Podľa toho rozlišujeme [8]:

- *automatické riadenie* bez účasti človeka,
- *automatizované riadenie* s čiastočným zapojením ľudského činiteľa.

2.3. Riadenie a modelovanie ZS

Zložité systémy popisujeme a ich vlastnosti určujeme (podobne ako pri ostatných dynamických systémoch) zvyčajne matematickými modelmi. Zložité mnohoparametrové systémy môžu vznikať spojením viacerých čiastkových mnohoparametrových systémov. Často majú hierarchickú štruktúru, ktorej hlavnými príčinami sú [7]:

- veľká rozmernosť riadeného ZS,
- rôzna informovanosť jednotlivých prvkov ZS o vplyve okolitého prostredia na ZS a parametroch riadeného procesu.

Tradičné metódy a procedúry určené na analýzu systémov a návrh stratégií riadenia sú založené na všeobecnom predpoklade *centrálnosti*, kde informácie o systéme a výpočty na nej založené sú centralizované. Tento predpoklad pri riadení ZS obyčajne zlyháva pre nedostatok centralizovanej

informácie alebo pre nedostatočný výpočtový výkon centralizovaného systému [3]. Spoločným znakom ZS je presun časti rozhodovacích procesov z centra na jednotlivé subsystémy usporiadané do decentralizovanej, distribuovanej, resp. hierarchickej štruktúry. Vlastnosti ZS potom zisťujeme sledovaním vlastností týchto subsystémov. ZS s hierarchickými štruktúrami je možné riadiť s využitím rôznych prístupov [1][3][6][10]:

- **Dekompozičné metódy riadenia ZS** – pri rozmerných ZS je možné použiť metódy dekompozície, ktorých podstatou je *cielené* rozloženie úlohy globálneho systému na ľahko riešiteľné úlohy podsystémov.
- **Decentralizované riadenie ZS** – základnou charakteristikou je existencia ohraničení pri prenose informácie medzi jednotlivými subsystémami ZS. Z tohto dôvodu centrum *nevyhnutne* prenecháva časť svojich rozhodovacích právomocí podsystémom. Decentralizácia však vyvoláva potrebu koordinácie jednotlivých podsystémov tak, aby bol dosiahnutý globálny cieľ.
- **Informačné hierarchicko-organizačné systémy riadenia** – zdôrazňujú najmä dosiahnutie apriórneho ocenenia rôznych variantov hierarchickej organizačnej štruktúry vybranej pre zvolený zložitý systém.
- **Situačné riadenie** – ktoré na základe určenia globálneho stavu riadeného ZS vyberá vhodnú stratégiu riadenia. Vybraná riadiaca stratégia môže byť použitá aj pri viacerých rôznych stavoch, keďže počet možných stavov (situácií) je zvyčajne výrazne vyšší ako počet dostupných stratégií riadenia. Bližšiemu popisu metodiky situačného riadenia sa venujeme v kapitole 2.4.
- **Riadenie ZS v každom čase („Anytime Control“)** – tieto algoritmy sa zameriavajú na špecifickú podmnožinu problémov situačného riadenia, napr. situácie v riadení, kedy dochádza ku chybám vo vzorkovaní na vstupe, napríklad z dôvodu preťaženia senzorického systému alebo výpočtového systému, resp. z dôvodu poruchového stavu samotného riadeného systému.
- **Kooperatívne riadenie ZS** – zadávací systém pre ZS vytyčuje ciele jeho funkcie a stanovuje pravidlá správania sa jeho subsystémov a prvkov. Subsystémy ZS majú značnú autonómiu vo svojom správaní avšak súčasne využívajú vzájomnú spoluprácu tak, aby bolo možné čo najvýhodnejšie dosiahnuť spoločný cieľ.
- **Teória chaosu pri riadení ZS** – poznatky vyplývajúce z teórie chaosu sa pri riadení ZS využívajú najmä na kontrolu chaosu obsiahnutého v riadenom ZS.

- **Prostriedky umelej inteligencie** – v poslednom čase sa využívajú v mnohých oblastiach riadenia a modelovania nielen ZS. Možno medzi ne zaradiť napr. *expertné systémy, agentové a multi-agentové systémy, evolučné prístupy, neurónové siete a fuzzy systémy*. Bližšie o týchto prostriedkoch pojednáva kapitola 3.

S ohľadom na nevyhnutnosť dôkladnej analýzy štruktúry riadeného ZS a príslušných riadiacich systémov sa proces riadenia ZS člení na dve etapy [1]:

- 1) *plánovanie riadiaceho procesu,*
- 2) *operatívne riadenie.*

Plánovanie riadiaceho procesu je časovo i priestorovo oddelené od vlastného riadenia ZS. Vychádza zo súboru hypotéz o dynamike ZS a prostredia v rámci celého rozsahu jeho činnosti. Výsledkom plánovacej fázy je navrhnutá metodika a štruktúra riadiaceho systému, ako aj príslušné algoritmy riadenia [1]. Operatívne riadenie následne priebežne odstraňuje odchýlky voči plánu pri využití navrhnutých riadiacich algoritmov, ktoré v závislosti od aktuálnych cieľov vhodne parametrizuje. Optimalizácia parametrov sa môže vzťahovať na kvalitu rozhodovacích a riadiacich procesov, príp. na minimalizáciu odchýlok voči plánu, ale je takmer nemožné optimalizovať globálne celý proces riadenia [1].

2.4. Situačné riadenie a modelovanie ZS

Situačné riadenie (SR) patrí medzi dôležité metodické postupy využiteľné pre riadenie ZS [2]. Východiskom pri využití metodiky SR je predpoklad, že riadený ZS sa môže nachádzať principiálne v nekonečne veľkom množstve stavov, pričom objem prostriedkov umožňujúcich jeho riadenie je zvyčajne obmedzený [5]. Pri použití princípu situačného riadenia je do riadiaceho systému integrovaný formálny model, ktorý umožňuje predvídať následky jednotlivých rozhodnutí a zvoliť tak najvhodnejšie riešenie s ohľadom na zvolené kritériá [1]. Inak povedané, rôznym situáciám, v ktorých sa môže ZS nachádzať, priradíme dopredu pripravené rozhodnutia (riadiace stratégie), pričom ich počet je zvyčajne oveľa menší, ako počet možných situácií [6].

2.4.1. Metodika situačného riadenia

Návrh systému situačného riadenia ZS je náročný proces pozostávajúci z viacerých krokov. V zásade je možné tieto kroky rozdeliť (podobne ako je to uvedené v kapitole 2.3) na *etapu plánovania a návrhu* riadiaceho systému a následne na *etapu operatívneho riadenia* ZS.

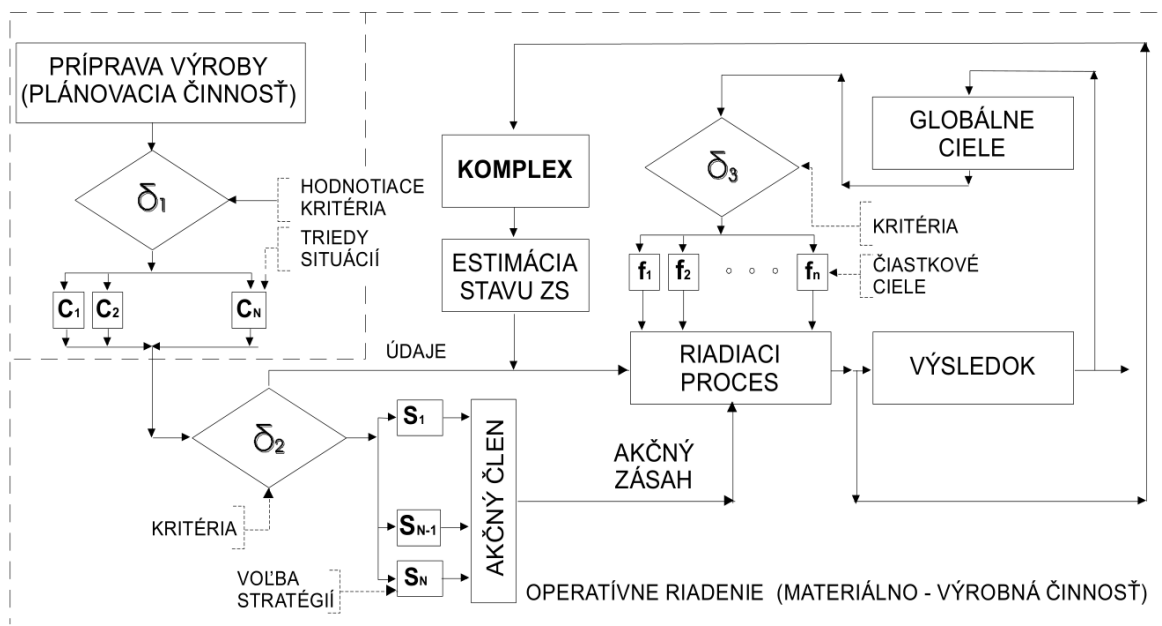
Etapu plánovania situačného riadenia ZS začína popisom riadeného systému, určením globálnych cieľov riadenia a následne návrhom tzv. situačných tried (rámcov), ktoré môžu zoskupovať viacero

podobných situácií, resp. stavov ZS. K jednotlivým situačným triedam sú potom priradené príslušné stratégie riadenia. Každú situačnú triedu pokrýva minimálne jedna riadiaca stratégia, ale môžu nastať aj prípady keď jednu triedu pokrývajú viaceré stratégie. V prípade, že práve jedna konkrétna stratégia pokrýva viacero rôznych situačných tried, je vhodné tieto triedy zlúčiť, prípadne ich návrh celkovo prehodnotiť. Pre zabezpečenie efektívnej práce riadiaceho systému je vhodné počet použitých tried a stratégií minimalizovať [5].

Úlohou *operatívneho riadenia* ZS je parametrizácia vopred pripravených stratégií riadenia podľa vyhodnotenia stavu ZS a ich použitie pri riadení systému. Cieľom je v reálnom čase vyrovnať odchýlky od požadovaného stavu systému [1]. Proces riadenia ZS obsahuje tri základné rozhodovacie uzly (pozri Obr. 3), v ktorých podľa zvolených rozhodovacích kritérií a aktuálnej situácie ZS prebieha rozhodovanie [1]:

- o zatriedení do príslušnej vzorovej triedy situácií (estimácia stavu ZS),
- o voľbe zodpovedajúcej stratégie,
- o realizácii čiastkových funkcií riadenia.

Pri výbere rozhodnutí je možné využiť klasický princíp rozhodovacích tabuliek, kde v riadkoch sú situácie a v stĺpcoch sú príslušné rozhodnutia [1]. Keďže SR je rámcovou metodikou, pre riešenie jednotlivých úloh, ktoré súvisia s rozhodovaním (napr. analýza, klasifikácia, modelovania atď.), môže využívať aj ďalšie aplikovateľné metódy z rôznych oblastí uvedených v kapitole 2.3.



Obr. 3 Proces riadenia zložitého systému (komplexu). Prevzaté z [11].

Z uvedených charakteristík situačného riadenia je zrejmé, že pre jeho úspešné použitie je potrebné vyriešiť tieto problémy [6]:

- ako vopred pripraviť súbor vhodných a vyhovujúcich rozhodnutí,
- ako roztriediť jednotlivé situácie do tried situácií tak, aby sa každej triede situácií mohlo priradiť vhodné rozhodnutie,
- ako uskutočniť klasifikáciu aktuálnych situácií do vzorových tried situácií pri skutočnej prevádzke systému.

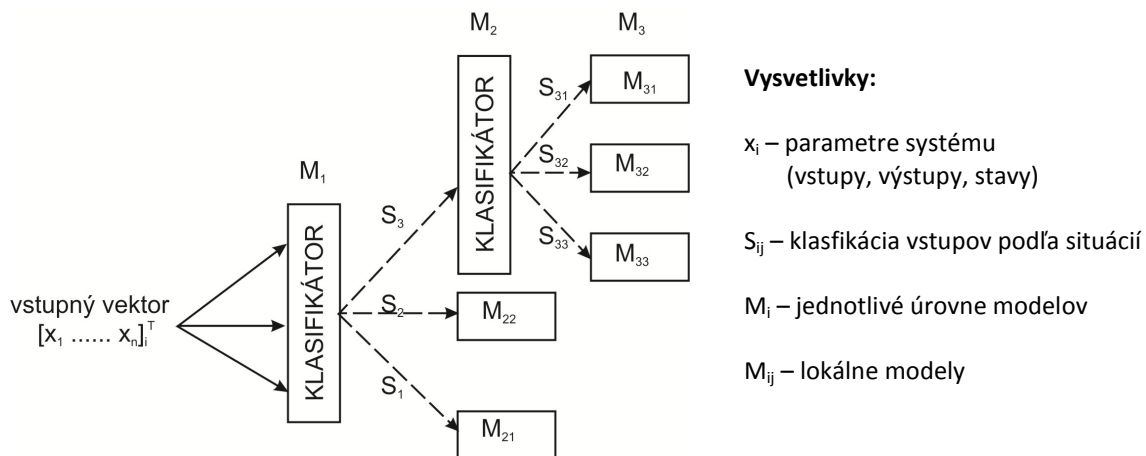
Spôsob riešenia týchto problémov súvisí s povahou konkrétneho riadeného ZS. Taktiež závisí od zvolených metód rozhodovania a návrhu riadenia ZS. Možné je použitie konvenčných metód (napr. matematicko-štatistické metódy, multikriteriálne rozhodovanie, skupinové rozhodovanie, heuristické postupy atď.) alebo modernejších prístupov integrujúcich v sebe prvky umelej inteligencie [1][5]. Algoritmus tvorby systému situačného riadenia ZS sa obyčajne skladá z nasledujúcich krokov [1]:

- opis modelu štruktúry a funkcie riadeného ZS,
- určenie globálneho cieľa riadenia,
- klasifikácia prevádzkových stavov a ich príčin,
- klasifikácia a opis riadiacich stratégií priradených k jednotlivým stavom,
- algoritmizácia jednotlivých režimov riadenia,
- implementácia.

Konkrétna podoba realizácie situačného riadenia, v našom prípade *formátorového riadenia s využitím prostriedkov umelej inteligencie*, je uvedená v kapitole 3.3.

2.4.2. Situačné modelovanie

Hoci metódy využívajúce situačnú klasifikáciu boli pôvodne určené najmä pre využitie v riadení ZS, je možné ich aplikovať aj pri tvorbe modelov dynamických systémov [5]. Príkladom je vytvorenie množiny lineárnych modelov približne odpovedajúcich správaniu systému v rôznych pracovných bodoch (stavoch, situáciách) systému a odpovedajúceho klasifikátora určujúceho použitie konkrétneho modelu. Výhodou tohto prístupu je celkové zjednodušenie modelu systému, ktorý môže byť modelovaný s rôznou presnosťou v závislosti od požiadaviek v danej situácii. V prípade potreby vyššej presnosti môže byť model v konkrétnej situácii ďalej dekomponovaný na presnejšie lokálne modely odpovedajúce mikro-situáciám na nižšej úrovni (pozri Obr. 4).



Obr. 4 Štruktúrna schéma situačného modelu. Prevzaté z [5].

Situačné modely je možné následne použiť na predikciu správania sa systému, diagnostiku alebo testovanie vhodných riadiacich stratégií. Ich veľkou výhodou je schopnosť modelovať aj nelineárne ZS v celom rozsahu prevádzky, čo je v prípade tradičných modelov veľmi zložité až nemožné.

3. Využitie prostriedkov umelej inteligencie pri situačnom riadení

*„Každá dostatočne pokročilá technológia je
na nerozoznanie od mágie.“*

Arthur C. Clarke

Umelá inteligencia (UI) spolu s informatikou, mikroelektronikou a telekomunikačnou technikou vedú k hlbokým štrukturálnym zmenám vo všetkých oblastiach ekonomického a spoločenského života. Šírka záberu UI siaha od základných vied, cez operatívne plánovanie a návrh robotov až ku kultúre. UI nie je len súborom výpočtových metód, ktorý podporuje informatiku a počítačové vedy. Svojím pôvodom a inšpiráciou študuje inteligenciu ako prírodný fenomén [12].

Inteligentné technológie predstavujú systémy, ktoré majú schopnosť riešiť úlohy o ktorých sa predpokladá, že by ich vyriešil len človek s poznatkami o danej problematike [13]. Medzi základné vlastnosti inteligentných technológií patria nasledovné schopnosti [13]:

- *učiť sa z dát a získavať poznatky,*
- *ukladať poznatky (získané v minulosti),*
- *využívať získané poznatky (pri riešení problémov v budúcnosti).*

Potreba systémov schopných učenia vedie k návrhu tzv. učiacich sa systémov. Učiace sa systémy majú schopnosť získavať informácie a poznatky o jednotlivých stavoch systému a v prípade potreby nahradiť operátora alebo iný riadiaci systém pri výkone akčného zásahu. Inteligentný systém (IS), môže získavať poznatky rôznym spôsobom [13]:

- *vie vytvárať usporiadané dvojice vstupov a výstupov systému,*
- *je schopný klasifikovať stav systému do vzorových tried (a to aj v prípade, že systém je popísaný viacrozmerným stavovým vektorom).*

Pre zabezpečenie schopnosti uchovávať poznatky je nevyhnutné v nejakej forme budovať *bázu vedomostí* (resp. „bázu znalostí“). IS môžu na vytvorenie bázy znalostí použiť už jestvujúce znalosti expertov a následne ich využívať podobným spôsobom ako človek. Kvalitu rozhodnutí IS determinuje kvalita vedomostí, ktoré má tento systém k dispozícii. Podľa spôsobu reprezentácie vedomostí, je možné ich rozdelenie na [1]:

- *deklaratívne vedomosti*, ktoré vyjadrujú, čo je potrebné poznať, dokázať, resp. vykonať,
- *procedurálne vedomosti*, ktoré definujú ako vykonať nejakú akciu.

Jadrom IS je riadiaci (odvodzovací, interpretačný, inferenčný) mechanizmus, ktorý využíva poznatky uložené v báze vedomostí na riešenie konkrétneho problému. Cieľom uloženia vedomostí (získaných na základe skúsenosti z minulosti) je teda ich použitie v budúcnosti. V praxi to znamená, že ak v minulosti vznikla nejaká prevádzková situácia a operátor ju svojim zásahom úspešne vyriešil, v budúcnosti by IS mal na rovnakú situáciu reagovať samostatne [1].

3.1. Prehľad prostriedkov výpočtovej UI

Metódy umelej inteligencie je v súčasnosti možné rozdeliť na dva hlavné prúdy [12]:

- *Klasické prístupy* založené na metódach **symbolickej umelej inteligencie** („Artificial Intelligence“), ktoré sú charakteristické využívaním matematickej logiky, symbolickej reprezentácii vedomostí a centrálnym sekvenčným spracovaním. Predstavujú prístup „zhora nadol“ („top-down“), ktorý vychádza predpokladu, že inteligencia je racionálna a môže byť reprezentovaná logickými systémami zahŕňajúcimi dokazovanie pravdivosti faktov od základných axiôm až po konečné okrajové dôsledky.
- *Moderné prístupy* založené na metódach subsymbolickej umelej inteligencie alebo aj **výpočtovej inteligencie** („Computational Intelligence“, „Soft Computing“), ktoré sú charakteristické nesymbolickou reprezentáciou vedomostí. Predstavujú prístup „zdola nahor“ („bottom-up“), ktorý je inšpirovaný prevažne nízkoúrovňovými perцепčnými procesmi, biologickými procesmi, evolučnými princípmi a prírodnými javmi. Prevládajúcou filozofiou je tzv. *konekcionalizmus* („connectionism“), ktorý predpokladá, že z jednoduchých častí je možné spájaním poskladať sofistikované systémy z vysokou abstraktnou inteligenciou.

Rozdiel medzi týmito metódami je očividne najmä v použitej reprezentácii vedomostí. Symbolická reprezentácia predstavuje jednoduché a kompaktné vyjadrenie v reči symbolov a matematických zákonov. Nesymbolická reprezentácia používa numerické zobrazenie, prácu s reálnymi číslami, obrazovou a akustickou informáciou [12].


V ďalšej časti práce sa budeme venovať najmä prostriedkom výpočtovej inteligencie, ktorej hlavnými predstaviteľmi sú neurónové siete, fuzzy systémy a evolučné algoritmy.

3.1.1. Neurónové siete

Umelá neurónová sieť (NS) je masívne paralelný procesor, ktorý dokáže uchovávať znalosti o probléme a neskôr ich využiť na jeho riešenie [14]. NS je uznávaným spôsobom riešenia širokého spektra problémov, ako sú napríklad problémy aproximácie funkcií, klasifikácie do tried, asociačné problémy, simulácia pamäte, transformácia signálov atď. Široká aplikovateľnosť NS

pramení z ich schopnosti aproximácie ľubovoľnej spojitej funkcie. O tejto schopnosti hovorí tzv. univerzálna aproximačná teoréma, ktorá bola dokázaná nezávisle v [16],[17] a [18].

Základnou štruktúrnou a procesnou jednotkou NS je umelý neurón (pozri Obr. 5).



Obr. 5 Štruktúra umelého neurónu.

Neurón pôsobí na ostatné neuróny prostredníctvom jednosmerných prepojení – synapsií. Sila pôsobenia medzi dvoma neurónmi je priamo úmerná hodnote synaptickej váhy w_{ij} odpovedajúcej danému prepojeniu. Okrem pôsobenia ostatných neurónov je tu navyše aj vplyv tzv. prahu (bias), čo je vlastne trvalé konštantné pôsobenie nezávislé od vplyvu ostatných neurónov. Jeho sila závisí od prahovej váhy Θ_i . Hodnoty synaptických váh (SV) sú hlavnými parametrami určujúcimi funkciu NS a zároveň nositeľkami znalostí uložených v NS [14].

Neurón sa počas svojej činnosti v NS aktivuje v závislosti od vplyvu ostatných neurónov, ktoré na neho pôsobia. Jeho aktivácia zvyčajne nadobúda hodnoty z intervalu $<0,1>$. Výpočet výstupnej hodnoty prebieha v troch fázach, resp. prostredníctvom troch funkcií neurónu [14]:

- 1) Vstupná funkcia in_i sa počíta ako súčet prahovej váhy Θ_i a sumy súčinov výstupov ou_j z predchádzajúcich (predsynaptických) neurónov y_j a príslušných váh w_{ij} :

$$in_i = \sum_{j=1}^N w_{ij} ou_j + \Theta_i. \quad (1)$$

- 2) Aktivačná funkcia x_i , ktorá prahuje výsledok vstupnej funkcie na interval $<0,1>$. Najčastejšie sa používa sigmoidálna aktivačná funkcia:

$$x_i = f(in_i) = \frac{1}{1 + e^{-\alpha in_i}}. \quad (2)$$

- 3) Výstupná funkcia ou_i , ktorá určuje konečnú výstupnú hodnotu neurónu. Zvyčajne sa používa funkcia identity:


$$ou_i = f(x_i) = x_i. \quad (3)$$

Ak definujeme neuróny y_j pomocou ich výstupných hodnôt ou_j ako $y_j = ou_j$ a použitú aktivačnú funkciu označíme φ , potom môžeme neurón y_i zjednodušene definovať aj nasledovne:

$$y_i = \varphi\left(\sum_{j=1}^N w_{ij} y_j + \Theta_i\right). \quad (4)$$

Neuróny sa v NS skladajú do zložitejších štruktúr s rôznym usporiadaním. Vo všeobecnosti môže mať NS ľubovoľnú štruktúru opísateľnú orientovaným grafom, ale vlastnosti takýchto sietí sa ťažko analyzujú. Častejšie sa využívajú NS s pravidelnými štruktúrami, napr. viacvrstvovou štruktúrou s jednou vstupnou, jednou výstupnou a jednou alebo viacerými skrytými vrstvami. Vo všeobecnosti rozdeľujeme topológie NS do dvoch základných skupín [14][15]:

- *Dopredné NS* (feed-forward – FF NS) – kde sú neuróny prepojené v jednom smere.
- *Rekurentné NS* (recurrent – RC NS) – pripúšťajú šírenie signálu oboma smermi a rozdelenie neurónov na vrstvy je tým pádom často nejednoznačné.



Obr. 6 Viacvrstvová dopredná neurónová sieť s dvoma skrytými vrstvami.

Činnosť NS je možné rozdeliť do dvoch fáz [14]:

- Fáza učenia (adaptácie) – počas ktorej sa do hodnôt váh NS ukladajú znalosti, prostredníctvom cieľenej zmeny SV.
- Fáza života – počas ktorej sa poznatky získané v procese učenia využijú v prospech riešenia nejakého problému (napr. klasifikácia, optimalizácia, zhlukovanie a pod.). V tejto fáze sa už SV nemenia.

Učenie NS rozdeľujeme do dvoch hlavných skupín. Prvou je *kontrolované učenie*, resp. učenie s učiteľom („supervised learning“), kde pre dané vstupné dáta sú určené odpovedajúce výstupné dáta. Výsledky NS pri procese učenia je teda možné s týmito dátami porovnávať. Druhou je *nekontrolované učenie*, resp. učenie bez učiteľa („unsupervised learning“), kde pre dané vstupné

dáta nie sú určené odpovedajúce výstupy. Pri tomto type učenia teda nie je možné kontrolovať výstup z NS.

Najčastejšie používanou metódou kontrolovaného učenia viacvrstvových dopredných NS je metóda spätného šírenia chyby (BP – „backpropagation of error“). Táto metóda umožňuje použiť takmer ľubovoľnú aktivačnú funkciu za predpokladu, že je spojito diferencovateľná [14]. Ďalšou výhodou je, že NS môže mať ľubovoľný počet vrstiev a tiež ľubovoľný počet neurónov na každej vrstve. Zmena synaptických váh sa počíta podľa *delta pravidla* [14]:

$$\Delta w_{ij}(t) = \gamma \delta_i(t) y_j(t). \quad (5)$$

Stanovenie príslušných chybových signálov $\delta_i(t)$ pre všetky neuróny je možné pomocou rekurzívneho vzťahu, ktorý predstavuje šírenie chyby smerom od výstupu NS k vstupu NS. Ak $\varphi'(in_i(t))$ je derivácia aktivačnej funkcie, potom [14]:

- pre neuróny na výstupnej vrstve platí:

$$\delta_i(t) = \varphi'(in_i(t))(ev_i(t) - y_i(t)), \quad (6)$$

- a pre neuróny na všetkých ostatných vrstvách platí:

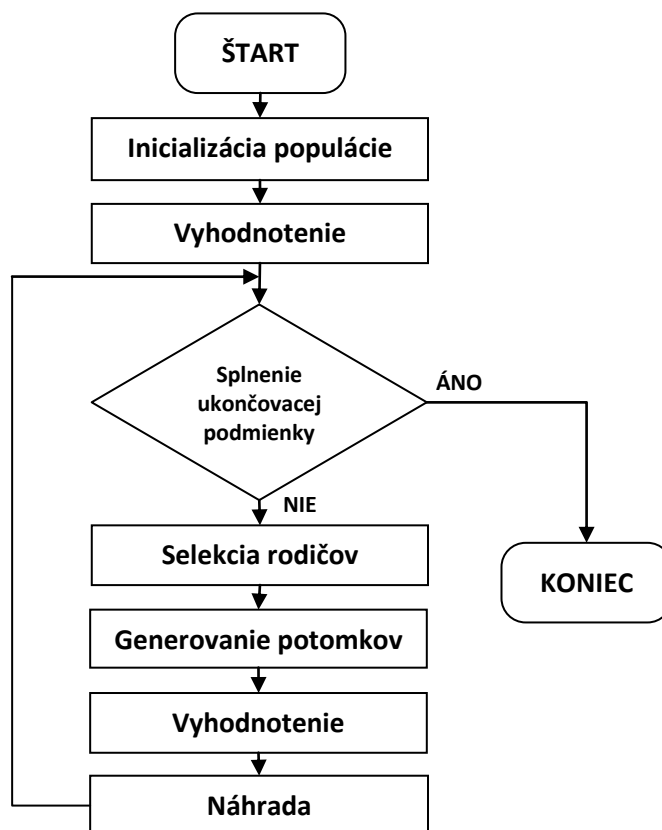
$$\delta_i(t) = \varphi'(in_i(t)) \sum_{h=1}^{N_0} (\delta_h(t) w_{hi}(t)), \quad (7)$$

pričom N_0 je počet neurónov vo vrstve napravo od neurónu y_i .

Tento spôsob učenia NS je vhodne použiteľný pri riadení a modelovaní technických systémov, kde je umožnené jednoduché meranie vstupno-výstupných parametrov systému. NS je možné použiť na identifikáciu riadeného systému a vytvorenie jeho modelu. Rovnako je možné aj jej použitie v úlohe neuroregulátora pri riadení procesu samotného. V tomto prípade sa využíva inverzný model systému.


3.1.2. Evolučné a populačné algoritmy

Evolučné algoritmy (EA) sú užitočným prostriedkom umožňujúcim optimalizáciu parametrov rôznych problémov [19]. Sú založené na simulovaní evolúcie populácie jedincov reprezentujúcich jednotlivé riešenia optimalizačného problému. Tieto riešenia sa v priebehu evolúcie menia pod vplyvom prirodzeného výberu, reprodukcie a mutácií. Na Obr. 7 je uvedená všeobecná schéma činnosti EA.



Obr. 7 Všeobecná schéma evolučného algoritmu.

EA môžeme popísať aj nasledovne: Ak predpokladáme, že riešená úloha pozostáva z N zložiek, potom každé jej riešenie (genotyp jedinca) predstavuje jeden bod v N rozmernom priestore. EA pracuje s $(N+1)$ rozmerným priestorom, kde dodatočný rozmer určuje vhodnosť príslušného riešenia. Ak vhodnosť považujeme za funkciu N premenných, potom ju môžeme znázorniť ako hyperplochu v priestore (krajina vhodnosti – Fitness Landscape – pozri Obr. 8). Cieľom EA je nájsť globálny extrém tejto plochy (najlepšie riešenie) a neuviaznuť pri hľadaní v lokálnom extréme [1].



Obr. 8 Znázornenie krajiny vhodnosti pre problém s dvoma parametrami. Prevzaté z [20].

Okrem všeobecnej definície je možné medzi EA zaradiť aj ďalšie podobné stratégie a prístupy, ktoré sú rovnako inšpirované evolučnou teóriou, napr.:

- evolučné stratégie,
- evolučné programovanie,
- genetické algoritmy.

Populačné algoritmy ako napr. „particle swarm optimization“ (PSO) [21] sú modernejšou alternatívou EA, ktorým sú veľmi podobné v tom zmysle, že tiež pracujú s populáciou jedincov reprezentujúcich parametre riešeného problému. Zmena atribútov jedincov je však vykonaná odlišným, než evolučným spôsobom. Napríklad v prípade PSO je populácia reprezentovaná časticami, ktoré sa pohybujú po krajine vhodnosti podľa jednoduchého matematického vzorca zohľadňujúceho polohu a rýchlosť pohybu častice. Každá častica sa pohybuje s cieľom zlepšiť svoju aktuálnu pozíciu, teda nasleduje povrch krajiny vhodnosti v smere jej rastu. Okrem toho zohľadňuje aj polohu ostatných častíc v prípade, že vhodnosť na ich pozícii je vyššia. Týmto spôsobom je zaručené prehľadanie širokej časti priestoru dostupných riešení s vysokou šancou na nájdenie globálneho optima.

3.1.3. Fuzzy inferenčné systémy

Fuzzy logika je veľmi často používaná v rôznych oblastiach, vrátane riadenia. Pojem *fuzzy* (nejasný, neostrý, vágny) odkazuje na fakt, že niektoré logické výrazy nemôžu byť jednoznačne definované ako pravdivé alebo nepravdivé, ale skôr ako čiastočne pravdivé. Napriek tomu, že alternatívne prístupy, vrátane neurónových sietí a evolučných algoritmov, môžu byť aplikovateľné pri mnohých problémoch s rovnakou efektivitou, fuzzy logika má výhodu v tom, že riešenie je vyjadrené spôsobom jednoducho zrozumiteľným človeku, takže jeho skúsenosti môžu byť použité pri návrhu systému.

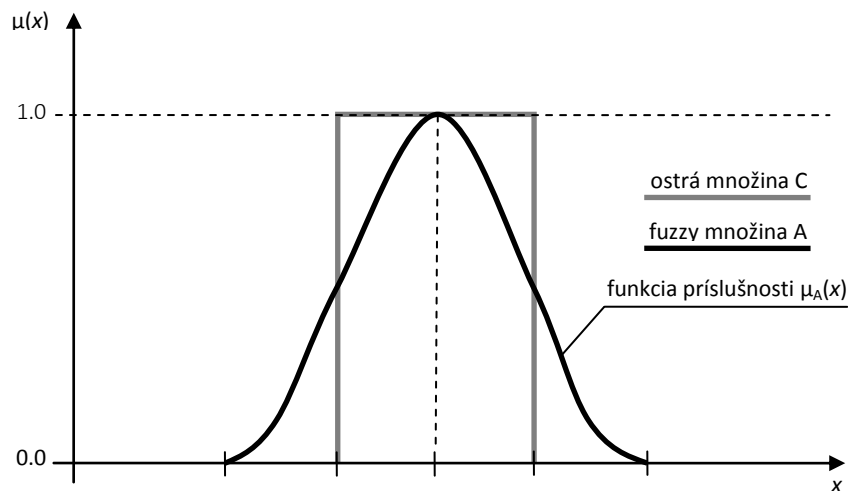
Ústredným pojmom v oblasti fuzzy systémov je *fuzzy množina* (FM) (pozri Obr. 9). Oproti konvenčnej ostrej množine sa líši najmä tým, že nie je možné jednoznačne povedať, či nejaký prvok do FM patrí alebo nie. Pri FM je na vyjadrenie príslušnosti prvku k množine k dispozícii celý interval $\langle 0,1 \rangle$, nie iba dve hodnoty (0 alebo 1), ako je to pri ostrých množinách. FM sú teda zovšeobecnením konvenčnej množinovej teórie [22].

Presnejšia definícia FM môže byť napr. nasledovná: V prípade, že X je súbor objektov (prvkov) x , potom fuzzy množina A je množina usporiadaných dvojíc [22]:

$$A = \{(x, \mu_A(x)); x \in X\}, \quad (8)$$

kde:

- $\mu_A : X \rightarrow M$ je funkcia príslušnosti („membership function“),
- $\mu_A(x)$ je stupeň príslušnosti („grade of membership“) prvku x k množine A ,
- X je univerzálna množina (univerzum) obsahujúca všetky objekty X .



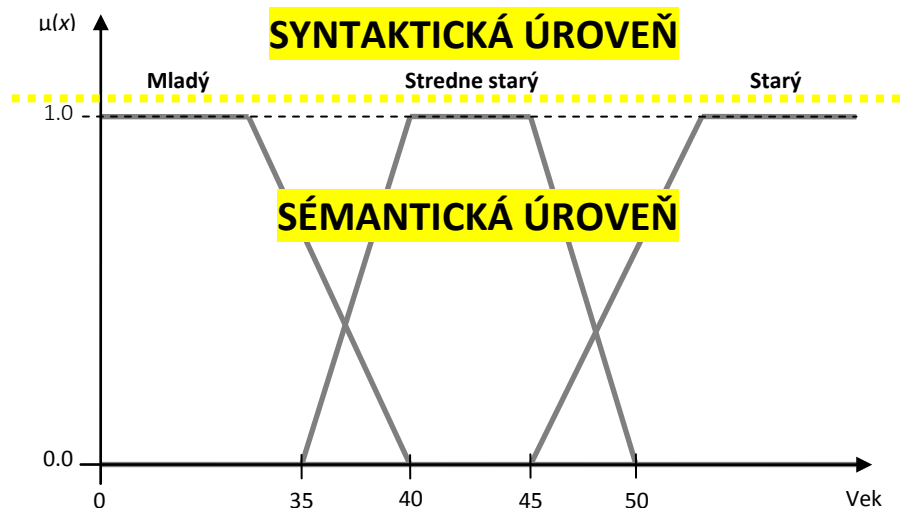
Obr. 9 Fuzzy množina.

FM samy o sebe nenachádzajú veľké využitie, ale predstavujú základný stavebný kameň pre zložitejšie logické štruktúry so širším uplatnením. Príkladom takejto štruktúry je *lingvistická premenná* (LP), resp. lingvistická jazyková premenná (pozri Obr. 10) [22], ktorá je formálne definovaná ako usporiadaná päťica [22]:

$$LP = \{N, T(N), U, G, M\}, \quad (9)$$

kde:

- N je názov lingvistickej premennej (napr. vek človeka),
- $T(N)$ je množina lingvistických termov (napr. mladý, stredne starý, starý) danej LP,
- U je univerzum,
- G sú syntaktické pravidlá, ktoré definujú spôsob tvorby konkrétnych názvov termov LP,
- M sú sémantické pravidlá, ktoré priradujú každému termu LP príslušnú FM.



Obr. 10 Lingvistická jazyková premenná.

Veľmi užitočným uplatnením lingvistických premenných je ich použitie pri návrhu *fuzzy pravidiel*. Klasické pravidlá môžeme fuzzifikovať využitím lingvistických premenných (napr. vek, výška, váha človeka) a konkrétnych lingvistických termov (malý, stredný, veľký). Môžeme vytvoriť napr. pravidlo v tvare:

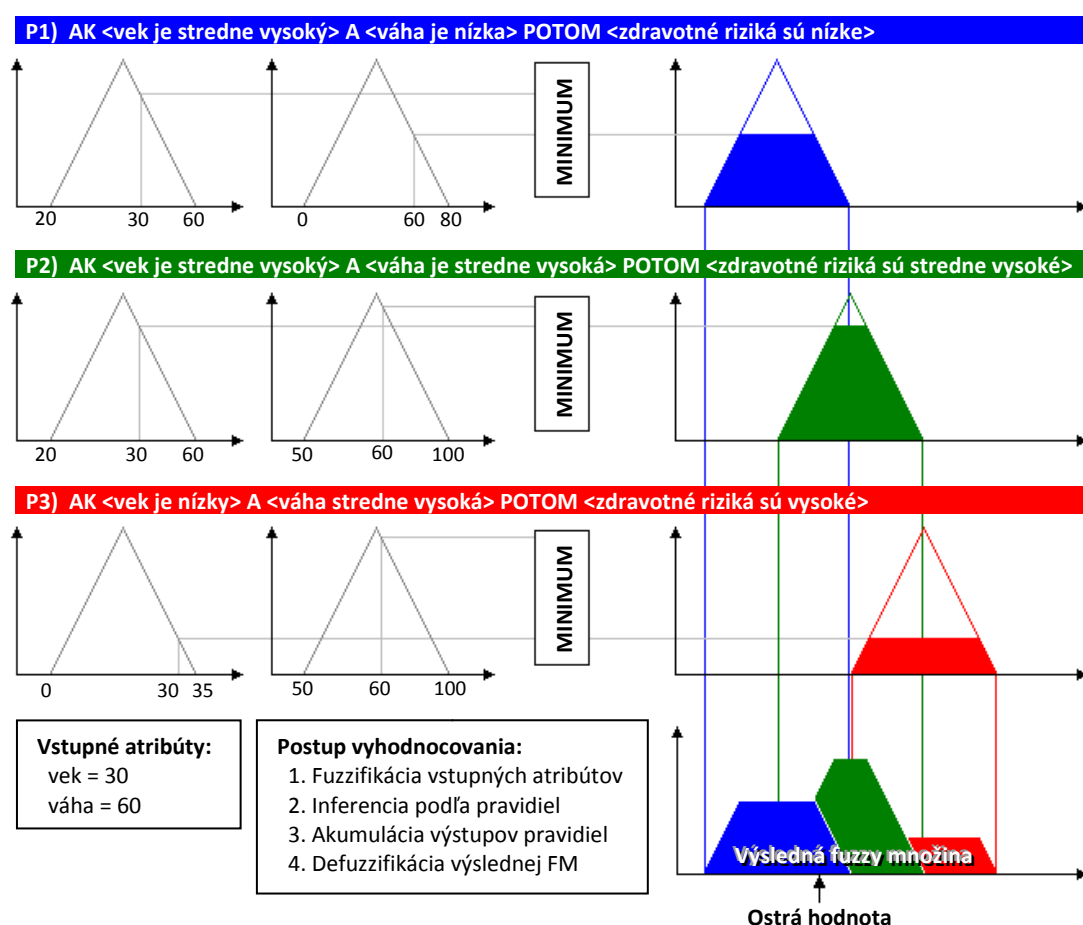
- AK <vek je vysoký> & <váha je vysoká> POTOM <zdravotné riziká sú vysoké>.

Každé fuzzy pravidlo obsahuje predpokladovú a dôsledkovú časť. Predpokladová časť priradzuje vstupné atribúty (t. j. ostré numerické hodnoty) k rôznym termom (malý, stredný, veľký) lingvistickej premennej (vek, výška, váha človeka) odpovedajúcej danému vstupnému atribútu. Dôsledková časť následne definuje LP výstupného atribútu a určuje konkrétny výstupný lingvistický term tejto LP.

Istota pravidla (resp. sila pravidla alebo „odpálenie pravidla“) závisí od stupňa príslušnosti vstupného atribútu k FM lingvistického termu použitej vstupnej LP. Problém nastáva, ak má pravidlo v predpokladovej časti viacero predpokladov, pričom každý z nich priradzuje vstupné atribúty do rôznych lingvistických termov s rôznym stupňom príslušnosti. V tomto prípade hodnota stupňa príslušnosti závisí od použitých operátorov (tzv. *T-noriem* a *T-konoriem*) realizujúcich logické spojky „a“ a „alebo“ v danom pravidle. Najčastejšie sa používa inferencia typu „min-max“, kde spojka „a“ je realizovaná operátorom minima a spojka „alebo“ operátorom maxima [22].

Vytvorenie sady fuzzy pravidiel je základom pre návrh *fuzzy inferenčných systémov* (FIS). Fuzzy inferenčný systém je vlastne množina produkčných pravidiel, ktorých výsledky sa určitým spôsobom sčítajú, resp. akumulujú (pozri Obr. 11). Zjednodušene povedané, FIS pre každý vstupný

atribút (resp. viaceré atribúty) formuje konkrétnu FM odpovedajúcu *výstupnému atribútu*, pričom konkrétne vstupné atribúty a výstupný atribút sú definované fuzzy pravidlami [22][23]. Presné určenie výstupnej FM závisí od samotných pravidiel, najmä od FM lingvistických termov v ich dôsledkových častiach, ale taktiež od istoty pravidiel. Výstupná FM určuje pravdepodobnosť výskytu výstupného atribútu naprieč celým univerzom. Najpravdepodobnejšia (ostrá) hodnota výstupného atribútu môže byť získaná defuzzifikáciou výslednej FM, pomocou rôznych prístupov, napr. na základe výpočtu ťažiska, maxima a iných. Vizualizácia inferencie fuzzy pravidiel vo FIS je zobrazená na Obr. 11.



Obr. 11 Vizualizácia inferencie fuzzy pravidiel.

Uvedený príklad inferenčného systému sa označuje aj ako *Mamdaniho FIS* a patrí medzi najstaršie typy FIS. Zároveň je základným prototypom pri návrhu ostatných odvodených typov FIS, napríklad Takagi-Sugeno-Kangov FIS (TSK) [24][25].

Štruktúra a spôsob inferencie pravidiel pri TSK FIS sú veľmi podobné ako u Mamdaniho FIS. Rozdiel je v tom, že výstupom pravidla nie je fuzzy množina, ale analytická funkcia, teda pravidlá zodpovedajú tvaru [22]:

- AK <atribút x_1 je vysoký> & <atribút x_2 je nízky> POTOM <výstup $u=f(x_1, x_2)$ >.

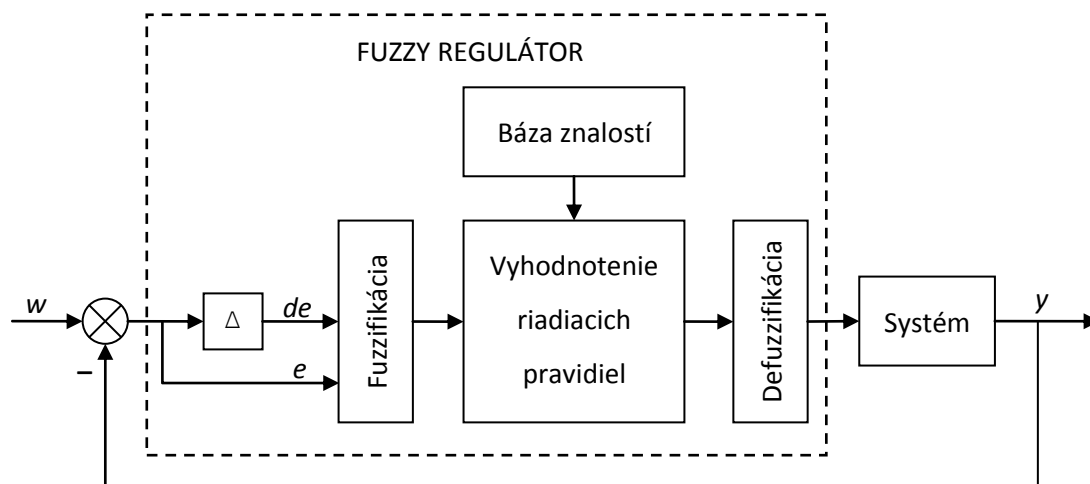
V prípade použitia väčšieho počtu pravidiel určujeme ich celkový výstup u ako vážený súčet [22]:

$$u = \frac{\sum_{i=1}^m \alpha_i u_i}{\sum_{i=1}^m \alpha_i}, \quad (10)$$

kde m je počet pravidiel, u_i je výstup i -tého pravidla a α_i je jeho istota

Výhodou TSK FIS je priamy výpočet hodnoty výstupného atribútu. Odpadá potreba defuzzifikácie, čím sa často podstatne zvyšuje rýchlosť výpočtov, čo je často veľmi dôležité. Na druhej strane, presná definícia analytických funkcií definujúcich výstupy pravidiel môže byť niekedy náročná.

FIS je v praxi možné použiť na riešenie rôznych úloh, napr. na tvorbu expertných systémov, klasifikátorov, prediktorov, nelineárnych aproximátorov, systémových modelov atď. Pre účely riadenia je možné použiť *fuzzy regulátory*. Bloková schéma fuzzy regulátora Mamdaniho typu je uvedená na Obr. 12.



Obr. 12 Štruktúra fuzzy regulátora.

Špeciálnym typom FIS sú napríklad aj fuzzy kognitívne mapy, ktorých štruktúra a spôsob inferencie sú veľmi podobné TSK. Ich výhodou je zjednodušenie zobrazenia pravidiel do grafickej podoby, ktorá je oproti explicitnému vyjadreniu zrozumiteľná a prehľadná aj pri relatívne veľkom počte pravidiel. Táto vlastnosť je veľmi dôležitá najmä pri modelovaní systémov s veľkým počtom vzájomných vplyvov a interakcií medzi jednotlivými prvkami. Fuzzy kognitívnym mapám sa detailne venuje kapitola 4.

3.2. Hybridné systémy UI v riadení

Hybridný systém je možné definovať ako systém, ktorý na vyriešenie abstraktného problému používa viac ako jednu metódu, resp. techniku. Na vytvorenie takýchto systémov je možné použiť rôzne spôsoby [5][26]:

- 1) *Sekvenčný hybridný prístup* predstavuje jednoduché sériové zapojenie dvoch subsystémov, kde výstup prvého subsystému sa stáva vstupom druhého. Ide o najslabšiu formu hybridizácie.
- 2) *Doplňkový hybridný prístup* využíva jeden subsystém na optimalizáciu parametrov druhého subsystému. Rovnako ako pri sekvenčnom prístupe, aj tu je možnosť jednoznačne rozlíšiť oba subsystémy. Úroveň hybridizácie je však v tomto prípade vyššia, pretože optimalizačný subsystém je tesne prepojený s optimalizovaným podsystémom.
- 3) *Prístup vzájomného zlúčenia* („Embedding“) predpokladá vzájomné zlúčenie oboch subsystémov. Tento prístup je možné pokladať za najvyššiu formu hybridizácie, pretože oba subsystémy sa už nedajú jednoznačne identifikovať.

Z hľadiska spôsobu realizácie sú hybridné systémy často navrhované ako decentralizované systémy. S ohľadom na hierarchiu usporiadania jednotlivých prvkov je potom možné rozlišovať dva základné prístupy [4]:

- 1) *Nehierarchický systém* (dekomponovaný), kde sú jednotlivé riadiace subsystémy priestorovo oddelené a zabezpečujú tak riadenie rôznych častí riadeného systému, bez koordinácie na hierarchicky vyššej úrovni.
- 2) *Hierarchicky decentralizovaný systém*, pri ktorom centrálny riadiaci člen určuje ktorý subsystém bude v danom časovom okamihu pri riadení použitý. Pri výbere konkrétneho subsystému môže byť použitá buď jednoduchá prepínacia podmienka [27] alebo zložitejšie rozhodovacie prístupy založené napr. na metódach multikriteriálneho rozhodovania alebo prostriedkoch umelej inteligencie.

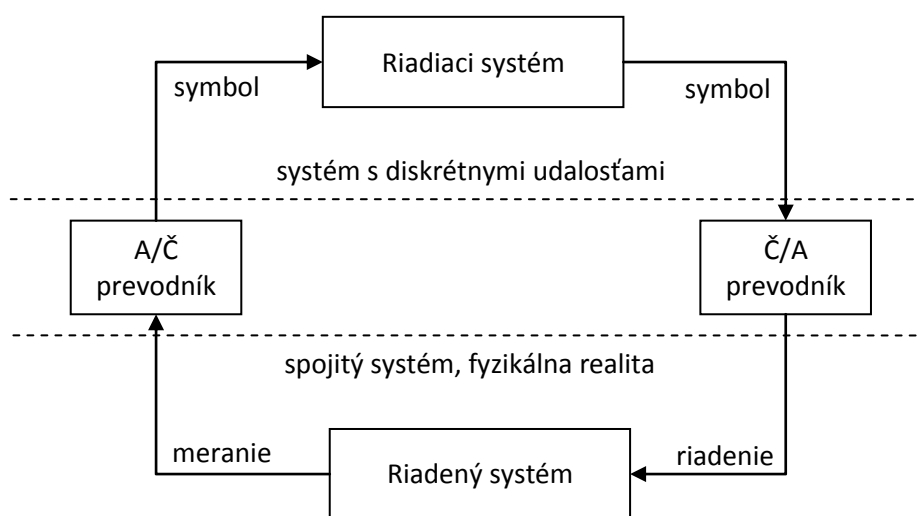
3.2.1. Hybridné systémy riadenia technických systémov

V súvislosti s *riadením* sa pojem *hybridný systém* používa pre označenie systémov, ktoré v sebe zahŕňajú spojitú aj diskretnú dynamiku. V tomto ponímaní majú hybridné systémy charakteristickú viacúrovňovú štruktúru, ktorá zahŕňa [1]:

- *dolnú úroveň* (technologickú) predstavujúcu spojitý systém, ktorý reprezentuje fyzikálnu realitu;

- *hornú úroveň* (rozhodovaciú/riadiacu), kde je použitý systém s diskretnými udalosťami, ktorý pri riadení aplikuje diskkrétne výpočtové metódy, vrátane prostriedkov výpočtovej inteligencie;
- *stykové rozhranie*, ktoré umožňuje konverziu signálov medzi vyššie uvedenými úrovňami pomocou číslicovo-analógových prevodníkov.

Schéma odpovedajúceho hybridného systému je zobrazená na Obr. 13. Uvedená viacúrovňová štruktúra vyhovuje požiadavkám kladeným na moderné digitálne systémy riadenia, ktoré predpokladajú využitie rôznych mechanických aj elektronických radiacích prvkov vrátane ich prepojenia s diskretnými výpočtovými systémami [1][5].



Obr. 13 Architektúra hybridného riadiaceho systému [1].

Okrem uvedenej definície hybridného systému je možné tento pojem použiť aj výhradne pri skúmaní kombinovaných radiacích systémov v rámci *hornej úrovne*. V ďalšej časti práce sa budeme venovať *hybridizácii prostriedkov UI*, ktoré môžu byť použité na tejto úrovni.

3.2.2. Hybridizácia prostriedkov výpočtovej UI


Hybridné systémy UI predstavujú skupinu algoritmov, ktoré spájajú rôzne prístupy. Môžu reprezentovať integráciu klasických metód riadenia s modernými prístupmi využívajúcimi prvky umelej inteligencie. Cieľom ich integrácie je snaha skĺbiť výhody jednotlivých metód. Prehľad výhod a nevýhod prostriedkov výpočtovej inteligencie v porovnaní s metódami symbolickej UI a algoritmami založenými na konvenčnej teórii riadenia je uvedený v Tab. 1 [28].

Tab. 1 Porovnanie výhod a nevýhod rôznych prostriedkov UI. Prevzaté z [28].

	FS	NS	EA	KTR	SUI
Kvalita matematického modelu	2	4	4	1	3
Schopnosť učenia	4	1	2	4	4
Kvalita reprezentácie znalostí	1	4	3	3	1
Kvalita expertných znalostí	1	4	4	3	1
Práca s nelinearitami	1	1	1	4	3
Schopnosť optimalizovať	4	2	1	3	4
Chybová tolerancia	1	1	1	4	4
Tolerancia neurčitosti	1	1	1	4	4
Práca v reálnom čase	1	2	3	1	4

Vysvetlivky k tabuľke: FS – fuzzy systémy, NS – umelé neurónové siete, EA – evolučné algoritmy, KTR – konvenčná teória riadenia, SUI – symbolická umelá inteligencia. Nižšia hodnota znamená lepšie hodnotenie (podobne ako pri známkovaní v škole).

V ďalšom sa sústreďíme na možnosti hybridizácie jednotlivých prostriedkov výpočtovej inteligencie, teda neurónových sietí, fuzzy systémov a evolučných algoritmov (pozri Obr. 14). Z hľadiska riadenia sa ako najvhodnejšia javí možnosť prepojenia NS a FIS, pretože obe metódy integrujú inferenčné systémy schopné vykonávať transformáciu riadiacich signálov. Spojením týchto prístupov vznikajú hybridné neuro-fuzzy systémy.



Obr. 14 Možnosti hybridizácie prostriedkov výpočtovej UI. Prevzaté z [1].

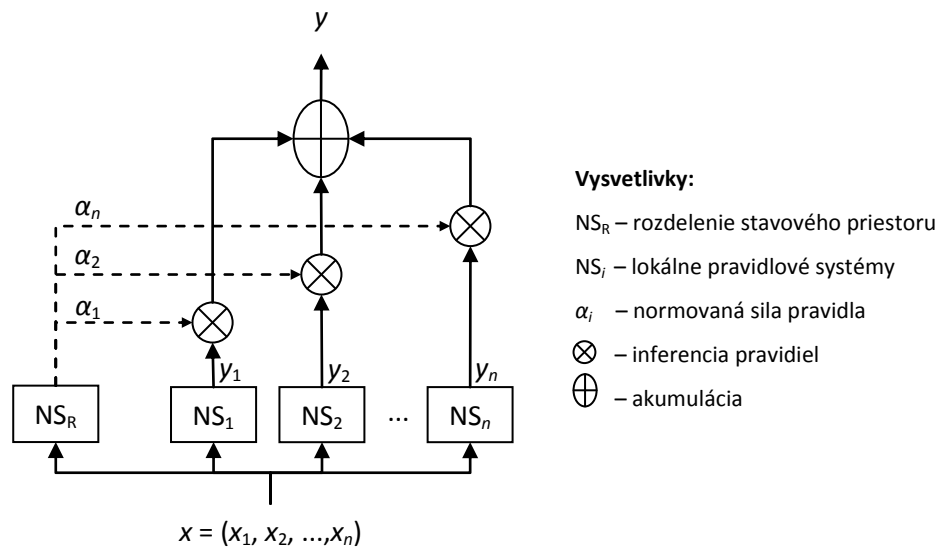
EA ako optimalizačný prostriedok sú však veľmi často používané ako alternatíva k nastavovaniu parametrov ako NS tak aj FIS. Pri FIS je možné použiť EA za účelom automatického generovania pravidiel do bázy znalostí, čo je obzvlášť vhodné v prípade, že expertné znalosti potrebné na riešenie problému nie sú dostupné. V prípade použitia pri adaptácii parametrov NS sú EA

potenciálnou náhradou ku konvenčnému kontrolovanému učeniu pomocou metódy spätného šírenia chyby.

3.2.2.1. Neuro-fuzzy systémy

Univerzálna aproximačná teoréma hovorí, že ako NS, tak aj FIS, sú schopné aproximovať ľubovoľnú funkciu. Nie vždy je však evidentné, aký počet pravidiel alebo neurónov postačuje na riešenie konkrétneho aproximačného problému. Určenie potrebného počtu (buď pravidiel, alebo neurónov) je často možné zjednodušiť kombináciou NS a FIS do vhodnej hybridnej štruktúry. Spojenie FIS a NS je možné realizovať rôznymi spôsobmi. Známe sú predovšetkým nasledovné možnosti [1]:

- 1) V prípade, že fuzzy logika je implementovaná do neurónov, vznikajú tzv. **fuzzy neuróny**. Táto modifikácia umožňuje NS spracovať neurčitost'. Poznatky uložené v takto fuzzifikovanej NS je možné považovať za abstraktnejšie, keďže sieť nie je obmedzená na prácu z ostrými hodnotami.
- 2) Možný je ale aj presne opačný prístup, t. j. **realizácia FIS pomocou NS**. Ak je takto zrealizovaný napríklad fuzzy regulátor, potom má schopnosť učiť sa alebo automaticky skonštruovať svoju bázu znalostí. Nevýhody FIS sú kompenzované použitím NS. Najznámejšími architektúrami tohto typu sú ANFIS, FALCON, resp. NARA (pozri Obr. 15).
- 3) NS môže byť použitá ako prostriedok na **generovanie bázy pravidiel** pre fuzzy regulátor (ak je možné použiť kontrolované učenie). Príkladom takéhoto prepojenia je adaptívny fuzzy regulátor AFAM (Adaptive Fuzzy Associative Memory).
- 4) Ďalšou možnosťou interakcie je použitie fuzzy regulátora na **adaptáciu učiacich parametrov NS** v podľa aktuálnej potreby v priebehu procesu učenia. Vhodná zmena učiacich parametrov v rôznych štádiách učenia umožňuje rýchlejšiu konvergenciu parametrov neurónovej siete k optimálnym hodnotám.
- 5) Okrem toho je možné aj vytvorenie **hybridných systémov**, v ktorých NS aj FIS sú navzájom oddelené a plnia samostatné úlohy. Môžu byť zapojené paralelne, kedy sa ich výstupy navzájom kombinujú alebo modifikujú. Taktiež môžu byť zapojené sériovo, kedy výstup jedného zo systémov je vstupom druhého.



Obr. 15 NARA – Neural-network designed on Approximate Reasoning Architecture.

3.2.2.2. Neuro-evolučné systémy

Použitie EA pri učení NS, resp. *neuro-evolúcia* [29], je alternatívou ku konvenčným učiacim algoritmom založeným na kontrolovanom učení, ktoré nevyhnutne potrebujú trénovacie dáta definujúce korešpondujúce vstupy a výstupy aproximovanej funkcie. Keďže EA takéto trénovacie dáta nepotrebujú, môžu byť použité v oveľa širšom rozsahu aplikácií. Jediným predpokladom je schopnosť definovať kritériálnu funkciu určujúcu vhodnosť jedincov reprezentujúcich parametre NS. Príkladom možnej aplikácie je napríklad hra, kde výsledok (výhra alebo prehra) môže byť jednoducho určený bez potreby trénovacích vzoriek vhodných herných stratégií.

Existuje veľké množstvo rôznych neuro-evolučných algoritmov. Základné rozdelenie z pohľadu adaptácie štruktúry NS je nasledovné:

- *Evolúcia NS s fixnou topológiou*, kde štruktúra NS je nemenná a adaptujú sa iba váhy na prepojeniach medzi neurónmi.
- *Evolúcia topológie aj váh NS* (TWEANN – „Topology & Weight Evolving Artificial Neural Network algorithm“), pri ktorej je možná aj zmena štruktúry NS.

Z pohľadu spôsobu zakódovania parametrov NS (fenotyp) do genotypu jedinca je možné rôzne prístupy rozdeliť na [30]:

- *Priame zakódovanie parametrov NS* („direct encoding“), ktoré predpokladá priame mapovanie fenotypu na genotyp a opačne. Teda všetky neuróny a prepojenia v NS sú v genotype jedinca špecifikované explicitne.

- *Nepriame zakódovanie parametrov NS („indirect encoding“)*, pri ktorých genotyp jedinca výslovne nešpecifikuje štruktúru NS, ale iba nepriamo definuje spôsob jej konštrukcie. Tento spôsob je výhodný najmä pri použití TWEANN algoritmov na návrh rekurentných neurónových sietí, kde sa jednotlivé štruktúry NS môžu opakovať. Ďalšou výhodou je kompresia fenotypu na menší genotyp, čím sa znižuje veľkosť prehľadávaného priestoru a v konečnom dôsledku aj rýchlosť konverencie EA k optimálnym hodnotám.

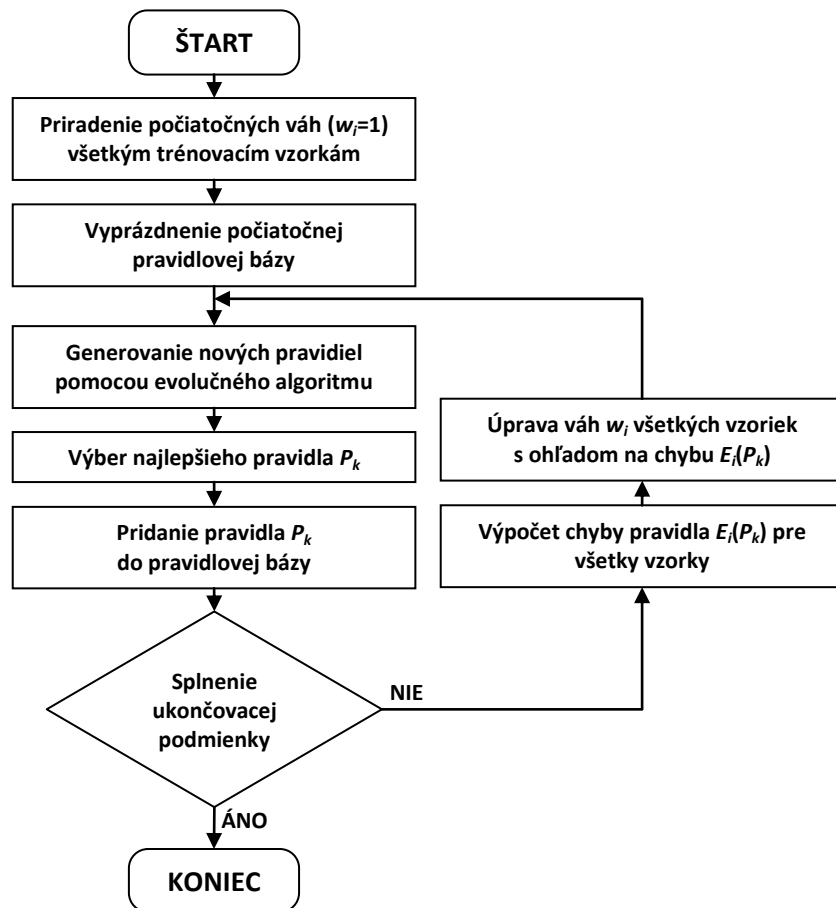
3.2.2.3. Fuzzy-evolučné systémy

Pri kombinácii s fuzzy systémami sú EA alternatívou k tvorbe bázy pravidiel FIS pomocou expertných znalostí. Na tento účel je možné použiť EA, kde každý jedinec v populácii predstavuje jedno fuzzy pravidlo. Nové pravidlá sa získavajú evolúciou počiatočnej bázy náhodne vygenerovaných pravidiel. Vždy po určitom počte generácií je najlepší jedinec z populácie zaradený do finálnej pravidlovej bázy.

Príkladom prepojenia FIS a EA je napríklad *príznaky vyberajúci lingvistický klasifikátor* (Feature Selective Linguistic Classifier – FeSLIC) [31], čo je vlastne genetický fuzzy-pravidlovo založený klasifikačný systém (Genetic Fuzzy Rule-Based Classification System – GFRBCS) vytvorený pomocou prístupu iteratívneho učenia pravidiel (Iterative Rule Learning – IRL).

Metóda IRL rieši problematiku tvorby bázy pravidiel postupným pridávaním jedného pravidla za druhým pomocou opakovaného spúšťania genetického algoritmu. Na určenie vhodnosti pravidiel je použitá množina vzoriek trénovacích dát. Vždy keď je vyprodukované nové pravidlo, trénovacie vzorky, ktoré sú ním dostatočne pokryté, sú z trénovacej množiny odstránené, takže novo vytvorené pravidlá sa môžu zamerať na správnu klasifikáciu ostatných vzoriek. Tento spôsob však môže viesť ku tvorbe konfliktných pravidiel, keďže pravidlá vytvorené v neskorších štádiách behu algoritmu neberú v úvahu predtým odstránené trénovacie vzorky [31].

Riešením tohto problému je použitie algoritmu AdaBoost [32], ktorý je vhodný pre tvorbu bázy pravidiel pomocou IRL [33]. AdaBoost (pozri Obr. 16) priradzuje každej trénovacej vzorke príslušnú váhu reprezentujúcu jej relatívnu dôležitosť pri ďalšom učení. Vždy keď je vyprodukované nové pravidlo, váhy u tých vzoriek, ktoré boli klasifikované správne, sú znížené, čo umožňuje novým pravidlám koncentrovať sa na nesprávne klasifikované vzorky. Keďže však žiadna zo vzoriek nie je z trénovacej množiny odstránená úplne, novo vytvorené pravidlá sú si vedomé predchádzajúco odvodených, čo obmedzuje tvorbu konfliktných pravidiel.



Obr. 16 Algoritmus iteratívneho generovania pravidiel AdaBoost.

Výhodou evolučne generovaných pravidlových systémov oproti expertnému návrhu je zautomatizovanie a urýchlenie procesu návrhu FIS. Nevýhodou je často nižšia miera čitateľnosti a veľký počet vygenerovaných pravidiel. Využitím dodatočných optimalizačných metód [31] je však možné tieto nedostatky do určitej miery redukovať, napríklad odstránením redundantných pravidiel alebo odfiltrovaním nadbytočných klauzúl v predpokladových častiach pravidiel.

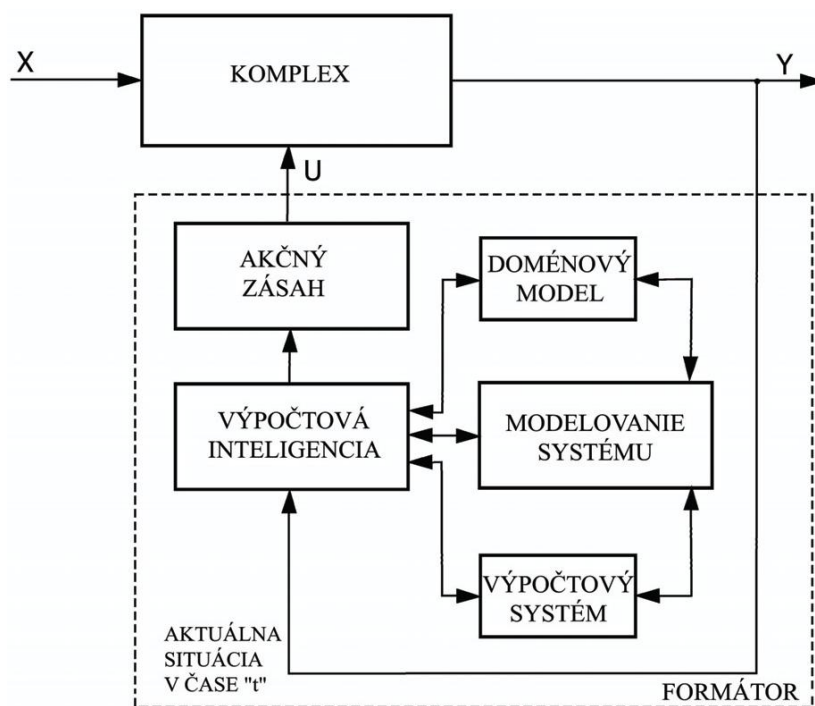
3.3. Využitie prostriedkov UI v situačnom riadení a modelovaní

Jedným z cieľov situačného riadenia je riadenie systému v každom prevádzkovom stave. Okrem riadenia objektu v normálnych prevádzkových podmienkach je nevyhnutné zabezpečiť aj riadenie v poruchových situáciách. Pri určovaní neštandardných stavov počas operatívneho riadenia je rozhodujúca schopnosť správne diagnostikovať riadený ZS. Pri plánovaní riadenia je navyše dôležitá tvorba vhodných situačných modelov ZS v súvislosti s potrebou predikcie a prognózovania stavu ZS. Práve v týchto oblastiach sa očakáva výrazný príspevok adaptívnych algoritmov a inteligentných metód [5].

Pri adaptácii parametrov radiacich algoritmov je zreteľná možnosť využitia evolučných prístupov. Evolučné prístupy je možné použiť napríklad pri cielenej zmene štruktúry ZS. Dôsledok tejto zmeny sa následne v rámci danej situácie vyhodnotí. Ak je zmena prospešná, je možné ju zakomponovať do ďalšej generácie použiteľných štruktúr riadenia [5].

SR je možné realizovať viacerými kooperujúcimi subsystémami, ktoré sa podieľajú na riadení celého ZS v danej situácii. Kooperatívne riadenie môže byť tiež realizované na viacerých úrovniach s rôznymi stupňami kooperácie a komunikácie medzi jednotlivými subsystémami [34]. V tejto oblasti je perspektívne použitie NS a FIS, resp. hybridných neuro-fuzzy systémov, ktorými sú napr. aj fuzzy kognitívne mapy (kapitola 4).

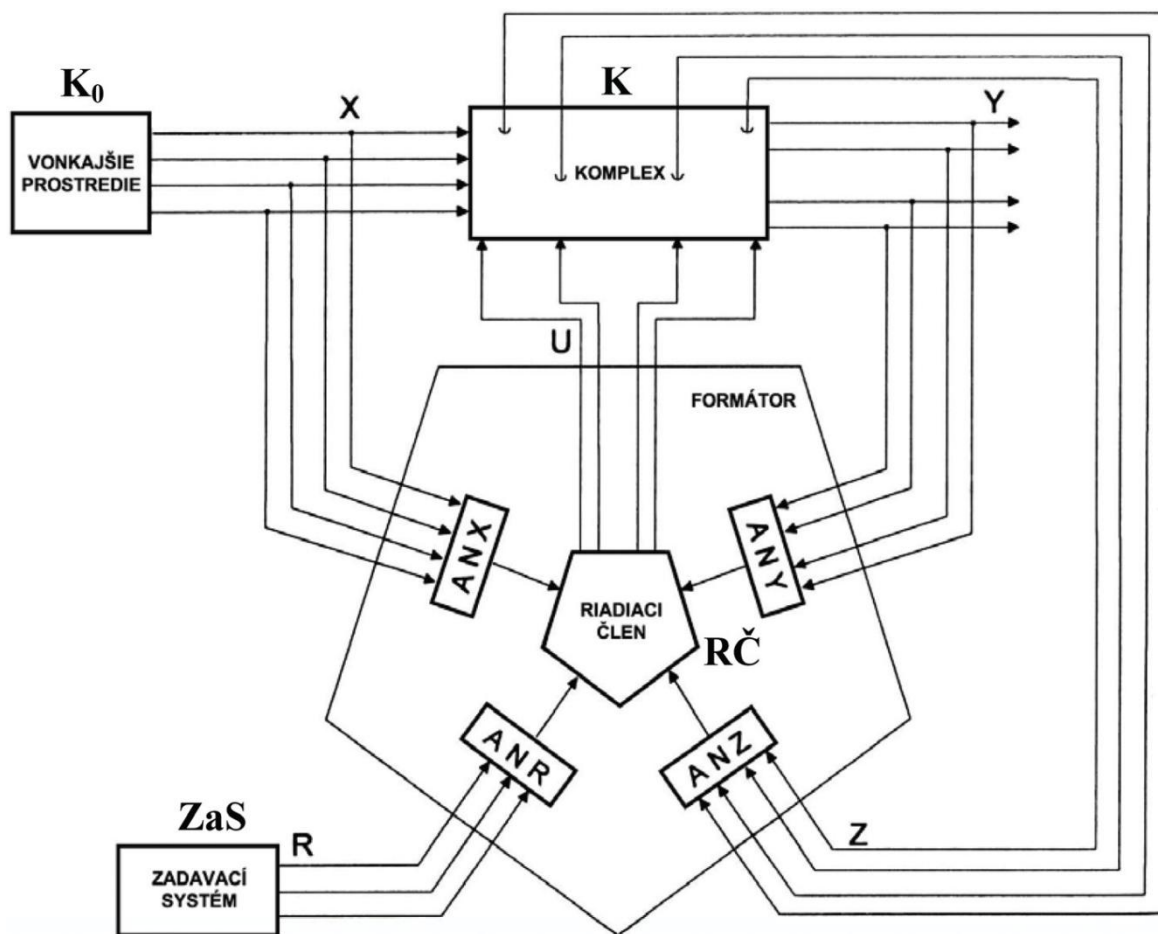
Zásady spolupráce medzi subsystémami je možné určiť rámcovým riadením z pozície nadriadeného radiaceho člena – *formátora*. Formátor vykonáva hrubé riadenie ZS prostredníctvom situačného riadenia, teda prideluje riadenie jednotlivým subsystémom v závislosti od aktuálnej situácie v ktorej sa ZS nachádza [34]. Na Obr. 17 je uvedená schéma modelu situačného riadenia *formátorom* s predpokladom využitia prostriedkov UI.



Obr. 17 Perspektívny model situačného riadenia zahŕňajúci prostriedky UI. Prevzaté z [1].

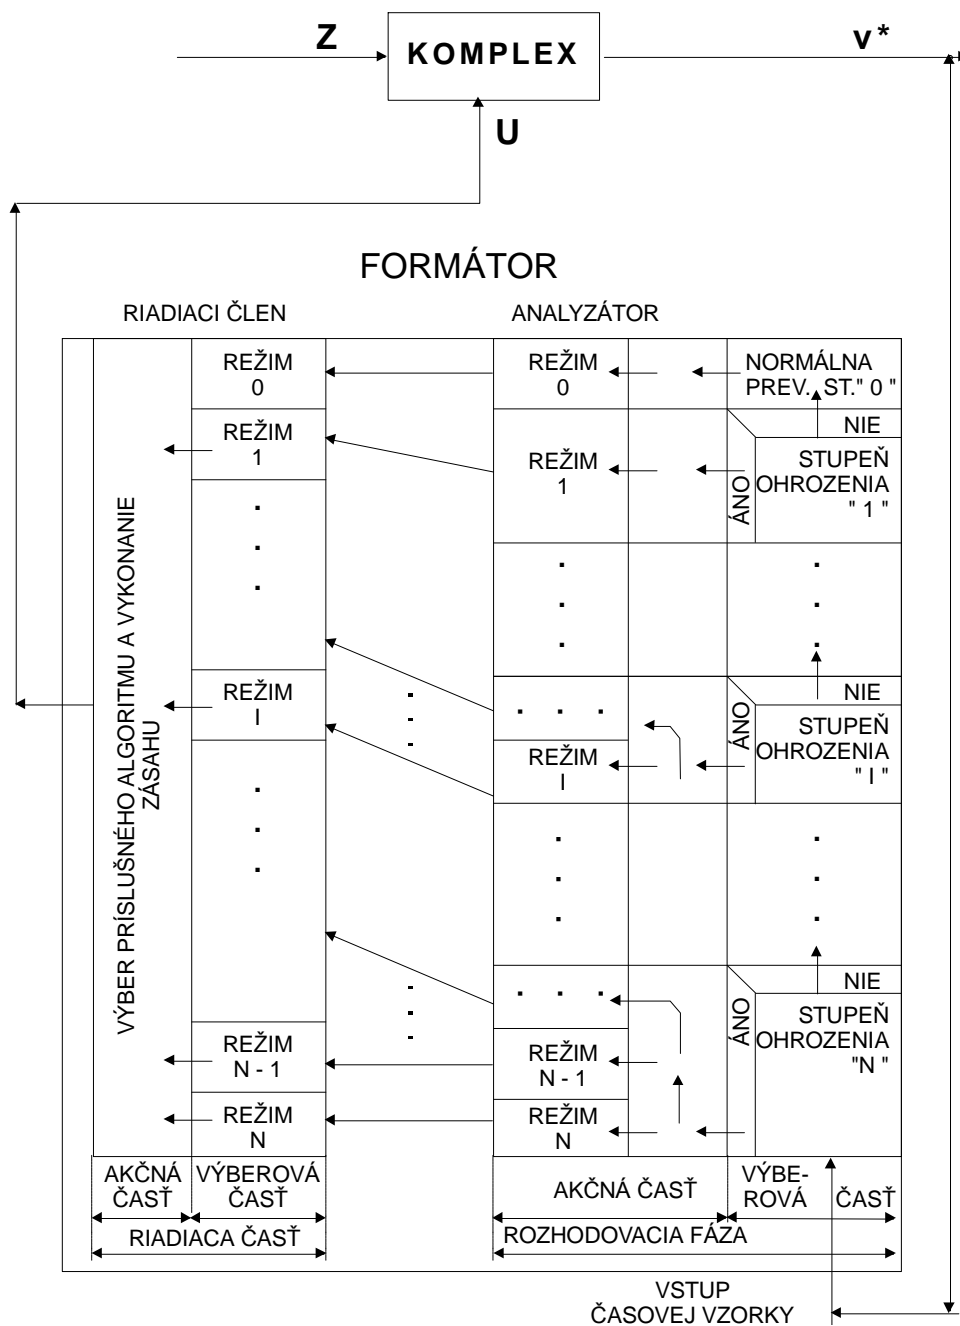
Formátor je vo všeobecnosti radiaci systém, ktorý riadi funkciu a formu (vonkajší tvar a vnútornú štruktúru) zložitého systému (komplexu) [35]. Jeho všeobecná štrukturálna schéma je uvedená na Obr. 18. Môže byť implementovaný jedným počítačom, alebo byť decentralizovaný v sieti viacerých počítačov. Spravidla je súčasťou spätno-väzobného obvodu s riadeným ZS, kde

pomocou spätnej väzby získava informácie o riadenom systéme, konkrétne vektory vstupných veličín X , výstupných veličín Y a vnútorných stavových veličín Z . Zo zadávacieho systému (ZaS), ktorý určuje ciele riadenia, do formátora navyše vstupuje vektor riadiacich veličín R . Jednotlivé súbory veličín sú analyzované príslušnými analyzátormi (ANX, ANY, ANR, ANZ). Analyzátory transformujú a redukovujú prijímané informácie (môžu napr. vykonávať situačnú klasifikáciu). Výsledky ich analýz sú odovzdávané riadiacemu členu (RČ), ktorý rozhoduje o riadení aplikovanom na ZS vo forme akčných veličín U [1].



Obr. 18 Štruktúrna schéma formátorového riadenia. Prevzaté z [1].

Okrem zobrazenia štruktúrnej schémy formátora je možné popísať aj jeho funkčné procesy, ktoré odpovedajú metodike situačného riadenia (kapitola 2.4.1). Funkcionálny model formátora je zobrazený na Obr. 19.



Obr. 19 Funkcionálny model situačného riadenia formátorom. Prevzaté z [7].

Činnosť formátora (resp. analyzátorov a riadiaceho člena) pozostáva z *rozhodovacej* a *riadiacej* fázy, pričom každá je rozdelená na *výberovú* (klasifikačnú) a *akčnú* časť. Z tohto dôvodu riadiaci proces prebieha v štyroch etapách [6]:

- 1) Spracovaná *situácia* sa analyzuje vo *výberovej časti rozhodovacej fázy*. Podľa výsledku analýzy sa priraduje do jednej z N situačných tried. Každá situačná trieda má k dispozícii istý súbor riadiacich algoritmov.

- 2) Počas *akčnej časti rozhodovacej fázy* sa aktivuje súbor *algoritmov* najvhodnejších na spracovanie danej situácie.
- 3) V priebehu *výberovej časti riadiacej fázy* sa vybrané algoritmy prispôsobia (*parametrizujú*) pre riešenie príslušnej situácie.
- 4) Realizácia *riadiacej činnosti* nastáva v *akčnej časti riadiacej fázy*.

Uvedený model realizácie situačného riadenia vo forme formátorového riadenia je vhodný pri použití inteligentných metód [5]. Na jeho základe je možné vypracovať konkrétnu realizáciu riadiaceho systému situačného riadenia vrátane definície jednotlivých akčných a rozhodovacích prvkov implementovaných pomocou prostriedkov UI [5]. S ohľadom na vlastnosti jednotlivých prostriedkov výpočtovej inteligencie je možné konštatovať, že NS a FIS sú uplatniteľné najmä v úlohe analyzátorov jednotlivých stavových veličín, napríklad pri situačnej klasifikácii. Ich použitie je možné taktiež pri implementácii konkrétnych riadiacich algoritmov. EA je možné nakoniec použiť pri parametrizácii týchto riadiacich algoritmov.

4. Fuzzy kognitívne mapy

„Málokto je schopný nevzrušene a nahlas prejavíť názor, ktorý je v protiklade s predsudkami ostatných. Väčšina ľudí sa k takému názoru ani nedopracuje.“

Albert Einstein

Fuzzy kognitívne mapy (FKM) sú široko využívaným inferenčným nástrojom pre modelovanie kvalitatívnych i kvantitatívnych komplexných vzťahov, v rámci širokého spektra rôznych technických i netechnických systémov, a to jednoduchým a zrozumiteľným spôsobom. V poslednej dekáde hrali FKM významnú úlohu pri aplikáciách v mnohých oblastiach vedeckého výskumu, ako sú spoločenské a politické vedy, inžinierstvo, informačné technológie, robotika, expertné systémy, medicína, vzdelávanie, predikcia, životné prostredie a ďalších. Rozsiahla prehľadová štúdia [36] významných osobností v oblasti výskumu FKM, prof. E. I. Papageorgiou a prof. J. L. Salmerona, zaraďuje medzi typické aplikačné oblasti FKM nasledujúce odvetvia:

- riadenie – predikcia, interpretácia, monitorovanie,
- biznis – plánovanie, manažment, rozhodovanie, inferencia,
- medicína – podpora rozhodovania, modelovanie, predikcia, klasifikácia,
- robotika – navigácia, učenie, predikcia,
- životné prostredie – reprezentácia, odvodzovanie znalostí a uvažovanie, tvorba politík,
- informačné technológie – modelovanie, analýza.

Rovnaká štúdia analyzuje aj dôvody vedúce k tak širokej aplikovateľnosti FKM v rôznych oblastiach. Za hlavné predpoklady, ktoré podporujú využívanie FKM pokladá najmä [36]:

- jednoduchosť návrhu a určenia parametrov,
- flexibilitu reprezentácie (je možné jednoducho pridávať/odoberať nové koncepty),
- jednoduchosť použitia, zrozumiteľnosť a transparentnosť pre netechnických expertov,
- nízku výpočtovú náročnosť,
- zvládnutie dynamických efektov vďaka spätno-väzobnej štruktúre.


Z týchto dôvodov je umožnené jednoduché a intuitívne vytváranie systémových modelov aj netechnickým pracovníkom a laikom. Pre porovnanie, pri iných metódach, akými sú napr. bayesovské siete (BS) alebo petriho siete (PS), nie je pre neznaleho človeka evidentné akým spôsobom vytvárať spomínané systémové modely [37][38]. FKM okrem toho umožňujú aj súčasné zapojenie viacerých expertov do procesu tvorby systémového modelu, pretože je jednoduché

kombinovať rôzne čiastkové FKM vytvorené jednotlivcami do zložitejších štruktúr. Na druhej strane, v prípade PS takáto možnosť neexistuje, pretože nie pevne stanovené, akým spôsobom možno spájať rôzne PS popisujúce ten istý systém [37][38].

V nasledujúcich podkapitolách uvedieme základné definície FKM a pozrieme sa na spôsob inferencie a výpočtov pri ich využití. Taktiež načrtneme základné problémy, na ktorých riešenie sú FKM aplikovateľné. V závere kapitoly uvedieme možnosti automatizovaného nastavovania parametrov FKM pomocou rôznych dostupných metód strojového učenia.

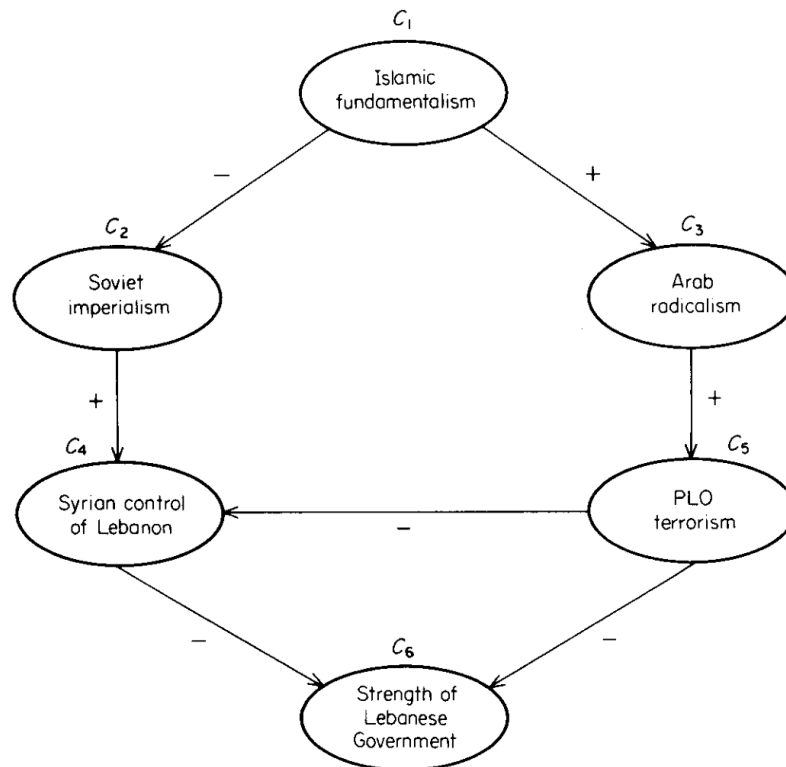
4.1. Jednoduché kognitívne mapy

Vo všeobecnosti je kognitívna mapa (KM) [39] orientovaný graf (pozri Obr. 20), kde uzly reprezentujú koncepty (resp. pojmy) a hrany určujú ich vzájomné kauzálne vzťahy. Koncepty zvyčajne určujú stavy a hrany sú akcie alebo prenosové funkcie, ktoré transformujú stav jedného uzla na iný stav v ďalšom uzle. Účinky vzťahov medzi konceptami sú zvyčajne sú definované trivalentne, teda troma ostrými (crisp) hodnotami -1, 0 a 1 [40].



Obr. 20 Jednoduchá kognitívna mapa.

Vďaka svojej cyklickej štruktúre sú KM schopné popisovať komplexné dynamické systémy. Je možné skúmať napr. limitné cykly systému [41], kolízie atď. Azda najväčšou výhodou KM je ich jednoducho zrozumiteľná reprezentácia znalostí, ktorá sa dá názorne vizualizovať v grafickej podobe [40]. Názornou ukážkou využitia KM môže byť napríklad Obr. 21, ktorý modeluje vplyvy na politickú situáciu v Libanone začiatkom 80. rokov 20. storočia [42]. Keďže dizajn takejto mapy je veľmi jednoduchý a intuitívny, je zrejmé, že KM je vhodným prostriedkom pre rýchle prototypovanie systémových modelov.




Obr. 21 Kognitívna mapa využitá na zobrazenie politickej situácie v Libanone skonštruovaná na základe článku Henryho A. Kissingera „Starting Out in the Direction of Middle East Peace“ (Los Angeles Times, 1982). Prevzaté z [42].

Nevýhodou KM s ostrými hodnotami je obmedzená schopnosť modelovania zložitejších vzťahov medzi konceptmi. Aj z tohto dôvodu bola základná koncepcia KM rozšírená, v čoho dôsledku vznikli fuzzy kognitívne mapy.

4.2. Fuzzy kognitívne mapy

Fuzzy kognitívne mapy (FKM) ako rozšírenie klasických KM navrhol Kosko [42] v roku 1986. FKM sú (rovnako ako klasické KM) orientované grafy, ktoré modelujú systém a jeho správanie použitím konceptov a ich vzájomných vzťahov, ktoré môžu byť pozitívne, negatívne alebo nulové [40][43][44]. FKM (oproti klasickým KM) však navyše zohľadňujú stupeň vplyvu (resp. váhu) týchto vzťahov vyjadrený príslušnou hodnotou zo spojitého intervalu $[-1,1]$ (pozri Obr. 22).



Obr. 22 Fuzzy kognitívna mapa.

Okrem zobrazenia FKM vo forme grafu je možné použiť aj reprezentáciu vzťahov medzi konceptmi s využitím tzv. *matice prepojení konceptov*, resp. *matice váh* W . Zobrazenie vo forme matice je výhodné pri výpočtoch prostredníctvom tabuľkových editorov (napr. Excel) ale aj iných programov podporujúcich výpočty pomocou matíc (napr. Matlab). Pre FKM na Obr. 22 je príslušná matica W určená nasledovne:

$$W_{FKM} = \begin{matrix} & \begin{matrix} C_1 & C_2 & C_3 & C_4 & C_5 \end{matrix} \\ \begin{matrix} C_1 \\ C_2 \\ C_3 \\ C_4 \\ C_5 \end{matrix} & \begin{pmatrix} 0 & 0,28 & 0 & 0 & -0,13 \\ 0 & 0 & -0,35 & 0 & 0 \\ 0 & 0 & 0 & 0,45 & 0,93 \\ 0 & 0,83 & 0 & 0 & 0 \\ -0,18 & 0 & 0 & -0,67 & 0 \end{pmatrix} \end{matrix} \quad (11)$$

Všimnime si, že štruktúra a možné formy zápisu FKM (graf, resp. matica) plne korešpondujú s požiadavkami na popis štruktúry ZS, v súlade s predpokladmi uvedenými v kapitole 2.1.

4.3. Formálna definícia FKM

Pre uľahčenie čitateľnosti textu sme doposiaľ uvádzali iba veľmi voľné definície KM a FKM. Pre úplnosť je však možné uviesť aj formálnejšiu matematickú definíciu. Takýchto definícií FKM existuje viacero, ale obvykle používaná je definícia Chena [45], kde FKM je definovaná ako štvorica [40]:

$$FKM = (C, W, \alpha, \beta) \quad (12)$$

kde:


- $C = \{C_1, C_2, \dots, C_n\}$ je konečná množina kognitívnych jednotiek (konceptov),
- $W = \{w_{11}, w_{12}, \dots, w_{nm}\}$ je konečná množina orientovaných prepojení medzi konceptami,
- $\alpha \rightarrow \langle 0, 1 \rangle$ je mapovanie reálnej hodnoty na stupeň príslušnosti v koncepte (fuzzifikácia),
- $\beta \rightarrow \langle -1, 1 \rangle$ má podobný význam ako α , ale určuje mapovanie hrán, resp. váh.

Koncept C_i ($i = 1, 2, \dots, n$) indikuje stav, procedúru, udalosť alebo premennú systému [44] a jeho hodnota je z intervalu $\langle 0, 1 \rangle$ (resp. v závislosti od implementácie z intervalu $\langle -1, 1 \rangle$). Priama väzba (prepojenie) medzi konceptami C_i a C_j určuje kauzalitu medzi týmito konceptami a je reprezentovaná váhou w_{ij} , ktorá je určená fuzzy hodnotou z intervalu $\langle -1, 1 \rangle$. Pre váhu w_{ij} môžeme rozlišovať tri možnosti [44]:

- *váha má kladnú hodnotu* ($w_{ij} > 0$), teda zvýšenie (zníženie) hodnoty konceptu C_i vedie k zvýšeniu (zníženiu) hodnoty konceptu C_j .
- *váha má zápornú hodnotu* ($w_{ij} < 0$), teda zvýšenie (zníženie) hodnoty konceptu C_i vedie k zníženiu (zvýšeniu) hodnoty konceptu C_j .
- *váha má nulovú hodnotu* ($w_{ij} = 0$), čo znamená, že medzi hodnotami konceptov C_i a C_j nejestvuje žiaden vzťah.

4.4. Výpočet aktivačnej hodnoty konceptu

Všeobecné pravidlo pre určenie hodnoty konceptu C_j v každom simulačnom kroku je výpočet vplyvu ostatných konceptov C_i (kde $i = 1 \dots m$), ktoré sú pripojené ku konceptu C_j (pozri Obr. 23).



Obr. 23 Výpočet aktivačnej hodnoty konceptu C_j závisí od hodnôt predchádzajúcich konceptov C_i .

Ak $A_j(t)$ je hodnota konceptu C_j v čase t , potom hodnota $A_j(t+1)$ konceptu C_j v čase $t+1$ bude pod vplyvom hodnôt $A_i(t)$ ostatných konceptov C_i v čase t určená nasledovne [44]:

$$A_j(t+1) = p \left(A_j(t) + \sum_{i=1; i \neq j}^n w_{ij} A_i(t) \right) \quad (13)$$

pričom w_{ij} sú váhy na prepojeniach medzi konceptami C_i a konceptom C_j . Prahová funkcia p obmedzuje výsledok na hodnoty z intervalu $<-1,1>$ [44]. Správanie FKM výrazne závisí od použitej prahovej funkcie [43]. Medzi často používané prahové funkcie $p(x)$ patria [43]:

- bivalentná:

$$p(x) = \begin{cases} 0; & x \leq 0 \\ 1; & x \geq 0 \end{cases}, \quad (14)$$

- trivalentná:

$$p(x) = \begin{cases} -1; & x \leq -0,5 \\ 0; & -0,5 \leq x \leq 0,5 \\ +1; & x \geq 0,5 \end{cases}, \quad (15)$$

- logistická (sigmoidálna):

$$p(x) = \frac{1}{1 + e^{-mx}} \quad (16)$$

V súčasnosti sú najčastejšie používané práve sigmoidálne prahovacie funkcie, resp. iné spojité funkcie, ktorých výsledok je v intervale $<0,1>$. Tento interval je významný najmä pri transformácii reálnych hodnôt (napr. senzorických signálov, fyzikálnych veličín, štatistických hodnôt atď.) na stupne príslušnosti v danom koncepte (tj. fuzzifikácii).


4.5. Základné problémy riešiteľné pomocou FKM

Podľa [46] sú FKM vhodné na riešenie dvoch hlavných tried úloh, ktorými sú:

- 5) tvorba **regresného modelu** systému,
- 6) **zakódovanie atraktora** k vybranému cieľovému stavu systému.

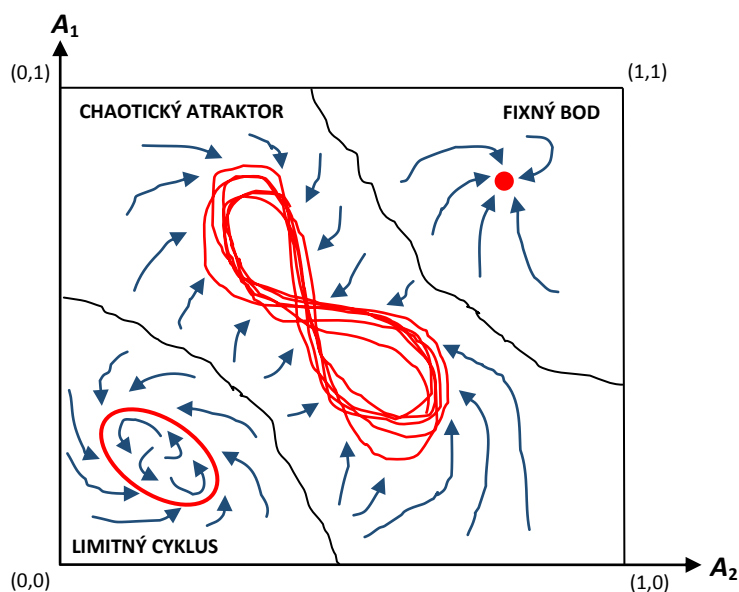
Úloha prvého typu (regresia) je najfrekvencovanejšou úlohou, na riešenie ktorej sa FKM využívajú. Jej cieľom je nastaviť parametre FKM (ktorými sú zvyčajne váhy na prepojeniach medzi konceptmi) s cieľom vytvorenia odpovedajúceho modelu reálneho systému. Konvenčné FKM sa najčastejšie používajú pri modelovaní uzavretých systémov bez vonkajších vstupov (pozri Obr. 24). Po určitej modifikácii štruktúry a výpočtového procesu FKM je však rovnako možné modelovať aj

otvorené systémy [47]. Najdôležitejšou zmenou je zavedenie špeciálnych *vstupných konceptov*, ktoré reprezentujú ruchy a šumy z okolitého prostredia, resp. riadiace signály [47].



Obr. 24 Model výmenníka tepla realizovaný pomocou FKM. Prevzaté z [48].

Úloha druhého typu (definovanie atraktora [41], pozri Obr. 25) sa dotýka oblastí určovania stability (a v konečnom dôsledku aj riadenia) FKM. Cieľom tejto úlohy je zakódovať do parametrov FKM schopnosť konverencie z ľubovoľného počiatočného stavu do žiadaného cieľového stavu, pričom tento stav je určený špecifickými hodnotami vybranej skupiny *riadených konceptov*. Inak povedané, snažíme sa nájsť také hodnoty parametrov FKM, pri ktorých systém reprezentovaný danou FKM dospeje z rôznych počiatočných podmienok do žiadaného konečného stabilného stavu, resp. limitného cyklu [41]. V tomto prípade nemusíme nevyhnutne nastavovať všetky parametre FKM, pretože model systému môže byť vopred daný. Cieľom je dodatočne určiť iba parametre (váhy) vybraných vstupných, resp. *riadiacich konceptov*.



Obr. 25 Vizualizácia troch rôznych atraktorov FKM s dvoma sledovanými hodnotami konceptov.

V súvislosti s definovanými základnými úlohami, na riešenie ktorých je možné použiť FKM, vyplýva aj ich aplikovateľnosť na riešenie problémov v oblasti modelovania a riadenia systémov. V zásade platí, že úlohy *prvého typu* sú riešené v súvislosti s *modelovaním* systémov a úlohy *druhého typu* sú aplikovateľné pri *riadení* systémov.

4.6. Metódy automatizovaného učenia FKM

Nevýhodou FKM je fakt, že podobne ako ostatné typy fuzzy inferenčných systémov nie sú schopné samostatného učenia. Návrh učiacich metód je náročný z dôvodu komplexnej štruktúry a variability FKM. Z tohto dôvodu je množina konceptov C zvyčajne daná *a priori* expertom a iba matica váh W je nastavovaná automatickými učiacimi algoritmi [40][43]. Cieľom učenia FKM je potom nájsť takú maticu váh, ktorá sa najviac hodí na riešenie daného rozhodovacieho, predikčného alebo iného problému.

Pre učenie FKM sú dostupné rôzne metódy, ktoré sú zväčša založené na myšlienkach z oblasti učenia umelých neurónových sietí. Učiace algoritmy môžu trénovať FKM, teda cieľavedome upravovať silu prepojení (váh) medzi konceptmi, podobne ako v prípade synapsií medzi neurónmi pri neurónových sieťach [43]. Vhodnosť konkrétneho algoritmu strojového učenia výrazne závisí od typu problému, na ktorého riešenie je FKM použitá.

Úlohy *prvého typu* (pozri kapitolu 4.5) sa riešia prostredníctvom učiacich prístupov založených na nekontrolovanom učení, najmä Hebbovom učení [40]. Vo všeobecnosti je nekontrolované učenie vhodné napríklad pre úlohu zhlukovania, kedy potrebujeme vzorku dát roztriediť do viacerých skupín. V prípade, že objekty v rámci jednej skupiny majú silné vzájomné vzťahy, zvyčajne reagujú alebo sú aktivované v rovnakom čase, čo korešponduje s paradigmou Hebbovho učenia. Z pohľadu situačného riadenia a modelovania je tento prístup vhodný pri hľadaní vhodného rozdelenia situačného priestoru do základných situačných rámcov, resp. pri definovaní alebo modifikovaní situačného klasifikátora.

V úlohách *druhého typu* je výhodnejšie využívať kontrolované učenie. Môžu to byť napríklad problémy experimentálnej identifikácie, modelovania a riadenia otvorených systémov [26], kde sú z experimentov dostupné vektory hodnôt vstupov, výstupov a taktiež vnútorných parametrov týchto systémov. Používajú sa prístupy využívajúce evolučné a populačné algoritmy, alebo aj prístupy založené na metóde najmenšej kvadratickej chyby (LMS – least mean square) [40], resp. spätnom šírení chyby (BP – backpropagation of error).

Prístupy k učeniu FKM môžu byť teda v zásade kategorizované nasledovne [40][43][46]:

- 1) prístupy s nekontrolovaným učením,
 - založené na Hebbovom učení (HL),
 - Differential HL, Active HL, Nonlinear HL,
- 2) prístupy s kontrolovaným učením,
 - využívajúce evolučné a populačné algoritmy,
 - Genetic algorithm, Simulated annealing, Tabu search,
 - Particle Swarm Optimization,
 - založené na metóde najmenšej kvadratickej chyby (LMS – Least Mean Square),
 - Delta Rule, Backpropagation of Error, Backpropagation through Time [41],
 - Data Driven Hebbian Learning (DDHL [49]).

V prípade väčšiny prístupov založených na Hebbovom učení je najprv na základe znalostí expertov určená podmnožina matice váh a cieľom ďalšieho učenia je určenie takých váh z tejto podmnožiny, ktoré vedú ku konvergencii FKM do cieľového regiónu špecifikovaného riešeným problémom.

V prípade populačných algoritmov a LMS prístupov (ale aj DDHL) je cieľom vypočítať maticu váh automaticky použitím historických dát tak, aby stavy FKM čo najlepšie odpovedali sekvenciám vstupných stavových vektorov alebo vzorov. V tomto prípade je expert nahradený historickými dátami. [3][9].

5. Perspektívy využitia FKM pri situačnom modelovaní a riadení leteckých motorov

„Len zložitosť môže zvládnuť zložitosť.“


(Princíp nevyhnutnej variety)

W. Ross Ashby

Letecké turbokompresorové motory (LTKM) ako zložité nelineárne systémy predstavujú vhodný prostriedok pre aplikáciu komplexných modelov a syntézu progresívnych riadiacich systémov založenú na využití prvkov a metód umelej inteligencie [26]. Fuzzy kognitívne mapy ako prostriedok umelej inteligencie sa javia vhodné predovšetkým na identifikáciu a modelovanie LTKM, a v tejto súvislosti aj ako prostriedok pre diagnostiku a kontrolu spoľahlivosti.

5.1. Letecké turbokompresorové motory

Letecké turbokompresorové motory (LTKM) (pozri Obr. 26) predstavujú špecifickú triedu zložitých systémov. Sú to mnohorozmerné objekty so zložitými vnútornými termomechanickými procesmi. Okrem závislostí medzi vnútornými prvkami objektu sú prítomné aj väzby s vonkajšími objektmi (napr. riadiacimi prvkami). Ich narušenie môže vážne ovplyvniť funkčnosť a integritu celého objektu (motora a lietadla) [5]. K riadeniu LTKM je preto potrebné pristupovať so zreteľom na tieto vlastnosti.

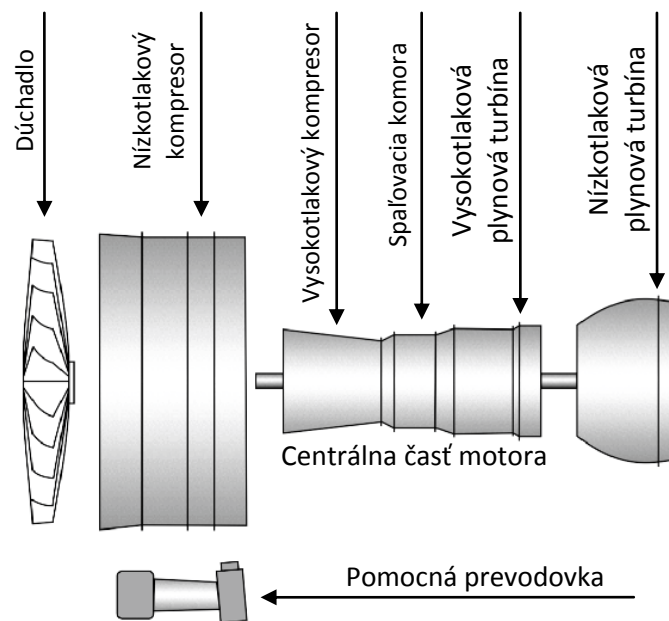


Obr. 26 Letecký turbokompresorový motor GE-90 firmy General Electric Aviation.

LTKM pozostáva z hlavných komponentov, ktoré menia stav prúdenia plynov v sekvencii termodynamického pracovného cyklu motora. Dizajn moderného LTKM predpokladá viacprvkovú modulárnu koncepciu. V súčasnosti typický dvojhriadeľový motor pozostáva z nasledujúcich hlavných modulov (pozri Obr. 27) [50]:

- dúchadlo („fan“),
- modul nízkotlakového kompresora,

- jadro motora („core engine“):
 - vysokotlakový kompresor,
 - spaľovacia komora (plynový generátor),
 - vysokotlaková plynová turbína,
- modul nízkotlakovej plynovej turbíny,
- pomocná prevodovka.




Obr. 27 Hlavné časti dvojhriadeľového LTKM. Prevzaté z [50].

Základné prvky, z ktorých sa jednotlivé moduly skladajú sú *kompresor*, *turbína* a *spaľovacia komora*. Dôležitou súčasťou sú aj *hriadele*, ktoré vzájomne prepájajú kompresory a turbíny. Základné vlastnosti týchto komponentov sú nasledovné [5]:

- *Kompresor* – skladá z viacerých stupňov, pričom každý stupeň je zložený z nehybnej statorovej časti a pohyblivej rotorovej časti (pozri Obr. 28) osadenej na niektorom z hriadeľov. Lopatky jednotlivých stupňov môžu mať meniteľný uhol natočenia.
- *Spaľovacia komora* – kde dochádza k zapáleniu zmesi paliva a vzduchu. Spaľovacia komora je ochladzovaná vonkajším prúdom vzduchu.
- *Turbína* – predstavuje aktívnu časť motora. Pozostáva z viacerých stupňov (zvyčajne menšieho počtu ako v kompresoroch). Jednotlivé stupne pozostávajú zo statorovej rotorovej časti. Lopatky stupňov sú zväčša konštruované ako duté. Chladenie turbíny závisí od konštrukčného riešenia motora, ale obvykle sa odoberá vzduch od niektorého stupňa kompresora vysokého tlaku.

- *Hriadeľ* – spája príslušnú turbínu a odpovedajúci kompresor do pevného mechanického celku (otáčky turbíny odpovedajú otáčkam kompresora). Pri tomto spojení reprezentuje kompresor pasívnu a turbína aktívnu časť motora (t. j. turbína roztáča kompresor).



Obr. 28 Jeden stupeň axiálneho kompresora. Prevzaté z [51].

Pohyblivé časti motora (dúchadlo, rotory kompresora a turbíny) sú pri dvojhriadeľových LTKM osadené na dvoch samostatných hriadeľoch. Jeden hriadeľ spája rotory nízkotlakovej plynovej turbíny a nízkotlakového kompresora vo vonkajšej časti. V prednej časti tohto hriadeľa je navyše osadené dúchadlo. Druhý hriadeľ spája rotory vysokotlakového kompresora a vysokotlakovej turbíny v jadre motora.

Modulárny dizajn LTKM je populárny najmä z hľadiska údržby, kedy je možné ktorúkoľvek časť motora oddeliť bez potreby jej rozobratia na základné diely. Každý modul má špecifický rozvrh údržby a rôzne požiadavky na vyžadované zručnosti a pracovné pomôcky technického personálu. Okrem aspektu údržby je táto modulárna koncepcia rovnako užitočná pri popise elementárnych funkcií motora a jeho pracovného cyklu [50]. Princíp činnosti motora je nasledovný [5][26][50]:

- 1) Vzduch je vstupným ústrojenstvom cez dúchadlo privádzaný do nízkotlakového kompresora a následne do vysokotlakového kompresora, v ktorých sa účinkom rotácie a pôsobenia odstredivých síl stláča a zrýchľuje. V difúzoroch dochádza k poklesu absolútnej rýchlosti prúdiaceho vzduchu pri súčasnom poklese statického tlaku a teploty.
- 2) V spaľovacej komore sa stlačený vzduch mieša s palivom a zapáľuje. Dochádza k expanzii plynov, nárastu teploty a tlaku. Spaľovacia komora je ochladzovaná vonkajším prúdom vzduchu a konštrukčné riešenie môže zabezpečovať aj zníženie axiálnej rýchlosti vhaňaného vzduchu, pre lepšie premiešanie vzduchu a paliva a tým jeho lepšie spaľovanie.
- 3) Prúd plynov po expanzii v spaľovacej komore prechádza postupne najprv do vysokotlakovej a následne do nízkotlakovej plynovej turbíny. Postupne tak premieňa svoju tepelnú a tlakovú energiu na kinetickú energiu. Lopatky rotorov turbíny následne

premieňajú túto energiu na mechanickú prácu vo forme krútiaceho momentu, ktorý prostredníctvom hriadele poháňa kompresor. Časť tohto krútiaceho momentu je navyše (pomocou prevodovky) využitá na pohon ďalších agregátov motora (napr. palivové a olejové čerpadlá) a systémov lietadla (generátor el. energie). Teplota, tlak a rýchlosť plynov za plynovou turbínou následne klesá..

- 4) Únikom plynov cez výstupnú sústavu sa nakoniec získava ťahová sila, ktorá je využitá na pohyb motora a lietadla smerom vpred.

Základný motor sám o sebe nie je prevádzkyschopný. Na jeho činnosť sú nevyhnutné ďalšie subsystémy. Medzi najdôležitejšie subsystémy LTKM patria:

- chladiace systémy,
- systém dodávky paliva,
- olejová sústava,
- systém zapaľovania,
- riadiaci systém.

Navyše sú tu aj ďalšie systémy, ktoré síce priamo neovplyvňujú činnosť motora, ale sú s ním funkčne prepojené. Tieto sekundárne systémy môžu byť počas bežnej prevádzky motora vypnuté. Aktivované sú len v prípade potreby. Patria sem najmä:

- systém ochrany pred požiarom,
- systém ochrany pred mrazom,
- generátor elektrickej energie,
- pneumatický systém,
- hydraulický systém.

Je zrejmé že súbežné riadenie LTKM a všetkých jeho subsystémov nie je jednoduché a vyžaduje sofistikované riadiace algoritmy. Tieto riadiace algoritmy sú integrované v riadiacom systéme.

Elektronické riadiace systémy LTKM sú všeobecne označované ako *systémy digitálneho riadenia motora* (DEC – „Digital Engine Control“). Podmnožinu týchto systémov tvoria *systémy riadenia motora s plnou autoritou* (FADEC – „Full Authority Digital Engine Control“). Systémy FADEC autonómne zabezpečujú optimálnu prevádzku motora vo zvolenom režime s ohľadom na letové podmienky, ktoré definujú vstupné parametre motora [5]. Pri návrhu takýchto riadiacich systémov v budúcnosti je vhodné uvažovať o možnostiach využitia moderných metód

automatického riadenia a umelej inteligencie. Systémy s plnou autoritou zároveň plne súhlasia s filozofiou situačného riadenia.

Vo všeobecnosti je cieľom riadenia mnohorozmerných objektov dosiahnutie optimálnej kvality riadenia a zároveň zabezpečenie stability celého riadiaceho obvodu [5]. Spôsoby riešenia tejto úlohy sú reprezentované dvoma základnými prístupmi [52]:

- 1) Dosiahnutie *lokálnych extrémov* (minimum, resp. maximum) každej z riadiacich veličín.
- 2) Dosiahnutie *globálneho extrému* u všeobecného ukazovateľa kvality, ktorý je závislý od všetkých riadiacich veličín.

Prvý spôsob je v súčasnej dobe najčastejšie používaný. Pri tomto postupe je sú aktuálne parametre porovnávané s požadovanými a v závislosti od odchýlok sú vykonávané príslušné riadiace zásahy. Druhý spôsob vyžaduje definíciu globálneho ukazovateľa, ktorým môže byť napríklad špecifická spotreba paliva. Táto v konečnom dôsledku závisí od veľkého počtu ostatných parametrov a teda snahou o jej optimalizáciu je možné nepriamo dosiahnuť aj optimalizáciu závislých parametrov [52].

5.2. Malý prúdový motor (MPM) s typovým označením ISTC-21V


Malý prúdový motor (MPM) s typovým označením¹ ISTC-21V je jednoprúdový, jednohriadeľový letecký turbokompresorový motor s jednostupňovým, jednostranným radiálnym kompresorom, združenou spaľovacou komorou, jednostupňovou, nechladenou plynovou turbínou a variabilnou výstupnou dýzou [26][53]. Vznikol postupnou evolúciou MPM s typovým označením¹ MPM-20, ktorý bol pôvodne vytvorený z turbo-spúšťača TS-21 používaného v lietadlách typu Mig-23, Su-7 a Su-22 na roztočenie hlavných motorov [26][53]. Hoci je rozmerovo menší ako normálne LTKM, jeho charakteristiky sú veľmi podobné [26]. Motor ISTC-21V (pozri Obr. 29) sa skladá z nasledovných súčastí [26][53]:

- *Kompresor* – jednostupňový, jednostranný kompresor radiálnej konštrukcie.
- *Spaľovacia komora* – je združená, umožňuje tak lepšie premiešanie vzduchu a paliva.
- *Plynová turbína* – je jednostupňová a nechladená.
- *Výstupná sústava* – obsahuje výstupnú dýzu s premenlivým priemerom.

Riadenie motora ISTC-21V je možné vykonávať prostredníctvom dvoch parametrov. Prvým je dodávka paliva do spaľovacej komory, ktorá je zároveň hlavným regulačným prvkom činnosti

¹ Hoci táto kapitola popisuje konkrétne malý prúdový motor s typovým označením ISTC-21V, ktorý vznikol úpravou malého prúdového motora motor s typovým označením MPM-20, v ďalších kapitolách, pri teoretických návrhoch riadiacich algoritmov a modelov s využitím FKM, používame všeobecnú skratku označujúcu malé prúdové motory, teda MPM. Toľko len pre spresnenie významu a použitia jednotlivých označení.

motora. Ďalším meniteľným parametrom je nastavenie priemeru výstupnej dýzy. Zmena tohto priemeru umožňuje na výstupe meniť zaťaženie motora, čo predstavuje druhý stupeň riadenia motora.




Obr. 29 Malý prúdový motor (MPM) s typovým označením ISTC-21V [53].

Pre umožnenie situačného modelovania MPM je potrebné zaznamenávať jeho charakteristiky. Digitálne snímanie parametrov MPM v reálnom čase je navyše nevyhnutné pre systémy automatického riadenia v súlade požiadavkami FADEC systémov a situačného riadenia. Merací reťazec môže byť v tomto zmysle považovaný za hybridný systém transformujúci spojitú fyzikálnu realitu do diskkrétnej podoby (pozri kapitolu 3.2.1, Obr. 13). Jednotlivé parametre je nevyhnutné snímať v reálnom čase, perióda vzorkovania musí byť porovnateľná s časovou konštantou systému, ktorá zodpovedá dynamike systému. Pri motore ISTC-21V je použitá perióda $\tau = 0.1s$, ktorá je pre tieto potreby postačujúca. Požiadavky na merací systém sú nasledovné [26]:

- 1) Meranie riadiacich, stavových a ďalších pozorovaných parametrov MPM musí prebiehať v reálnom čase.
- 2) Snímače meraných parametrov musia byť odolné voči šumom a byť schopné pracovať v extrémnych podmienkach (veľkom rozsahu teplôt, tlakov a vibrácií).
- 3) Merané analógové hodnoty je potrebné previesť do digitálnej podoby v reálnom čase a paralelným spôsobom.
- 4) Získané údaje je potrebné spracovať a uložiť s dostatočnou periódou vzorkovania (najmenej $\tau = 0.1s$) pre všetky snímané kanály.

S ohľadom na uvedené požiadavky bol merací systém pôvodného motora MPM-20 (pozri Obr. 30) [5] úpravou na ISTC-21V postupne rozvinutý do aktuálneho stavu [53], kedy je umožnené meranie 15 parametrov motora, ktoré sú použité pre potreby modelovania, diagnostiky a riadenia motora. Nasleduje zoznam meraných parametrov motora (kde čísla v indexoch parametrov určujú umiestnenie príslušných senzorov v jednotlivých rezoch motora; pozri Obr. 29) [53]:

- p_H – atmosférický tlak [Pa],
- p_{2C} – celkový tlak za radiálnym kompresorom [Pa],
- p_{3C} – celkový tlak pred turbínou [Pa],
- p_{pal} – tlak paliva [Pa],
- p_{ol} – tlak oleja [Pa],
- t_H – vonkajšia teplota okolia motora [°C],
- t_{1C} – teplota na vstupe do kompresora [°C],
- t_{2C} – teplota na výstupe z kompresora [°C],
- t_{3C} – teplota v spaľovacej komore [°C],
- t_{4C} – teplota za turbínou [°C],
- t_{ol} – teplota oleja [°C],
- n – otáčky rotora turbo-kompresora [min^{-1}],
- F_t – ťah motora [N],
- Q_{pal} – dodávka paliva [l/min],
- A_5 – priemer výstupnej dýzy [%].



Obr. 30 Zmena parametrov malého prúdového motora počas jedného merania. Prevzaté z [5].

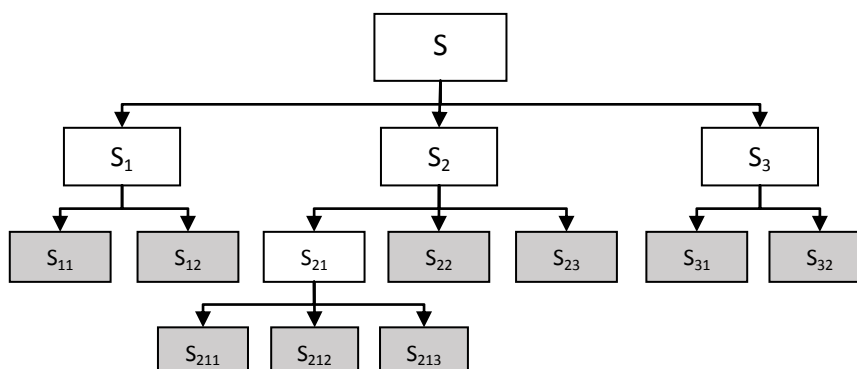
Merací systém je nevyhnutný pri riadení MPM. Merané dáta musia byť presné, spoľahlivé a stabilné. Stavové parametre motora, ako napr. otáčky turbo-kompresora sú dôležité pri digitálnom riadení motora. Z tohto dôvodu sú na zaistenie spoľahlivosti týchto parametrov využité špecializované diagnostické algoritmy [53].

5.3. Situačné riadenie a modelovanie MPM

Použitím metodiky situačného riadenia (kapitola 2.4.1) je celý rozsah činnosti MPM rozdelený do časovo invariantných situačných rámcov (situačných tried), pre ktoré sú následne vypracované špecializované riadiace algoritmy a stratégie. Pri návrhu situačného modelu MPM je možné použiť nasledovné situačné rámce a príslušné atypické situácie [5]:

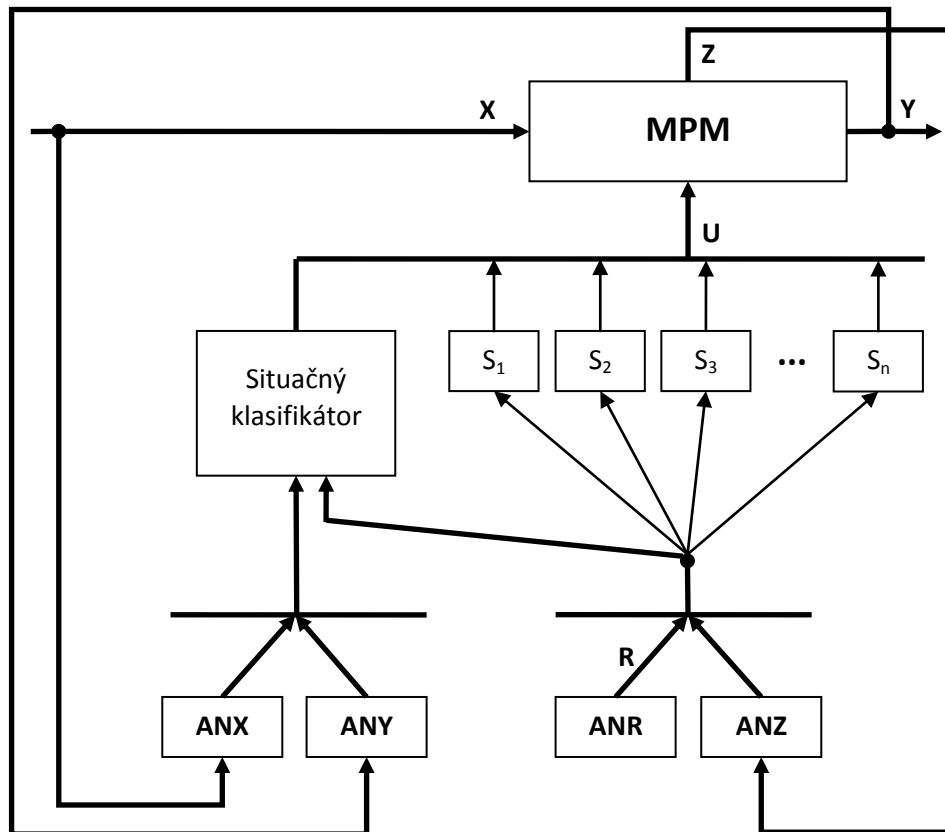
- S_1 – rozbeh motora:
 - S_{11} – prekročenie medzných teplôt pri spustení,
 - S_{12} – nedostatočné stlačenie p2C,
- S_2 – stabilná prevádzka motora:
 - S_{21} – atypický stav:
 - S_{211} – pokles stlačenia kompresora,
 - S_{212} – pokles dodávky paliva,
 - S_{213} – nestabilné otáčky,
 - S_{22} – akcelerácia motora,
 - S_{23} – decelerácia motora,
- S_3 – dobeh motora:
 - S_{31} – zhasnutie motora,
 - S_{32} – porucha pri dobehu.

Hierarchické usporiadanie týchto situačných rámcov zobrazuje Obr. 31. Atypické situácie sú vyznačené sivou farbou.



Obr. 31 Situačná dekompozícia MPM [5].

Pre návrh riadenia motora MPM metodikou situačného riadenia a s pomocou prostriedkov UI je aj s ohľadom na existujúci systém merania parametrov vhodné vychádzať z metódy formátorového riadenia (kapitola 3.3). Štrukturálna schéma formátorového riadenia MPM je zobrazená na obr



Obr. 32 Schéma formátorového riadenia MPM [5].

Z praktického hľadiska je možné jednotlivé situačné rámce počas situačného riadenia ISTC-21V popísať nasledovne [53]:

- Štart motora* – je režim pri ktorom je MPM spustený z pokojového stavu do rovnovážneho chodu počas stabilnej prevádzky. Tento režim je úzko ohraničený diagnostickým a elektromechanickým systémom motora. Štart motora je umožnený až po tom, čo je každý agregát a senzor skontrolovaný. Na riadenie systémových agregátov (elektrický štartér, zapalovacie sviečky, palivové a olejové čerpadlo, elektromagnetické ventily) počas štartu je použitý expertný systém. Po tom, čo je zapálené palivo, jeho dodávka je riadená s cieľom minimalizovať teplotný preskok (najmä parametra t_{4c}). Tento situačný rámec je v súčasnosti riadený fuzzy regulátorom.
- Stabilná prevádzka motora* – je režim pri ktorom je každý prvok MPM v termodynamickej rovnováhe. Použité je dvojité spätno-väzobné riadenie, kde vnútorná väzba zisťuje presnú dodávku paliva do motora (riadenú mikropočítačom) a vonkajšia väzba (prostredníctvom

nadriadeného riadiaceho počítača) určuje požadovanú dodávku paliva, pričom cieľom je minimalizovať rozdiel medzi požadovanými otáčkami motora a aktuálnymi otáčkami. Na tento účel sa používa adaptívny diskretný PSD regulátor a tiež tradičný PS regulátor.

- c) *Akcelerácia a decelerácia motora* – akcelerácia reprezentuje stav pri ktorom MPM zvyšuje svoje aktuálne otáčky. Hlavnou požiadavkou je minimalizácia času medzi zmenou rýchlosti otáčok. Akcelerácia to špeciálny režim pri ktorom hrozí riziko náhleho zníženia účinnosti kompresora (pumpáže). S cieľom zabrániť pumpáži pri akcelerácii je použitý špeciálny fuzzy regulátor. Špecializovaný regulátor je tiež navrhnutý pre situáciu, kedy teplota výstupných plynov presahuje bezpečné hodnoty. V tom prípade motor prejde do režimu v ktorom udržiava túto teplotu konštantnú s použitím adaptívneho obmedzovača, pričom súčasne sa snaží udržať možný maximálny výkon motora v daných podmienkach.
- d) *Atypické prevádzkové stavy* – pre ktoré je potrebné navrhnuť špecializované regulátory. Tieto stavy môžu zahŕňať napríklad prekročenie maximálnych otáčok, poruchové prevádzkové stavy, obálku limitných operácií, zlyhania atď.

5.4. FKM pri riadení a modelovaní MPM

Využitie metód umelej inteligencie pri situačnom riadení MPM je podľa [53] možné pri:

- situačnej klasifikácii aktuálneho stavu do príslušnej situačnej triedy,
- návrhu inteligentných riadiacich metód pre niektoré operačné stavy,
- návrhu modelov použitých pri diagnostike stavu motora.

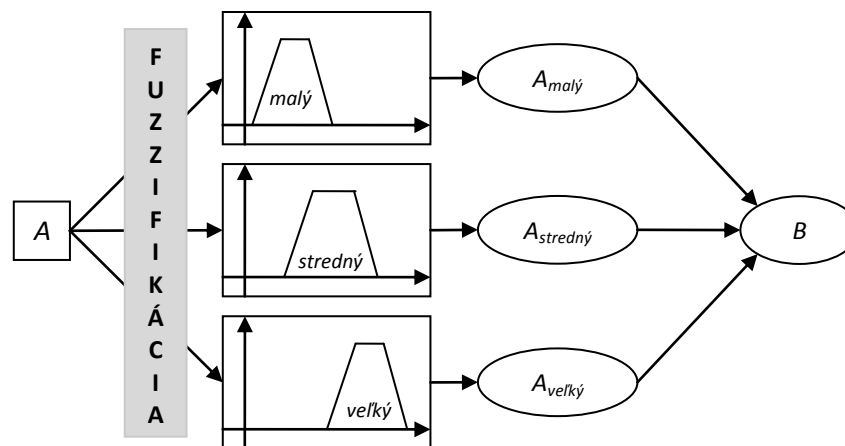
FKM ako prostriedok UI sú s určitými rezervami využiteľné vo všetkých uvedených oblastiach. Avšak je potrebné brať v úvahu niektoré obmedzenia FKM vyplývajúce z ich vlastností. Vzťahy medzi prvkami systémov v reálnom svete nie sú lineárne, ani monotonické, ako je to v prípade modelov realizovaných pomocou jednoduchých FKM [36]. Reálne systémy majú obvykle nelineárnu dynamiku, často viac ako druhého rádu. Oproti tomu dynamika FKM je iba prvého rádu, kde nasledujúci stav závisí iba od predošlého. V princípe má základná koncepcia FKM tieto tri zásadné nedostatky [54]:

- 1) Prepojenia medzi konceptmi FKM sú iba numerické,
 - vzťahy medzi nimi by teda mali byť lineárne.
- 2) Nepočíta sa s časovým oneskorením,
 - v praxi má každý kauzálny vzťah rôzne časové oneskorenie.

3) Nezahrňajú súčasný výskyt viacerých príčin,


- používajú sa iba pravidlá typu "ak A potom B",
- neuvažuje sa s pravidlami typu "ak (A1 a A2) potom B".

Väčšinu týchto problémov je však možné do určitej miery redukovať. Odstránenie prvého problému, teda dosiahnutie nelineárnych vzťahov medzi modelovanými konceptmi je možné pridaním potrebného počtu konceptov, t. j. zvýšením lingvistických termov dostupných pre modelovaný parameter (pozri Obr. 33). Dôležité však je aby sa hodnoty parametra fuzzifikovali pre každý príslušný koncept s využitím inej fuzzy množiny.



Obr. 33 Modelovanie nelineárneho vzťahu medzi parametrami A a B prostredníctvom FKM.

Odstránenie problémov s chýbajúcimi časovými oneskoreniami, resp. s dynamikou vzťahov je možné opätovne odstrániť pridaním špeciálnych dodatočných konceptov, ktoré budú reprezentovať modelovaný parameter v minulosti, resp. pridaním konceptov reprezentujúcich dynamickú zmenu parametra medzi poslednými časovými okamihmi (pozri Obr. 34).



Obr. 34 Modelovanie dynamických vzťahov medzi parametrami A a B prostredníctvom FKM.


Problém s modelovaním zložitejších príčinných vzťahov je možné vyriešiť modifikáciou funkcie určujúcej výpočet aktivácie konceptu (kapitola 4.4 rovnica 13) a nahradením sumačného člena zložitejšou funkciou podľa potreby.

Je zrejmé, že veľkosť mapy definujúcej model sa po takýchto zmenách zväčší a jej čitateľnosť sa zhorší. Aby sme tomu zamedzili a zachovali počet konceptov na prijateľnom množstve, je okrem vyššie uvedených návrhov možné použiť aj modifikované FKM [54], ktoré sú rozšírené o oneskorenia vplyvov, nelineárne a podmienené vzťahy. Tiež je možné uvažovať nad hybridizáciou FKM pomocou neurónových sietí.

V ďalších kapitolách (najmä v schémach a obrázkoch) budeme kvôli zjednodušeniu predpokladať, že vzťahy medzi modelovanými parametrami sú lineárne. V prípade návrhu konkrétnych modelov, je kedykoľvek možné vykonať potrebné úpravy FKM s cieľom dosiahnuť komplexnejšie vzťahy medzi modelovanými parametrami.

5.4.1. FKM pri modelovaní a diagnostike MPM

V situačnom riadení sa môžu klasické FKM s lineárnymi váhami uplatniť ako čiastkové modely pre jednotlivé situačné rámce (pozri Obr. 35). V prípade realizácie modelu MPM pre konkrétny situačný rámec sú ako koncepty FKM použité merané parametre motora (po normalizácii, resp. fuzzifikácii na interval $\langle 0, 1 \rangle$).




Obr. 35 Návrh lokálneho modelu MPM realizovaného pomocou FKM.

Vzhľadom k tomu, že nie je problém merať parametre motora počas jeho činnosti, je jednoduché vytvárať bázu historických dát a trénovacie množiny. Tie môžu byť následne použité pri adaptácii váh medzi konceptmi pomocou rôznych metód kontrolovaného učenia, vrátane prístupov z oblasti neurónových sietí, ako je napr. metóda spätného šírenia chyby. Rovnako je možné použiť aj evolučné a populačné algoritmy.

5.4.2. FKM pri riadení MPM


FKM je tiež možné využiť v oblasti riadenia MPM. V tomto prípade je cieľom riešiť úlohu zakódovania atraktora (pozri kapitolu 4.5), t. j. hľadať také hodnoty váh radiacích parametrov, pri ktorých sa FKM po určitom čase dostane z ľubovoľného počiatočného stavu do žiadaného cieľového stavu (resp. stabilného limitného cyklu). Zadaný cieľový stav môže byť určený napríklad optimálnymi hodnotami parametrov určujúcich kvalitu riadenia (napr. spotreba paliva a i.). Tento prístup je možné použiť napríklad s cieľom dostať MPM z rôznych neštandardných stavov naspäť do rovnovážneho chodu počas stabilnej prevádzky. Avšak okrem stabilných bodov je možné do FKM zakódovať aj trajektórie a limitné cykly. Týmto spôsobom by bolo možné riešiť napríklad problémy optimálnej akcelerácie, resp. štartu motora.

V prípade učenia radiacích štruktúr FKM môžeme použiť rôzne prístupy. Jednou možnosťou je použitie natrénovaného situačného modelu MPM a jeho doplnenie o prepojenia v smere od meraných parametrov ku radiacim konceptom (na Obr. 36 vyznačené tmavou farbou). Nejedná sa o nič iné, ako o zavedenie spätnej väzby, teda informačného kanála na základe ktorého dokážu radiace koncepty správne určiť svoje aktivačné hodnoty (t. j. radiace parametre, ako je napr. dodávka paliva). Cieľom učenia je potom adaptácia váh smerujúcich k radiacim konceptom takým spôsobom, aby radiace koncepty správne reagovali na zmenu parametrov motora a zvolený cieľ riadenia (napr. konštantné otáčky a pod.). Vhodnou metódou učenia pre sú v tomto prípade EA.



Obr. 36 Návrh riadenia MPM realizovaného prostredníctvom FKM.

Ďalšou možnosťou je vytvorenie prostej doprednej štruktúry FKM a jej učenie s pomocou tréningových dát. Takto koncipovaná FKM sa svojou štruktúrou a funkciou približuje klasickej doprednej neurónovej sieti (pozri Obr. 37).

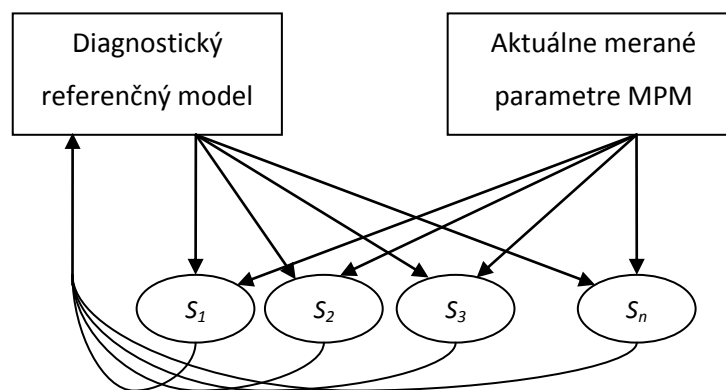


Obr. 37 Alternatívny návrh riadenia s využitím FKM.

Pri tomto návrhu je zrejmé, že riadiace koncepty budú aktivované iba pomocou lineárnej funkcie meraných parametrov. V prípade, že to nie je pre účely riadenia postačujúce, opäť je možné rozšíriť merané parametre o ďalšie koncepty reprezentujúce širšiu množinu lingvistických termov.

5.4.3. FKM ako situačný klasifikátor stavov MPM

Pri využití FKM v úlohe situačného klasifikátora sú okrem konceptov reprezentujúcich model MPM použité aj koncepty odpovedajúce jednotlivým situačným triedam (pozri Obr. 38). Situačné koncepty sú aktivované v závislosti od stavu motora (t. j. hodnôt jeho parametrov), pričom najsilnejšie aktivovaný koncept predstavuje aktuálnu situačnú triedu. Navyše je možné do mapy zahrnúť aj výstupy diagnostického modelu a porovnať ich s aktuálnymi hodnotami parametrov motora. Veľké rozdiely reálnych a modelovaných hodnôt indikujú stav, kedy sa MPM už nenachádza v odpovedajúcej situácii. Na tento rozdiel odpovedajúco zareagujú aj aktivačné hodnoty situačných konceptov, ktoré môžu následne akčným zásahom modifikovať aktuálny referenčný model alebo ho zameniť za nový, lepšie reflektujúci aktuálnu situáciu. Ak takýto model neexistuje, potom je pravdepodobné, že motor sa dostal do novej, predtým nedefinovanej situácie. V tomto prípade je vytvorený nový situačný koncept a tiež nový referenčný model odpovedajúci novej situácii.



Obr. 38 Zjednodušený pohľad na situačnú klasifikácia pomocou FKM.

Pri návrhu takéhoto modelu situačného klasifikátora je potrebný príspevok experta, najmä pri definovaní počiatočných situačných konceptov a príslušných modelov. Ďalej sú použité učiace algoritmy, ktoré s využitím historických údajov adaptujú hodnoty váh medzi konceptmi. Pri implementácii automatického rozpoznávania nových situácií je zároveň nevyhnutné aby tieto algoritmy pracovali online, teda aby boli schopné vytvoriť nové situačné modely v krátkom čase, priamo počas činnosti MPM.

Záver

*„Ako môžeme ísť k obedu, pokiaľ sme nevyriešili
otázku zmyslu života?“*

Ivan Sergejevič Turgenev

V predloženej práci k dizertačnej skúške sú zosumarizované všetky poznatky nevyhnutné k ďalšej výskumnej práci v oblasti situačného riadenia MPM s využitím prostriedkov umelej inteligencie, menovite FKM. Uvedené metódy a metodiky majú široké uplatnenie v širokom spektre rôznych oblastí technickej aj netechnickej praxe.

Do budúcnosti je cieľom pokúsiť sa implementovať jednotlivé modely navrhnuté v kapitole 5.4 a overiť ich v experimentálnych podmienkach LIRS LM. V tejto súvislosti bude potrebné vytvoriť vhodný prostriedok, v ktorom budú tieto modely implementované, pretože použiteľnosť dostupných programových prostriedkov umožňujúcich modelovanie pomocou FKM je obmedzená zvyčajne na úzke spektrum činností. Navrhnuté modely bude oproti tomu potrebné naprototypovať, parametrizovať, odladiť a následne nasadiť do existujúceho riadiaceho systému. Vzhľadom k týmto požiadavkám bude jedným z cieľov budúcej práce návrh univerzálnej programovej knižnice podporujúcej výpočty pomocou FKM využiteľnej na všetky spomínané úlohy.

Okrem využitia základných FKM s lineárnymi váhami bude ďalším cieľom overiť možnosti využitia modifikovaných FKM (napríklad s váhami realizovanými pomocou neurónových sietí). Hľadanie štrukturálnych modifikácií FKM, ktoré odstránia ich lineárny charakter, je veľmi dôležitým cieľom ďalšieho výskumu v tejto oblasti. Nemenej dôležitou výskumnou úlohou je hľadanie progresívnych metód učenia FKM s cieľom spresniť výsledné modely a zlepšiť kvalitu riadenia MPM ako zložitého termodynamického systému.

Tézy budúcej doktorandskej dizertačnej práce

Ako je z predchádzajúceho textu a záveru tejto práce zrejmé, hlavným cieľom budúcej dizertačnej práce bude overenie možností využitia fuzzy kognitívnych máp v situačnom riadení a modelovaní malého prúdového motora. S ohľadom na tento hlavný cieľ stanovujeme nasledovné tézy dizertačnej práce:

- 1) Modifikovať základnú koncepciu FKM s cieľom umožniť modelovanie zložitých nelineárnych dynamických systémov.
- 2) Vytvoriť programovú knižnicu podporujúcu výpočty pomocou FKM, ktorá bude kompatibilná s existujúcimi systémami realizujúcimi riadenie malého prúdového motora ISTC-21V.
- 3) Vytvoriť situačný model malého prúdového motora ISTC-21V s využitím FKM.
- 4) Navrhnuť štruktúru systému situačného riadenia malého prúdového motora ISTC-21V s využitím FKM.
- 5) Implementovať systém situačného riadenia malého prúdového motora ISTC-21V realizovaný s využitím FKM a overiť jeho použiteľnosť v experimentálnych podmienkach.

Uvedené tézy budúcej doktorskej dizertačnej práce sú zároveň premietnuté do cieľov projektu KEGA č. 014TUKE-4/2015 s názvom „Digitalizácia, virtualizácia a testovanie malého prúdového motora a jeho častí pomocou stendov pre potreby modernej aplikovanej výuky“, ktorý bude riešený v rokoch 2015-17.

Zoznam použitej literatúry

- [1] Madarász, L., Vaščák, J., Andoga, R., Karol', T., „Rozhodovanie, zložitost' a neurčitost',“ pp. 396, Elfa s.r.o. Košice, 2010. ISBN 978-80-8086-142-1.
- [2] Madarász, L. et al., „Systémová analýza a syntéza,“ Elfa, s.r.o., 2012, pp. 303, ISBN 978-80-8086-193-3.
- [3] Sarnovský J., Madarász, L., Bízík, J., Csontó, J., „Riadenie zložitých systémov,“ pp. 384, Alfa, Bratislava, 1992. ISBN 80-05-00945-3.
- [4] Madarász, L., „Inteligentné technológie a ich aplikácie v zložitých systémoch,“ pp. 346, Elfa, s.r.o., Košice, FEI TU, 2005. ISBN 80-89066-75-5
- [5] Andoga R., „Hybridné metódy situačného riadenia zložitých systémov,“ Doktorandská dizertačná práca, pp. 120, KKUI FEI TU v Košiciach, 2006
- [6] Madarász, L., „Metodika situačného riadenia a jej aplikácie,“ pp. 212, Elfa Košice, 1996. ISBN 80-88786-66-5
- [7] Madarász, L., „Základné princípy situačného riadenia a formalizácie rozhodovacích procesov pri riadení zložitých hierarchických systémov.“ Kandidátska dizertačná práca, pp. 95, EF VŠT Košice, 1982.
- [8] Madarász, L., Főző, L., Andoga, R., Bučko, M., „Základy automatického riadenia. Lineárne dynamické systémy - teória a príklady,“ Elfa, s.r.o., Košice, 2010, pp. 402, ISBN 978-80-8086-162-9.
- [9] Jadlovská A., Jadlovská S., „Moderné metódy modelovania a riadenia nelineárnych systémov,“ FEI TUKE, 2013, ISBN 987-808086-228-2.
- [10] Várkonyi – Kóczy, A., Kováčsházy, T., „Anytime Algorithms in Embedded Signal Processing Systems.“ IX. European Signal Processing Conf., EUSIPCO-98, Rhodes, Greece, Sept. 8.-11, Vol. I, pp. 169-172., 1998.
- [11] Madarász, L., „Riadenie organizačných systémov“, Alfa, Bratislava, pp. 267, 1985.
- [12] Olej, V., „Modelovanie ekonomických procesov na báze výpočtovej inteligencie.“ M&V, Milady Horákovéj 262, Hradec Králové, pp. 160, 2004, ISBN 80-903024-9-1.
- [13] Sinčák, P., Kostelník, P., Novotný, P., „Strojová inteligencia, inteligentné technológie – súčasnosť a budúcnosť.“ Riadenie a informatika, 4.-6 apríl 2001, FEI TU Košice. ÚTRaR SAV Bratislava, pp. 1-5.
- [14] Sinčák, P., Andrejková, G., „Neurónové siete – Inžiniersky prístup. Dopredné neurónové siete.“ I. diel. Elfa, s.r.o., Košice, pp. 110, 1996, ISBN 80-88786-38-X.
- [15] Sinčák, P., Andrejková, G., „Neurónové siete – Inžiniersky prístup. Rekurentné a modulárne siete.“ II. diel. Elfa, s.r.o., Košice, pp. 63, 1996, ISBN 80-88786-42-8.

- [16] Cybenko, G., „Approximation by Superpositions of a Sigmoidal Function,“ *Math. Control Signals Systems*, 2, pp. 303-314. 1989.
- [17] Hornik, K., Stinchcombe, M., White, H., „Multilayer Feedforward Networks are Universal Approximators,“ *Neural Networks*, 2(5), pp. 359-366. 1989.
- [18] Funahashi, K., „On the Approximate Realization of Continuous Mapping by Neural Networks,“ *Neural Networks*, Vol.2, pp. 183-192, 1989.
- [19] Mach, M., „Evolučné algoritmy: Prvky a princípy.“ 1. vydanie, elfa s.r.o., Košice, pp. 250, 2009, ISBN 978-80-8086-123-0
- [20] Pedersen, M.E.H., „Tuning & Simplifying Heuristical Optimization,“ PhD Thesis, University of Southampton, School of Engineering Sciences, Computational Engineering and Design Group. 2010.
- [21] Clerc, M., „Standard Particle Swarm Optimisation,“ HAL open access archive, 2012.
- [22] Vaščák, J., „Fuzzy logika v regulácii. Podrobný úvod do problematiky fuzzy riadenia,“ TUKE, FEI, KKUI, 2008.
- [23] Mamdani, E. H., „Application of fuzzy algorithms for the control of a simple dynamic plant.“ In *Proc IEEE*, pp. 121-159, 1974.
- [24] Sugeno, M., „An Introductory Survey of Fuzzy Control, Information Sciences,“ N.36, pp. 59-83, 1985.
- [25] Takagi, T., Sugeno, M., „Fuzzy identification of systems and its applications to modeling and control,“ *IEEE Transactions on Systems Man and Cybernetics*, Vol. SMC-15, pp. 116-132, 1985.
- [26] Lazar, T., Madarász L., et al., "Inovatívne výstupy z transformovaného experimentálneho pracoviska s malým prúdovým motorom," monografia, FEI, LF, TUKE, elfa, s.r.o., Košice 2011, ISBN 978-80-8086-170-4, EAN 978 8080 861704
- [27] Hladký, V., „A Contribution to Hybrid Control.“ *Symposium on Applied Machine Intelligence and Informatics (SAMI 2005)*, January 21-22, 2005, pp. 195-201, ISBN 963-7154-35-3.
- [28] Lin, C.-T. , Lee, C. S. G., „Neural Fuzzy Systems: A Neuro-Fuzzy Synergism to Intelligent Systems,“ Prentice-Hall PTR, 1996.
- [29] Sher, G. I., „Handbook of Neuroevolution Through Erlang.“ Springer Verlag, pp. 831, 2012, ISBN 978-1-4614-4463-3.
- [30] Kassahun, Y., Edgington, M., Metzen, J. H., Sommer, G., Kirchner, F., „Common Genetic Encoding for Both Direct and Indirect Encodings of Networks,“ *Proceedings of the Genetic and Evolutionary Computation Conference (GECCO 2007)*, London, UK, pp. 1029-1036, 2007.

- [31] Stavrakoudis, D. G., Galidaki G. N., Gitas I. Z., Theocharis J. B., „Enhancing the Interpretability of Genetic Fuzzy Classifiers in Land Cover Classification from Hyperspectral Satellite Imagery,” WCCI 2010 IEEE World Congress on Computational Intelligence, Barcelona, Spain. 2010.
- [32] Freund, Y., Schapire R., „Experiments with a new boosting algorithm,” Proceedings of 13th International Conference on Machine Learning, pp. 148–156, 1996.
- [33] Hoffman F., „Combining boosting and evolutionary algorithms for learning of fuzzy classification rules,” Fuzzy Sets Syst., vol. 14, no. 1, pp. 47–58, 2004.
- [34] Beneš, J., „Některé otázky syntézy kooperativního, evolučního a situačního řízení.” Automatizace , roč. 27, č. 8-9, pp. 213-216, 1984.
- [35] Beneš, J., „Nové výhledy technické kybernetiky.” Věda a lidstvo. Horizont, Praha, pp. 241-252, 1983.
- [36] Papageorgiou, E. I., Salmeron, J. L., „A Review of Fuzzy Cognitive Maps research during the last decade,” IEEE Transactions on Fuzzy Systems, vol.21, no.1, pp.66,79, Feb. 2013.
- [37] León, M., Rodriguez, C., García, M.M., Bello, R., Vanhoof, K., “Fuzzy Cognitive Maps for Modeling Complex Systems”. Advances in Artificial Intelligence. 9th Mexican International Conference on Artificial Intelligence, MICAI 2010, Pachuca, Mexico, November 8-13, 2010, Proceedings, Part I, pp 166-174. Springer Berlin Heidelberg. ISBN 978-3-642-16760-7
- [38] Li, X., „Dynamic Knowledge Inference and Learning under Adaptive Fuzzy Petri Net Framework,” IEEE Transactions on Systems, Man, and Cybernetics – Part C: Applications and Reviews, vol.30, no.4, pp. 442-450, Nov 2000. ISSN 1094-6977
- [39] Axelrod, R., „Structure of decision: The Cognitive Maps of political elites,” Princeton, N.J.: Princeton University Press, 1976.
- [40] Vaščák, J., Madarász L., „Adaptation of Fuzzy Cognitive Maps – a Comparison Study,” Acta Polytechnica Hungarica, Vol. 7, No. 3, pp.109,122, 2010.
- [41] Gregor, Michal., Groumpos, P. P., „Tuning the Position of a Fuzzy Cognitive Map Attractor Using Backpropagation through Time”, The 7th International Conference on Integrated Modeling and Analysis in Applied Control and Automation, Athens, Greece, 25-27 Sep. 2013.
- [42] Kosko B., „Fuzzy Cognitive Maps”, International Journal of Man-Machine Studies, Elsevier, Vol. 24, No. 1, pp. 65-75, 1986
- [43] Papageorgiou, E.I., „Learning Algorithms for Fuzzy Cognitive Maps – A Review Study,” IEEE Transactions on Systems, Man, and Cybernetics, Part C: Applications and Reviews, vol.42, no.2, pp.150,163, March 2012.

- [44] Ketipi, M.K., Koulouriotis, D.E., Karakasis, E.G., Papakostas, G.A., Tourassis, V.D., „Nonlinear cause-effect relationships in Fuzzy Cognitive Maps,” 2011 IEEE International Conference on Fuzzy Systems (FUZZ), pp.836,843, 27-30 June 2011.
- [45] Chen S. M., „Cognitive-Map-based Decision Analysis Based on NPN Logics”, Fuzzy Sets and Systems, Elsevier, Vol. 71, No. 2, pp. 155-163, 1995.
- [46] Gregor, Michal., Groumpos, P. P., „Training Fuzzy Cognitive Maps Using Gradient-Based Supervised Learning”, IFIP Advances in Information and Communication Technology, Volume 412, pp 547-556, Jan. 2013.
- [47] Vaščák, J., „Príklady aplikácií fuzzy kognitívnych máp v robotike,” Sborník príspevků z letní školy Mezioborové přístupy informatiky a kognitivní vědy. Hradec Králové. Gaudeamus. 2013. pp. 74-92. ISBN 978-80-7435-311-6
- [48] Stylios, Ch. D., Groumpos, P. P., „Modeling Complex Systems Using Fuzzy Cognitive Maps,” IEEE Transactions on Systems Man and Cybernetics, Part A: Systems and Humans, vol. 34, no. 1, January 2004.
- [49] Stach, W., Kurgan, L., Pedrycz, W., „Data-driven Nonlinear Hebbian Learning method for Fuzzy Cognitive Maps,” IEEE International Conference on Fuzzy Systems (FUZZ), IEEE World Congress on Computational Intelligence. pp.1975,1981, 1-6 June 2008
- [50] Diesinger, A.L., „Systems Of Commercial Turbofan Engines,” Springer-Verlag, 2008, pp. 234, ISBN 978-3-540-73618-9
- [51] Baskharone, E. A., „Principles of Turbomachinery in Air-Breathing Engines,” Cambridge Aerospace Series, Cambridge University Press, pp. 600, 2006, ISBN-13: 978-0521858106.
- [52] Lazar, T., et. al., „Tendencie vývoja a modelovania avionických systémov,” 160 pp, ISBN 80-88842-26-3, MoSR, Bratislava, 2000.
- [53] Főző, L., Andoga, R., Madarász, L., Kolesár, J., Judičák J., „Description of an Intelligent Small Turbocompressor Engine with Variable Exhaust Nozzle,” IEEE 13th International Symposium on Applied Machine Intelligence and Informatics (SAMII), January 22-24, 2015, Herľany, Slovakia. ISBN 978-1-4799-8221-9.
- [54] Hagiwara, M., „Extended fuzzy cognitive maps,” 1992 IEEE International Conference on Fuzzy Systems, pp.795,801, 8-12 Mar 1992.

Profil doktoranda

1. Curriculum Vitae



Ing. Michal Puheim je absolventom Gymnázia Poštová 9 v Košiciach, kde študoval v gymnaziálnom odbore so zameraním na matematiku (2004-2008). Počas stredoškolského štúdia pôsobil na pozícii manažéra marketingu a neskôr viceprezidenta študentskej spoločnosti Aurora. Bol členom organizačného tímu Medzinárodného turnaja mladých fyzikov IYPT 2006 (International Young Physicists' Tournament) na Slovenskej Technickej Univerzite v Bratislave. Po ukončení štúdia absolvoval jazykovú skúšku z anglického jazyka, kde získal medzinárodne uznávaný jazykový certifikát Cambridge First Certificate in English (FCE).

Neskôr úspešne ukončil bakalárske a inžinierske štúdium na FEI TU v Košiciach v odbore Umelá inteligencia (2008-2013). Absolvoval študijnovo-výskumný pobyt "Erasmus Intensive Programme: Developing Open Source Systems Expertise in Europe", so zameraním na programátorské zručnosti, na University of Applied Sciences FH JOANNEUM (Graz-Kapfenberg, Rakúsko, 2012).

V súčasnosti pôsobí na Katedre kybernetiky a umelej inteligencie FEI TU v Košiciach v odbore Umelá inteligencia, ako interný doktorand 2. ročníka štúdia. Je autorom a spoluautorom domácich a zahraničných publikácií v tematike navrhutej dizertačnej práce. Pôsobil v medzinárodnom organizačnom výbore IEEE konferencií SAMI 2014 a SAMI 2015. Na konferencii SAMI 2014 získal cenu Baltazára Frankoviča pre mladých vedcov za najlepší konferenčný príspevok. Participuje na riešení projektov VEGA č. 1/0298/12 „Digitálne riadenie systémov s dvoma stupňami voľnosti“, KEGA č. 018TUKE – 4/2012 „Progresívne metódy výučby riadenia a modelovania zložitých systémov objektovo orientované na letecké turbokompresorové motory“ a KEGA č. 014TUKE-4/2015 – „Digitalizácia, virtualizácia a testovanie malého prúdového motora a jeho častí pomocou stendov pre potreby modernej aplikovanej výuky.“

2. Publikačná činnosť

Skupina A1 - Knižné publikácie charakteru vedeckej monografie (AAA, AAB, ABA, ABB, ABC, ABD)

Počet záznamov: 1

AAB - Vedecké monografie vydané v domácich vydavateľstvách (1)

Skupina C - Ostatné recenzované publikácie (ACC, ACD, ADE, ADF, AEC, AED, AFA, AFB, AFC, AFD, AFE, AFF, AFG, AFH, BBA, BBB, BCK, BDA, BDB, BDE, BDF, BEC, BED, BFA, BFB, BGH, CDE, CDF)

Počet záznamov: 8

ADE - Vedecké práce v zahraničných nekarentovaných časopisoch (1)

AED - Vedecké práce v domácich recenzovaných vedeckých zborníkoch, monografiách (1)

AFC - Publikované príspevky na zahraničných vedeckých konferenciách (3)

AFD - Publikované príspevky na domácich vedeckých konferenciách (3)

Počet záznamov spolu: 8

Menný zoznam publikácií:

AAB - Vedecké monografie vydané v domácich vydavateľstvách(1)

AAB001 [v tlači] **Vzájomnosť teoreticko-praktických problémov prognózovania spoľahlivosti MPM** / Tobiáš Lazar, Ladislav Madarász, Vladimír Gašpar, Ladislav Nyulászi, Michal Puheim - 1. vyd - Košice : Elfa - 2015. - ISBN 978-80-8086-236-7.

[LAZAR, Tobiáš - MADARÁSZ, Ladislav - GAŠPAR, Vladimír – NYULÁSZI, Ladislav – PUHEIM, Michal]

ADE - Vedecké práce v zahraničných nekarentovaných časopisoch(1)

ADE001 [149436] **Application of Tracking-Learning-Detection for Object Tracking in Stereoscopic Images** / Michal Puheim - 2014.In: Advances in Intelligent Systems and Computing. Vol. 316 (2014), p. 323-331. - ISBN 978-3-319-10782-0 - ISSN 2194-5357

[PUHEIM, Michal - BUNDZEL, Marek - SINČÁK, Peter - MADARÁSZ, Ladislav]

AED - Vedecké práce v domácich recenzovaných vedeckých zborníkoch, monografiách(1)

AED001 [138385] **Aplikácia metódy TLD na sledovanie objektov v stereovíznom obraze** / Michal Puheim, Marek Bundzel - 2013.In: Electrical Engineering and Informatics 4: Proceedings of the Faculty of Electrical Engineering and Informatics of the Technical University of Košice. - Košice: TU, 2013 S. 136-141. - ISBN 978-80-553-1440-2

[PUHEIM, Michal - BUNDZEL, Marek]

AFC - Publikované príspevky na zahraničných vedeckých konferenciách(3)

AFC001 [140886] **Forward Control of Robotic Arm Using the Information from Stereo-vision Tracking System** / Michal Puheim, Marek Bundzel, Ladislav Madarász - 2013.In: CINTI 2013 : 14th IEEE International Symposium on Computational Intelligence and Informatics: Proceedings: November 19-21, 2013, Budapest. - Piscataway: IEEE, 2013 P. 57-62. - ISBN 978-1-4799-0197-1

[PUHEIM, Michal - BUNDZEL, Marek - MADARÁSZ, Ladislav]

AFC002 [148036] **On Practical Constraints of Approximation Using Neural Networks on Current Digital Computers** / Michal Puheim... [et al.] - 2014.In: INES 2014: IEEE 18th International Conference on Intelligent Engineering Systems: Proceedings: July 3-5, 2014, Tihany, Hungary. - Danvers: IEEE, 2014 P. 257-262. - ISBN 978-1-4799-4616-7
[PUHEIM, Michal - NYULÁSZI, Ladislav - MADARÁSZ, Ladislav - GAŠPAR, Vladimír]

AFC003 [152843] **Three-Term Relation Neuro-Fuzzy Cognitive Maps** / Michal Puheim, Ján Vaščák, Ladislav Madarász - 2014.In: CINTI 2014: 15th IEEE International Symposium on Computational Intelligence and Informatics: Proceedings: November 19-21, 2014, Budapest. - Danvers: IEEE, 2014 P. 477-482. - ISBN 978-1-4799-5337-0
[PUHEIM, Michal - VAŠČÁK, Ján - MADARÁSZ, Ladislav]

AFD - Publikované príspevky na domácich vedeckých konferenciách(3)

AFD001 [145208] **Diagnostics of complex systems using thermography** / František Adamčík... [et al.] - 2014. In: SAMI 2014: IEEE 12th International Symposium on Applied Machine Intelligence and Informatics: proceedings: January 23-25, 2014, Herľany, Slovakia. Danvers: IEEE, 2014 S. 109-113. - ISBN 978-1-4799-3441-6
[ADAMČÍK, František ml. - BRÉDA, Róbert - LAZAR, Tobiáš - PUHEIM, Michal]

AFD002 [147223] **Introduction to Modeling of Complex Systems Using Fuzzy Cognitive Maps** / Michal Puheim - 2014.In: SCYR 2014: 14th Scientific Conference of Young Researchers: proceedings from conference: May 20th, 2014, Herľany, Slovakia. - Košice: TU, 2014 S. 201-204. - ISBN 978-80-553-1714-4
[PUHEIM, Michal]

AFD003 [148037] **Normalization of inputs and outputs of neural network based robotic arm controller in Role of Inverse kinematic model** / Michal Puheim, Ladislav Madarász - 2014.In: SAMI 2014: IEEE 12th International Symposium on Applied Machine Intelligence and Informatics: proceedings: January 23-25, 2014, Herľany, Slovakia. - Danvers: IEEE, 2014 S. 35-38. - ISBN 978-1-4799-3441-6
[PUHEIM, Michal - MADARÁSZ, Ladislav]